




Amélioration et valorisation de la qualité des données

Table des matières

I - Contexte	3
II - Évaluation systématique de la qualité des données	4
A. Cadre d'analyse de la qualité des données.....	4
B. Audit approfondi des jeux de données.....	6
III - Techniques d'amélioration des données	9
A. Nettoyage et prétraitement avancé.....	9
B. Augmentation et enrichissement des données.....	10
IV - Mise en œuvre d'une stratégie de données de qualité	12
A. Stratégies de collecte et validation des données.....	12
B. Intégration dans le cycle de vie des modèles.....	14
V - Synthèse	15
VI - Auto-évaluation	19
VII - Exercice : Optimiser la qualité des données pour un modèle de prédiction de pannes industrielles	24
Solutions des exercices	26

I Contexte

Contexte

Dans le domaine de l'intelligence artificielle, la **qualité des données** constitue l'un des leviers stratégiques les plus puissants pour influencer la réussite ou l'échec des modèles. Contrairement à une croyance tenace, les performances d'un algorithme ne dépendent pas seulement de la sophistication des architectures ou de la puissance de calcul, mais avant tout de la **richesse**, de la **cohérence** et de la **pertinence** des données d'entraînement et de test utilisées. Comme l'illustre parfaitement l'adage « *Garbage in, garbage out* », même le modèle le plus avancé ne peut compenser une entrée de données dégradée ou inadaptée.

La **qualité des données** ne se limite pas à l'absence d'erreurs ou de valeurs manquantes : elle intègre la **complétude**, l'**exactitude**, la **cohérence interne**, la **fraîcheur** (actualité), la **représentativité** et la **pertinence** au regard des usages réels. Dans des environnements aussi variés que la santé, la finance, la maintenance industrielle ou le e-commerce, des jeux de données imparfaits ou mal documentés demeurent la cause la plus fréquente d'écarts imprévus de performance, de biais ou de dysfonctionnements en production.

Cette leçon s'attache à explorer toutes les méthodologies permettant d'**évaluer la qualité des données de façon rigoureuse et systématique**, mais aussi à présenter les stratégies d'**amélioration concrète** : audit, nettoyage, enrichissement, équilibrage, validation et surveillance continue. Les exemples issus de différents secteurs démontrent qu'un **investissement ciblé sur la qualité** offre généralement un retour bien supérieur à celui obtenu par une simple optimisation des modèles – un constat partagé par les équipes IA les plus performantes du marché.

Plus qu'un préalable à l'apprentissage, la **maîtrise de la qualité des données** devient le véritable moteur de progression et de fiabilité pour tous les systèmes d'IA ambitieux, en garantissant à la fois la robustesse, l'explicabilité et la capacité d'adaptation des modèles tout au long de leur cycle de vie.

II Évaluation systématique de la qualité des données

A. Cadre d'analyse de la qualité des données

Dimensions de la qualité des données en IA

La **qualité des données** est multidimensionnelle : il ne s'agit pas seulement d'éviter les erreurs de saisie, mais d'assurer que chaque information utilisée par un modèle soit **complète, exacte, cohérente, représentative, pertinente et à jour**. Dans un contexte IA, toute déficience sur l'une de ces dimensions peut gravement altérer la capacité du modèle à apprendre, à généraliser et à délivrer des résultats fiables.

La **complétude** garantit qu'aucune variable-clé n'est laissée vide de façon systématique ou aléatoire. Si, dans un projet d'assurance, la moitié des dossiers manquent l'information « *date de premier contrat* », toute prévision de churn cesse d'être robuste sur certains segments clients.

L'**exactitude** mesure si les données saisies reflètent fidèlement la réalité : une erreur dans la valeur d'un capteur industriel, une faute dans une date de naissance ou la persistance d'une erreur de reporting bancaire peuvent propager le faux jusqu'à un niveau de décision automatisée. La **cohérence** vise la non-contradiction du dataset : des transactions postérieures à la date de clôture d'un compte, ou des âges calculés incohérents sont des signaux de fragilité. L'**actualité** (fraîcheur) devient critique lorsque la réalité se transforme vite : un algorithme de détection de fraude restera aveugle à de nouveaux modes opératoires si le jeu d'entraînement date de plusieurs années.

La **représentativité** est essentielle pour éviter tout biais : si tous les exemples d'un modèle de vision industrielle proviennent d'une seule usine, il échouera face à une production venue d'ailleurs. Enfin, la **pertinence** relie la donnée à l'objectif : garder des variables superflues, ou perdre des informations-clés absentes des features, nuit à la performance autant qu'un bug.

Dans la santé, la finance ou le retail, les entreprises qui investissent dans ces dimensions voient une réduction spectaculaire des incidents et une progression rapide de la valeur obtenue par l'IA.

Représentativité des données

[Az Définition](#)

La **représentativité** désigne la correspondance entre l'échantillon de données disponible et la diversité réelle de la population ou des situations en production.

Si un dataset ne couvre que certains groupes (âge, région, type de produit), le modèle sera biaisé et inapte à généraliser.

Complétude des données

[Az Définition](#)

La **complétude** désigne le fait que l'ensemble des champs ou variables attendus dans une base de données soit effectivement rempli pour chaque échantillon ou presque, sans valeurs « *nulles* » ou manquantes invalidantes.

Évaluation quantitative de la qualité des données

Détection des problèmes de distribution et de représentativité

Un modèle d'IA performant exige que ses données d'entraînement et de test couvrent fidèlement l'espace réel des cas d'usage. Or, il est fréquent que le dataset ignore des segments entiers de la population : seuls certains profils clients sont collectés, seuls des patients hospitalisés dans un service précis sont inclus, ou certains types de transactions sont peu représentés.

Comparer la **distribution** des variables entre l'entraînement, le test et la population cible permet de repérer ces problèmes structurels : tests statistiques, visualisations de clusters (analyse en composantes principales), ou détection de drift via des indicateurs comme le Wasserstein Distance ou le Kolmogorov-Smirnov sont essentiels.

Dans la pratique, une banque française a pu, grâce à une analyse de distribution approfondie, détecter un biais dans son historique de crédits : les clients jeunes étaient sous-représentés, faussant le scoring des nouveaux entrants.

La correction peut alors passer par un rééquilibrage de l'échantillon ou une priorisation de la collecte de nouvelles données couvrant les zones ignorées.

Scoring bancaire biaisé

👁 Exemple

Une banque a découvert que les clients **étudiants** étaient quasi absents de son historique de crédit. Résultat : le modèle classait systématiquement les jeunes demandeurs comme « à risque ». La correction a consisté à **rééquilibrer l'échantillon** en collectant spécifiquement des dossiers étudiants.

Biais cachés

⚠ Attention

Un modèle performant en test peut masquer d'énormes biais si ses tests reposent sur des sous-populations surreprésentées ou sur une distribution « idéalisée » des cas. Toujours vérifier la représentativité réelle avant de déclarer les performances comme « généralisables ».

Analyse des valeurs manquantes et aberrantes

Les **valeurs manquantes** et les **outliers** constituent des sources majeures de dégradation de la qualité des données. Une analyse efficace commence par l'identification des patterns de valeurs manquantes : sont-elles concentrées sur certains champs, certains groupes, certaines périodes ? Ces patterns révèlent souvent des problèmes de collecte, de saisie ou des défauts d'intégration de sources multiples.

La détection d'**outliers** repose sur des statistiques robustes (écart interquartile, méthodes robustes de Mahalanobis, application de modèles non supervisés). Les visualisations (boxplots, techniques de réduction de dimension, heatmaps de valeurs extrêmes) permettent d'anticiper les causes : nouvelle gamme de produits, erreur de saisie, rupture technologique, panne de capteur, etc.

Un cas typique concerne une grande compagnie d'assurance qui, en identifiant une anomalie dans ses distributions de sinistralité, a corrigé des années d'historique erroné, ce qui a immédiatement amélioré la justesse et l'équité de son modèle de tarification.


Heatmap des valeurs manquantes

Heatmap des valeurs manquantes


Matrice de complétude

	Janv.	Févr.	Mars	Avr.	Mai	Juin
Identifiant client	12 %	28 %	45 %	68 %	57 %	81 %
Date de transaction	4 %	11 %	18 %	29 %	43 %	65 %
Montant commande	1 %	5 %	10 %	19 %	31 %	46 %
Canal de vente	21 %	44 %	58 %	70 %	76 %	89 %
Code postal	7 %	12 %	43 %	67 %	82 %	90 %
Segment client	13 %	20 %	27 %	41 %	54 %	63 %
Date de livraison	2 %	4 %	9 %	16 %	30 %	42 %
Statut retour	0 %	3 %	11 %	28 %	39 %	61 %

Légende



Valider auprès d'un référent métier



En cas de doute sur l'origine d'une valeur extrême, toujours valider l'hypothèse d'erreur auprès d'un référent métier avant de corriger ou d'exclure des données potentiellement valides mais peu fréquentes.

B. Audit approfondi des jeux de données

Méthodologie d'audit des données d'entraînement

L'**audit approfondi** d'un jeu de données ne se limite pas à un simple passage en revue des statistiques descriptives : il s'agit d'un processus complet, itératif et collaboratif, où chaque variable, chaque corrélation et chaque rupture temporelle ou métier doit être analysée. On commence par réaliser un **profilage statistique avancé** : distributions des variables, taux de valeurs uniques, couples de variables fortement corrélées, variables constantes ou quasi-constantes. Cette étape dévoile les premières anomalies et lacunes.

Un **examen des corrélations** entre features révèle fréquemment des redondances, voire des problèmes de fuites de données où une variable annonce, sans le vouloir, la cible à prédire (ex : code de transaction qui trahit son statut « fraude » ou non). La **cohérence temporelle** est également primordiale : un même jeu de données peut afficher des patterns saisonniers invisibles à première vue, ou contenir des « coupures » dues à des changements de process métier (nouveau CRM, changement d'unités de mesure, etc.).

La **validation métier** est une étape cruciale souvent négligée : faire relire les conclusions ou les découvertes à des experts terrain permet de distinguer les erreurs réelles des cas particuliers légitimes. Un audit conduit sérieusement, comme dans le cas d'une grande entreprise de vente en

ligne ayant découvert une incohérence entre le suivi web et la livraison, débouche régulièrement sur des actions structurelles : refonte des processus de collecte, filtrage automatisé, enrichissement ciblé ou rétro-correction historique.

Détection automatisée des anomalies dans les données

Évaluation de la qualité des annotations et étiquettes

La fiabilité des **étiquettes** ou annotations est déterminante dans un projet supervisé : une cible bruitée ou incohérence fausse la totalité de l'apprentissage, même avec un dataset volumineux et riche. La première étape consiste à mesurer l'**accord inter-annotateurs** : un faible taux de consensus suggère la nécessité de clarifier les consignes, d'améliorer la formation ou de spécialiser l'annotation par cas difficiles. Les modèles de confiance, qui prédisent le risque d'erreur d'étiquetage à partir du contexte, ou l'analyse des résidus d'un modèle déjà entraîné (ex : erreurs systématiques sur une classe) sont aussi vivement recommandés.

Dans l'univers de la santé, le recours à la validation croisée des annotations entre équipes (double lecture d'imagerie médicale, arbitrage par expert senior) a permis d'améliorer significativement la performance, la stabilité et la crédibilité des modèles mis en production. Ces pratiques évitent de bâtir des systèmes IA sur des labels contestables qui renforcent les biais ou sapent la confiance métier.

Danger d'un biais d'annotation

⚠ Attention

Un biais à l'annotation – par exemple, des annotateurs qui survalorisent certains cas rares ou ignorent certaines subtilités – peut avoir des conséquences désastreuses : le modèle cherchera à reproduire ce biais et sera incapable de généraliser, ou risquera d'être injuste sur certains segments.

Santé – annotation divergente

👁 Exemple


En imagerie médicale, deux radiologues annotaient différemment les mêmes radios (tumeurs bénignes vs suspectes). Le modèle oscillait et produisait des prédictions incohérentes. Une **double-lecture avec arbitrage par un senior** a permis de clarifier les labels et de doubler la stabilité du modèle.

Analyse de l'adéquation des données avec les objectifs du modèle

Avant de consacrer du temps au nettoyage ou à l'augmentation d'un jeu de données, il faut s'assurer que ce jeu est **pertinent** pour l'objectif du modèle. Cela implique d'identifier les **gaps informationnels** : quelles variables essentielles manquent pour prédire ce que l'on vise ? Y a-t-il des aspects du phénomène jamais couverts par les données historiques ? L'évaluation de la pertinence s'appuie souvent sur l'analyse d'erreurs du modèle : là où il échoue, il manque fréquemment une pièce d'information ou une granularité suffisante.

Par exemple, une société de logistique s'est aperçue que ses modèles de prévision d'incidents de livraison échouaient systématiquement sur les zones rurales – simplement parce qu'aucune donnée contextuelle sur les conditions météo ou l'état du réseau routier n'était collectée dans ces segments. Elle a donc complété son système par des données externes, ce qui a immédiatement amélioré les performances.

L'adéquation s'obtient enfin par des entretiens métier : confronter les résultats du modèle et l'explicabilité de ses échecs à ceux qui connaissent le terrain révèle très vite les lacunes structurelles du dataset.

Toujours croiser diagnostic data et retours d'usage

Un audit purement automatisé ne suffit jamais : la confrontation avec les observations de terrain et l'analyse métier permet de détecter les angles morts et de prioriser les correctifs ayant réellement un impact sur l'adoption et la crédibilité du modèle.

III Techniques d'amélioration des données

A. Nettoyage et prétraitement avancé

Stratégies optimales de gestion des valeurs manquantes

La gestion des **valeurs manquantes** est un défi constant : en IA, ignorer ou remplacer ces absences sans réflexion peut détériorer dramatiquement le pouvoir prédictif. Il convient d'abord d'identifier la nature des manques : sont-ils isolés, concentrés sur certaines variables ou groupes de données ? Sont-ils dus à des oublis, à des défauts structurels dans la collecte, ou à des réponses non-applicables (NA logique) ?

Ensuite, le choix de la technique d'**imputation** devient stratégique. Une méthode simple comme la moyenne ou la médiane convient parfois pour les numériques, mais peut amplifier les biais si les absences ne sont pas aléatoires. Les méthodes par **modèles** (régression, k plus proches voisins, imputation multiple) rendent possible la préservation des corrélations et la maîtrise de l'incertitude sur l'imputation. Enfin, il faut toujours analyser l'impact sur la performance du modèle : dans une entreprise industrielle, l'usage d'une stratégie d'imputation adaptative a permis de réduire le taux de faux positifs dans la maintenance prédictive de 30 %.

Les valeurs manquantes ne sont pas qu'un artefact gênant, mais souvent une source de signal sur les phénomènes sous-jacents. Parfois, leur présence même – si elle se concentre sur certains segments – peut devenir un prédicteur puissant ou éclairer une faille de collecte à corriger.

Normalisation et transformation optimisée des features

Une bonne **préparation des variables** (features engineering) est déterminante pour la convergence et l'efficacité des modèles. Les variables numériques doivent souvent être **mises à l'échelle** pour limiter l'influence disproportionnée des grandes valeurs : normalisation min-max, standardisation (centrage-réduction), ou normalisation robuste selon la distribution. Certaines distributions nécessiteront une transformation non linéaire, comme un passage en log ou une transformation Box-Cox, qui facilite la détection d'associations linéaires réelles.

Pour les données catégorielles, le choix entre **encodage one-hot**, **target encoding**, ou **embeddings** dépend du volume de modalités, de la cardinalité et du modèle cible. Un mauvais encodage (par ex, one-hot sur des dizaines de milliers de modalités) peut faire exploser la dimensionnalité et rendre le modèle inopérant.

Une entreprise de télécom française a ainsi obtenu une nette amélioration de la prédiction de churn en passant d'un simple label encoding à de l'embedding appris sur les historiques d'appels, réduisant la perte d'information et la sur-adaptation aux valeurs les plus fréquentes.

Imputation multiple

Az Définition

L'**imputation multiple** consiste à générer plusieurs jeux de valeurs plausibles pour chaque donnée manquante, puis à agréger les prédictions des modèles obtenus sur ces différents jeux, afin de mieux prendre en compte l'incertitude liée au remplissage artificiel.

Réduction du bruit et lissage des données

Dans de nombreux domaines, la qualité du signal sous-jacent se trouve masquée par des fluctuations aléatoires ou des artefacts. Améliorer le **rapport signal/bruit** constitue alors un des plus efficaces leviers d'amélioration de la donnée. Les techniques de **filtrage statistique** (moyenne

mobile, médiane glissante), de **décomposition fréquentielle** (ondelettes, FFT) ou de modèles d'**apprentissage supervisé du bruit** permettent de séparer la tendance pertinente des variations parasites.

Dans l'IoT industriel, une société française a multiplié la précision de ses prévisions grâce au denoising automatique des signaux capteurs, rendant son modèle moins sensible aux artefacts matériels ponctuels ou aux erreurs de transmission.

Savoir distinguer ce qui relève du bruit ou d'un comportement réel est aussi fondamental pour éviter de lisser des signaux d'alerte faibles mais pertinents (début de panne, utilisation anormale, etc.).

Toujours documenter les choix de nettoyage



Conseil

Chaque correction, imputation ou transformation appliquée doit être tracée et documentée pour assurer la reproductibilité, le suivi des impacts, et permettre de revenir en arrière en cas de détection ultérieure d'un effet indésirable.

B. Augmentation et enrichissement des données

Techniques d'augmentation adaptées aux différents types de données

Face à la rareté ou à la sous-représentation de certains cas dans le dataset d'entraînement, les stratégies d'**augmentation de données** consistent à créer de nouveaux exemples artificiels à partir de ceux déjà disponibles, de façon à améliorer la diversité et la robustesse du modèle. Ces techniques sont particulièrement puissantes dans les domaines de l'image, de l'audio, du texte et des séries temporelles.

Pour les **images**, il s'agit d'appliquer des transformations comme la rotation, le recadrage, l'inversion miroir, le zoom, ou le changement léger de couleur. De cette façon, un modèle de vision industrielle sera moins sensible à la position d'un défaut ou à la variation de lumière.

Avec les **données textuelles**, l'augmentation passe par la substitution lexicale (remplacement de mots par des synonymes ou des paraphrases), la translation automatique et retour (« *back-translation* »), ou l'insertion/suppression contrôlée de mots pour tester la robustesse sémantique.

Les **séries temporelles** bénéficient de méthodes comme la permutation locale, le jittering (ajout de petits bruits), la découpe en sous-séquences, ou la combinaison de fragments issus de plusieurs instances.

Une startup de vision par ordinateur française a, par exemple, doublé l'efficacité de son système de contrôle qualité en combinant différentes augmentations ciblées sur les cas de défauts rares.

Bien utilisée, l'augmentation de données permet de lutter contre le surajustement, d'améliorer l'équilibrage inter-classes et d'atténuer les biais de collecte.

NLP – Back Translation



Exemple

Dans l'analyse de sentiments en français, une équipe a utilisé la **back-translation** (traduction français → anglais → français) pour enrichir les commentaires texte. Résultat : le modèle a gagné +3 points de F1-score sur les critiques contenant des formations inhabituelles.

Génération synthétique de données avec les modèles génératifs

Stratégies d'enrichissement par données externes

L'**enrichissement** consiste à compléter le jeu de données de base par l'intégration de nouvelles sources d'information pertinentes et complémentaires. Il peut s'agir de données publiques (météo, indices économiques, géolocalisation, démographie) ou issues de partenariats (API spécialisées, bases sectorielles).

Ce renfort de contexte accroît la capacité du modèle à capter des patterns invisibles dans les seules données historiques internes. Un acteur du retail a ainsi incorporé des données météorologiques pour ses prévisions de ventes, découvrant que certains produits connaissent des pics atypiques uniquement lors d'événements climatiques.

L'enrichissement réclame toutefois une validation rigoureuse de la fiabilité, de la granularité et de la synchronisation des nouvelles sources, sous peine d'introduire un nouveau bruit ou des incohérences.

SMOTE et sur-échantillonnage synthétique

Az Définition

La technique **SMOTE** (Synthetic Minority Over-sampling Technique) consiste à générer artificiellement de nouveaux exemples pour la classe minoritaire en interpolant entre des points proches, ce qui permet de corriger les déséquilibres sans dupliquer les données existantes de façon simpliste.

Équilibrage des classes et gestion des données déséquilibrées

De nombreux cas réels souffrent d'un fort **déséquilibre de classes** (fraude/non-fraude, maladie rare/non malade, churner/client fidèle). Former un modèle sans traitement spécifique conduit à des prédictions biaisées ou inopérantes sur les classes les plus rares. L'équilibrage s'effectue par différentes méthodes : sous-échantillonnage intelligent de la classe majoritaire, sur-échantillonnage synthétique de la minoritaire via SMOTE ou GAN, pondération de la fonction de coût, voire recours à des architectures de modèles adaptés (ensembles spécifiques ou bagging pondéré).

Une banque a triplé son taux de détection de fraude après avoir adopté une stratégie combinant SMOTE avec des modèles robustes aux déséquilibres et une pondération adaptée de la fonction de perte.

Il est essentiel, ensuite, de valider la pertinence du nouvel échantillonnage sur la distribution réelle post-déploiement : un modèle trop « corrigé » en laboratoire peut se dégrader si la réalité terrain présente des cas encore différents ou une nouvelle dérive des ratios inter-classes.

Toujours valider l'augmentation

 Conseil

L'augmentation de données (images modifiées, textes paraphrasés) peut introduire des **artefacts non réalistes**. Il faut toujours vérifier avec des experts métier que les données générées restent crédibles.

Toujours surveiller l'impact post-déploiement

 Conseil

Tout changement structurel d'équilibrage ou d'enrichissement doit faire l'objet d'un suivi des métriques en production pour détecter d'éventuels effets secondaires non anticipés, adapter la stratégie et éviter la dégradation progressive liée à des évolutions de la population.

IV Mise en œuvre d'une stratégie de données de qualité

A. Stratégies de collecte et validation des données

Conception optimale des processus de collecte de données

La **qualité des données** se joue dès leur capture : un pipeline d'IA n'est jamais meilleur que l'amont du processus. Concevoir une **stratégie de collecte** efficace implique une réflexion sur le design des formulaires, des capteurs, des flux d'entrée. Il convient de mettre en place des **contrôles de qualité à la source**, comme des règles de format, des vérifications de valeur permises, ou des alertes temps réel en cas d'écart anormal.

Un protocole rigoureux de collecte réduit le coût de nettoyage en aval, diminue les pertes d'information, et garantit aux équipes IA une base de travail robuste et réutilisable. Par exemple, une entreprise de smart building a totalement réorganisé la collecte de mesures issues de centaines de capteurs, en centralisant le stockage et en imposant des contraintes de fraîcheur et de validité dès l'enregistrement des valeurs. Résultat : un taux d'incidents de collecte réduit de moitié et une nette élévation du potentiel prédictif de ses modèles.

La **validation** n'est pas qu'un contrôle ponctuel mais un système vivant, où la cohérence, la logique métier, la contrainte statistique et la détection de valeurs aberrantes sont testées régulièrement. Cela suppose des outils et pipelines automatisés pour traiter le flux entrant, avertir les opérateurs ou bloquer l'intégration de données suspectes.

Stratégies d'échantillonnage intelligent pour les jeux de test

Un jeu de test pertinent doit être **représentatif** de la diversité des cas réels, ni surspécifique, ni trop homogène. L'**échantillonnage stratifié** permet de garantir que chaque sous-groupe (région, catégorie, plage de dates, etc.) contribue proportionnellement aux évaluations. L'**échantillonnage par importance** cible les cas rares ou difficiles, et la création de **benchmarks dédiés** aide à mesurer les performances sur des cas jugés critiques par le métier.

A titre d'exemple, une entreprise de traduction automatique a amélioré l'évaluation de ses modèles en constituant un jeu de test enrichi en segment difficile (textes techniques, langues peu fréquentes), ce qui a permis de révéler des faiblesses insoupçonnées et d'orienter efficacement les efforts d'amélioration.


Schéma d'échantillonnage stratifié

Schéma d'échantillonnage stratifié

✗ Échantillonnage aléatoire simple



✓ Échantillonnage stratifié



■ Classe A ■ Classe B ■ Classe C

Data card (fiche de données)

Az Définition

Une **data card** est une fiche descriptive standardisée qui synthétise les caractéristiques, limites, usage prévu, sources, modalités de collecte et risques potentiels d'un jeu de données, facilitant la transparence, la gouvernance et la passerelle entre équipes.

Gouvernance et documentation des données

Assurer la qualité ne se résume pas à une succession d'actions techniques : il faut instituer de véritables **processus de gouvernance**, c'est-à-dire des standards formalisés, de la **documentation** exhaustive (data cards, guides d'utilisation, répertoires d'évolution), et des circuits de validation croisée.

La trace de chaque modification ou correction doit être conservée (versioning), chaque équipe ayant la responsabilité de justifier et d'expliquer ses choix de traitement. Une grande organisation française du secteur public a vu la performance et la reproductibilité de ses modèles bondir après avoir instauré une gouvernance data transversale et des audits qualité réguliers.

Documentation obligatoire pour la conformité

⚠ Attention

Respecter la réglementation et être à même d'expliquer un résultat algorithmique (ex : RGPD, audit externe) exige de documenter toutes les transformations et décisions impactant le jeu de données.

B. Intégration dans le cycle de vie des modèles

Amélioration itérative guidée par l'analyse d'erreurs

Améliorer un dataset est un **processus itératif** guidé par l'analyse des faiblesses du modèle : chaque erreur, chaque segment mal prédit révèle potentiellement un problème de couverture, un biais ou une lacune informationnelle. On cible alors l'enrichissement, la correction ou la collecte sur ces zones d'ombre plutôt que d'opérer des ajustements aléatoires ou globaux inutiles.

Dans le e-commerce, des cycles d'analyse fine des recommandations incorrectes ont permis de renforcer l'intégration des attributs produits ignorés et de recueillir des exemples dans les segments où le modèle échouait le plus fréquemment, élevant rapidement la pertinence perçue par les utilisateurs.

Retour d'expérience et apprentissage actif

Le retour d'expérience direct – remontée des erreurs utilisateurs, signalement de cas particuliers issus des opérations, ou confrontation des prédictions du modèle à la réalité terrain – est fondamental dans une démarche d'**apprentissage actif**. On exploite le feedback pour cibler manuellement ou automatiquement des zones sous-explorées, enrichir les annotations là où le modèle doute, et compléter le jeu avec des segments nouveaux.

Une startup française de NLP a ainsi mis en place un process de correction semi-automatique sur les cas de prédictions fausses relevés par ses clients, aboutissant à une forte réduction du taux d'erreur dans les six mois qui ont suivi.

Prioriser le retour métier dans la boucle d'amélioration


**Conseil**

Impliquez régulièrement les utilisateurs finaux et les référents opérationnels dans la validation ou correction des données pour garantir que les améliorations opérées correspondent à la complexité réelle et aux attentes du terrain.

Équilibre coût-bénéfice dans l'amélioration des données

Toute action d'**amélioration des données** a un coût : temps, budget d'annotation, charges informatiques, impacts réglementaires. Il importe donc d'évaluer systématiquement le **retour sur investissement** de chaque action : quelles corrections ou enrichissements ont un effet significatif sur la performance ? Quel est le point de rendement décroissant où l'amélioration data coûte plus qu'elle ne rapporte ? Cette analyse, appuyée sur des métriques objectivées et pilotée par des tableaux de bord, oriente intelligemment les ressources vers les tâches ayant le plus fort impact.

Soutenir une vraie culture data-centric dans l'organisation

**Conseil**

Le progrès durable en IA ne vient pas uniquement d'une amélioration technique ponctuelle, mais d'une transformation des réflexes collectifs face à la donnée : suivi, remise en question, collaboration entre équipes métier/data, pilotage par l'impact réel sur la performance et l'équité des modèles.

V Synthèse

A. Flashcards

Qualité des données

Ensemble de dimensions garantissant complétude, exactitude, cohérence, actualité, représentativité et pertinence des données IA.

Complétude

Absence de valeurs manquantes invalidantes sur les champs essentiels d'un dataset.

Représentativité

Correspondance entre l'échantillon disponible et la diversité réelle de la population cible.

Imputation multiple

Génération de plusieurs jeux de valeurs plausibles pour chaque donnée manquante, puis agrégation des prédictions.

SMOTE

Technique de sur-échantillonnage synthétique créant exemples artificiels pour la classe minoritaire par interpolation.

Data card

Fiche descriptive standardisée synthétisant caractéristiques, limites, sources et risques d'un jeu de données.

Outliers

Valeurs aberrantes ou extrêmes détectées par méthodes statistiques robustes dans un dataset.

Augmentation de données

Création d'exemples artificiels par transformations pour diversifier et enrichir le dataset d'entraînement.

Accord inter-annotateurs

Mesure du consensus entre annotateurs pour évaluer la fiabilité des étiquettes d'un dataset supervisé.

Normalisation

Mise à l'échelle des variables numériques pour limiter l'influence disproportionnée des grandes valeurs.

Enrichissement de données

Intégration de sources externes complémentaires pour accroître le pouvoir prédictif du modèle.

Gouvernance des données


Processus formalisés de documentation, validation, traçabilité et contrôle qualité des données IA.

La théorie en Bref

🔗 Fondamental

L'**amélioration de la qualité des données** constitue le levier stratégique majeur de la réussite des modèles d'IA, bien au-delà de la sophistication des algorithmes. La **qualité** repose sur six dimensions : **complétude**, **exactitude**, **cohérence**, **actualité**, **représentativité** et **pertinence**. L'**évaluation systématique** combine analyses statistiques, détection de valeurs manquantes et aberrantes, audit des annotations et validation de l'adéquation aux objectifs. Les


techniques d'amélioration incluent le nettoyage (imputation, traitement des outliers, normalisation), l'**augmentation** (transformations, génération synthétique, SMOTE) et l'**enrichissement** par données externes. La mise en œuvre pérenne exige une **gouvernance rigoureuse** : collecte validée à la source, documentation (data cards), monitoring continu et amélioration itérative guidée par l'analyse d'erreurs, intégrée dans les pipelines MLOps.



1. Absence de valeurs manquantes invalidantes sur les variables clés.
2. Fidélité des données saisies à la réalité observée.
3. Non-contradiction interne du dataset.
4. Fraîcheur et pertinence temporelle des données.
5. Couverture fidèle de la diversité réelle des cas.
6. Adéquation des variables aux objectifs du modèle.
7. Détection de biais et sous-représentation par tests statistiques.
8. Identification des patterns de lacunes dans les données.
9. Repérage des valeurs aberrantes par méthodes robustes.
10. Mesure de l'accord inter-annotateurs et validation métier.
11. Gestion des valeurs manquantes par modèles ou statistiques.
12. Détection et correction des valeurs extrêmes.
13. Mise à l'échelle et transformation des features.
14. Filtrage statistique pour améliorer le signal.
15. Rotation, recadrage, jittering selon le type de données.
16. GANs et modèles génératifs pour créer exemples artificiels.
17. Sur-échantillonnage synthétique pour équilibrer les classes.
18. Intégration de sources complémentaires pertinentes.
19. Contrôles qualité dès la capture des données.
20. Data cards et traçabilité des transformations.
21. Intégration du contrôle qualité dans MLOps.
22. Cycles guidés par analyse d'erreurs et retour métier.

Qualité des données IA

Les conseils pro



Comment auditer efficacement la qualité d'un jeu de données IA ?

- Réaliser un profilage statistique avancé pour identifier distributions, corrélations et variables constantes.
- Analyser les patterns de valeurs manquantes et aberrantes par segment et période.
- Mesurer l'accord inter-annotateurs et valider les étiquettes avec des experts métier.
- Confronter les résultats d'audit aux retours terrain pour détecter les angles morts structurels.

Comment choisir la stratégie d'imputation adaptée aux valeurs manquantes ?

- Identifier la nature des manques : aléatoires, structurels ou logiques.
- Privilégier les méthodes par modèles pour préserver les corrélations inter-variables.
- Mesurer l'impact de chaque stratégie sur la performance du modèle avant généralisation.
- Documenter et tracer chaque choix d'imputation pour assurer reproductibilité et audit.

Comment équilibrer un dataset fortement déséquilibré entre classes ?

- Combiner sous-échantillonnage intelligent de la classe majoritaire et sur-échantillonnage synthétique (SMOTE, GANs).
- Pondérer la fonction de coût pour pénaliser davantage les erreurs sur la classe minoritaire.
- Valider l'équilibrage sur la distribution réelle post-déploiement pour éviter les biais artificiels.
- Suivre les métriques métier (F1-score, recall) plutôt que l'accuracy globale.

Comment intégrer le contrôle qualité des données dans un pipeline MLOps ?

- Automatiser la validation des données entrantes avec règles de format et alertes temps réel.
- Implémenter un monitoring continu des dérives de distribution et des anomalies.
- Tracer toutes les transformations et corrections dans un système de versioning centralisé.
- Organiser des cycles d'amélioration itérative guidés par l'analyse d'erreurs du modèle en production.

Comment enrichir un dataset par des sources externes pertinentes ?

- Identifier les gaps informationnels en analysant les zones d'échec du modèle.
- Valider la fiabilité, la granularité et la synchronisation des nouvelles sources avant intégration.
- Tester l'impact de l'enrichissement sur la performance et la généralisation du modèle.
- Documenter l'origine, la licence et les limites de chaque source externe dans une data card.

VI Auto-évaluation

Exercice 1 : Dimensions de la qualité des données

[solution n°1 p. 26]

Exercice

La complétude d'un jeu de données garantit à elle seule qu'un modèle d'IA sera exempt de biais et produira des prédictions fiables.

Vrai

Faux

Exercice

Associez chaque dimension de la qualité des données à la situation qui illustre le mieux sa défaillance.

A Pertinence

B Cohérence

C Représentativité

D Actualité (fraîcheur)

Un algorithme de détection de fraude entraîné sur des données vieilles de plusieurs années reste aveugle aux nouveaux modes opératoires	Un modèle de vision industrielle entraîné sur une seule usine échoue sur des productions venues d'ailleurs	Des transactions enregistrées après la date de clôture d'un compte apparaissent dans le dataset	Des variables superflues sont conservées tandis que des informations-clés pour la prédiction sont absentes des features
---	--	---	---

Exercice

Une société de logistique constate que son modèle de prévision d'incidents de livraison échoue systématiquement sur les zones rurales. Aucune donnée météo ni sur l'état du réseau routier n'est collectée pour ces segments. Quelle dimension de la qualité des données est principalement en cause ?

La complétude, car des champs sont vides pour les zones rurales

La pertinence, car des informations essentielles à la prédiction sont absentes du dataset

L'exactitude, car les données rurales contiennent des erreurs de saisie

La cohérence, car les données rurales contredisent les données urbaines

Exercice 5 : Audit et détection des anomalies

[solution n°2 p. 27]

Exercice

Lors d'un audit approfondi d'un jeu de données d'entraînement, quelles actions font partie d'une méthodologie rigoureuse ? (Plusieurs réponses attendues)

A☐

Réaliser un profilage statistique avancé incluant les distributions, les taux de valeurs uniques et les variables quasi-constantes

B☐

Remplacer immédiatement toutes les valeurs aberrantes détectées par la médiane de la variable concernée

C☐

Examiner les corrélations entre features pour détecter des redondances ou des fuites de données vers la cible

D☐

Valider les conclusions auprès d'experts métier pour distinguer erreurs réelles et cas particuliers légitimes

E☐

Limitier l'audit aux statistiques descriptives pour gagner du temps avant la phase de modélisation

Exercice

Un faible taux d'accord entre annotateurs sur un jeu de données supervisé est un signal mineur qui n'affecte pas significativement les performances du modèle final.

Vrai

Faux

Exercice

Lors de l'examen des corrélations entre features d'un dataset de détection de fraude, vous constatez qu'une variable est corrélée à quasi 1 avec la cible. Quelle est l'interprétation la plus probable et l'action recommandée ?

C'est une excellente feature à conserver en priorité car elle maximisera la performance du modèle

Il s'agit probablement d'une fuite de données : la variable encode implicitement la cible et doit être exclue ou réexaminée

La variable est redondante avec d'autres features et doit être supprimée pour réduire la dimensionnalité

C'est un signe de biais de représentativité qui nécessite un rééquilibrage de l'échantillon

Exercice 9 : Nettoyage et prétraitement des données

[solution n°3 p. 29]

Exercice

Face à des valeurs manquantes dans un dataset industriel, quelles approches sont recommandées selon les bonnes pratiques décrites dans la leçon ? (Plusieurs réponses attendues)

A
☐ Identifier si les valeurs manquantes sont concentrées sur certaines variables, certains groupes ou certaines périodes avant de choisir une stratégie

B
☐ Supprimer systématiquement toutes les lignes contenant au moins une valeur manquante pour garantir la propreté du dataset

C
☐ Utiliser des méthodes d'imputation par modèles (régression, k plus proches voisins) pour préserver les corrélations entre variables

D
☐ Considérer la présence de valeurs manquantes comme un signal potentiel sur les phénomènes sous-jacents, voire comme un prédicteur

E
☐ Appliquer systématiquement la moyenne pour toutes les variables numériques, quelle que soit la distribution

Exercice

Remettez dans le bon ordre les étapes d'un pipeline de nettoyage et prétraitement d'un jeu de données pour un projet IA.

A Valider les anomalies détectées auprès d'un référent métier pour distinguer erreurs et cas légitimes

B Appliquer la stratégie d'imputation adaptée et traiter les valeurs aberrantes confirmées

C Identifier les patterns de valeurs manquantes et d'outliers par analyse statistique et visualisation

D Documenter chaque correction et transformation pour assurer la reproductibilité

E Appliquer les transformations de features (normalisation, encodage, réduction de bruit)

Réponse : _ _ _ _ _

Exercice 12 : Augmentation et équilibrage des données

[solution n°4 p. 30]

Exercice

Une banque cherche à améliorer son modèle de détection de fraude. Les transactions frauduleuses représentent moins de 0,5 % du dataset. Sans traitement spécifique, quel comportement typique observera-t-on sur le modèle entraîné ?

Le modèle sera très performant sur les deux classes car il dispose d'un grand volume de données

Le modèle tendra à prédire systématiquement la classe majoritaire, produisant des prédictions biaisées et inopérantes sur la classe fraude

Le modèle sur-apprendra uniquement sur les cas de fraude, ignorant les transactions normales

Le modèle sera instable et produira des prédictions aléatoires sur l'ensemble des transactions

Exercice

Associez chaque type de données à la technique d'augmentation qui lui est spécifiquement adaptée selon la leçon.

A Classes déséquilibrées**B** Données textuelles**C** Séries temporelles**D** Images

Rotation, recadrage, inversion miroir, changement de couleur	Back-translation et substitution lexicale par synonymes	Jittering, permutation locale et découpe en sous-séquences	Génération d'exemples synthétiques par interpolation entre points proches (SMOTE)
--	---	--	---

Exercice 15 : Gouvernance et amélioration continue

[solution n°5 p. 31]

Exercice

La documentation d'un jeu de données via une data card est une bonne pratique optionnelle, utile uniquement pour les grandes organisations disposant d'équipes data dédiées.

Vrai

Faux

Exercice

Dans une démarche d'amélioration itérative guidée par l'analyse d'erreurs, quelles pratiques sont cohérentes avec les principes décrits dans la leçon ? (Plusieurs réponses attendues)

A☐

Cibler l'enrichissement et la collecte sur les segments où le modèle échoue le plus fréquemment

B☐

Améliorer uniformément l'ensemble du dataset à chaque itération pour maximiser la couverture globale

C☐

Exploiter les retours d'expérience des utilisateurs finaux pour identifier les cas sous-explorés et enrichir les annotations

D☐

Évaluer le retour sur investissement de chaque action d'amélioration pour prioriser les efforts à fort impact

E☐

Déléguer exclusivement l'amélioration des données aux équipes techniques sans impliquer les référents métier

VII Exercice : Optimiser la qualité des données pour un modèle de prédiction de pannes industrielles

Mise en situation

Vous venez d'intégrer l'équipe Data & IA de **TechnoMaint**, une entreprise spécialisée dans la **maintenance prédictive** d'équipements industriels pour le secteur agroalimentaire. L'entreprise déploie des capteurs IoT sur les lignes de production de ses clients pour anticiper les pannes et réduire les arrêts non planifiés.

Votre responsable, Nadia Ferreira, vous confie un projet critique : le modèle de prédiction de pannes actuellement en production affiche un **taux de faux positifs de 38 %**, ce qui génère des interventions inutiles coûteuses et érode la confiance des clients. Après une première investigation, l'équipe suspecte que le problème vient principalement de la **qualité des données d'entraînement** plutôt que de l'architecture du modèle.

Données du projet

Vous disposez des éléments suivants :

- **Dataset principal** : 850 000 enregistrements de capteurs (température, vibration, pression, humidité) collectés sur **3 ans** auprès de **12 sites industriels**
- **Taux de valeurs manquantes** : **7 %** sur la variable « vibration », **22 %** sur la variable « humidité », **1 %** sur « température »
- **Répartition des classes** : **96,2 %** de fonctionnement normal vs **3,8 %** de pannes confirmées
- **Annotations** : les labels « panne » / « normal » ont été posés par les techniciens de maintenance sur site, sans protocole d'annotation unifié entre les 12 sites
- **Constat terrain** : 4 sites sur 12 sont situés en zone climatique tropicale, mais ces sites ne représentent que **8 %** du dataset alors qu'ils concentrent **27 %** des pannes réelles
- **Sources externes disponibles** : données météorologiques locales (API publique), fiches constructeur des équipements (PDF), historique des interventions de maintenance corrective (ERP client)

Variable	Type	Taux de manquants	Distribution
Température	Numérique	1 %	Normale, centrée sur 45°C
Vibration	Numérique	7 %	Asymétrique droite
Pression	Numérique	2 %	Bimodale
Humidité	Numérique	22 %	Concentrée sur les sites tropicaux
Label (panne/normal)	Catégoriel	0 %	Fortement déséquilibré (96,2 % / 3,8 %)

Question 1

[solution n°6 p. 32]

Réalisez un diagnostic structuré de la qualité du dataset de TechnoMaint en identifiant les problèmes majeurs sur au moins quatre dimensions de la qualité des données. Pour chaque problème identifié, expliquez son impact potentiel sur les performances du modèle de prédiction de pannes.

Question 2

[solution n°7 p. 33]

Proposez une stratégie d'amélioration du dataset en trois volets (nettoyage, augmentation/équilibre, enrichissement) en justifiant vos choix techniques pour chaque volet. Précisez les risques associés à chaque technique retenue.

Question 3

[solution n°8 p. 34]

L'équipe constate que les labels « panne » posés par les techniciens des 12 sites présentent des incohérences significatives. Élaborez un plan d'action pour fiabiliser les annotations, en intégrant des mesures immédiates et des mesures structurelles à moyen terme.

Question 4

[solution n°9 p. 35]

Nadia Ferreira vous demande de concevoir un dispositif de monitoring continu de la qualité des données une fois le modèle amélioré déployé en production. Décrivez les indicateurs à surveiller, les seuils d'alerte et le processus de réaction en cas de dégradation détectée.

Solutions des exercices

Solution n°1

[exercice p. 19]

Exercice

La complétude d'un jeu de données garantit à elle seule qu'un modèle d'IA sera exempt de biais et produira des prédictions fiables.

Vrai

✓ Faux



La complétude est une dimension nécessaire mais non suffisante. Un dataset peut être complet (aucune valeur manquante) tout en étant biaisé, inexact ou non représentatif. La qualité des données est multidimensionnelle : elle intègre également l'exactitude, la cohérence, l'actualité, la représentativité et la pertinence. Un jeu de données complet mais surreprésentant certains profils produira des modèles biaisés, comme l'illustre l'exemple bancaire où les clients jeunes étaient quasi absents malgré un historique volumineux.

Exercice

Associez chaque dimension de la qualité des données à la situation qui illustre le mieux sa défaillance.

Un algorithme de détection de fraude entraîné sur des données vieilles de plusieurs années reste aveugle aux nouveaux modes opératoires Actualité (fraîcheur)	Un modèle de vision industrielle entraîné sur une seule usine échoue sur des productions venues d'ailleurs Représentativité	Des transactions enregistrées après la date de clôture d'un compte apparaissent dans le dataset Cohérence	Des variables superflues sont conservées tandis que des informations-clés pour la prédiction sont absentes des features Pertinence
--	--	--	---



Chaque défaillance illustre une dimension précise : l'actualité concerne la fraîcheur des données face à une réalité qui évolue ; la représentativité désigne la couverture insuffisante de la diversité réelle des cas ; la cohérence renvoie à l'absence de contradictions internes dans le dataset ; la pertinence relie les variables disponibles à l'objectif réel du modèle. Ces quatre dimensions sont indépendantes : un dataset peut être à jour mais non représentatif, ou cohérent mais non pertinent.

Exercice

Une société de logistique constate que son modèle de prévision d'incidents de livraison échoue systématiquement sur les zones rurales. Aucune donnée météo ni sur l'état du réseau routier n'est collectée pour ces segments. Quelle dimension de la qualité des données est principalement en cause ?

La complétude, car des champs sont vides pour les zones rurales

✓ La pertinence, car des informations essentielles à la prédiction sont absentes du dataset

L'exactitude, car les données rurales contiennent des erreurs de saisie

La cohérence, car les données rurales contredisent les données urbaines



Le problème décrit n'est pas lié à des valeurs manquantes dans des champs existants (complétude), ni à des erreurs ou contradictions. Il s'agit d'un défaut de pertinence : les variables nécessaires pour prédire les incidents en zone rurale (météo, état du réseau) ne sont tout simplement pas collectées. La pertinence relie les données disponibles à l'objectif du modèle – ici, l'absence structurelle de ces informations crée un angle mort que ni le nettoyage ni l'imputation ne peuvent corriger.

Solution n°2

[exercice p. 20]

Exercice

Lors d'un audit approfondi d'un jeu de données d'entraînement, quelles actions font partie d'une méthodologie rigoureuse ? (Plusieurs réponses attendues)

A

☐

Réaliser un profilage statistique avancé incluant les distributions, les taux de valeurs uniques et les variables quasi-constantes

B

Remplacer immédiatement toutes les valeurs aberrantes détectées par la médiane de la variable concernée

C

☐

Examiner les corrélations entre features pour détecter des redondances ou des fuites de données vers la cible

D

☐

Valider les conclusions auprès d'experts métier pour distinguer erreurs réelles et cas particuliers légitimes

E

Limiter l'audit aux statistiques descriptives pour gagner du temps avant la phase de modélisation



Un audit rigoureux combine le profilage statistique avancé (distributions, corrélations, variables constantes), la détection de fuites de données (une variable qui trahit implicitement la cible), et la validation métier qui permet de distinguer une vraie erreur d'un cas rare mais légitime. Remplacer systématiquement les outliers par la médiane est une erreur : certaines valeurs extrêmes sont réelles et porteuses de signal. Se limiter aux statistiques descriptives est insuffisant car cela ne révèle pas les ruptures temporelles, les biais de collecte ni les incohérences métier.

Exercice

Un faible taux d'accord entre annotateurs sur un jeu de données supervisé est un signal mineur qui n'affecte pas significativement les performances du modèle final.

Vrai

✓ Faux



Un faible accord inter-annotateurs est au contraire un signal critique : il indique que les étiquettes sont bruitées ou incohérentes, ce qui fausse l'ensemble de l'apprentissage supervisé, même avec un dataset volumineux. L'exemple de l'imagerie médicale l'illustre parfaitement : deux radiologues annotant différemment les mêmes radios ont conduit à un modèle oscillant et instable. La mise en place d'une double lecture avec arbitrage a permis de doubler la stabilité du modèle. La qualité des labels est aussi déterminante que la quantité des données.

Exercice

Lors de l'examen des corrélations entre features d'un dataset de détection de fraude, vous constatez qu'une variable est corrélée à quasi 1 avec la cible. Quelle est l'interprétation la plus probable et l'action recommandée ?

C'est une excellente feature à conserver en priorité car elle maximisera la performance du modèle

✓ Il s'agit probablement d'une fuite de données : la variable encode implicitement la cible et doit être exclue ou réexaminée

La variable est redondante avec d'autres features et doit être supprimée pour réduire la dimensionnalité

C'est un signe de biais de représentativité qui nécessite un rééquilibrage de l'échantillon



Une corrélation quasi parfaite entre une feature et la cible est le signe classique d'une fuite de données (data leakage) : la variable contient une information qui ne serait pas disponible au moment de la prédiction réelle, ou qui encode directement le label (ex : un code de transaction qui trahit son statut fraude). Conserver cette variable produirait des performances artificiellement excellentes en test mais un modèle inutilisable en production. La redondance entre features est un problème distinct, et le rééquilibrage ne résout pas une fuite de données.

Solution n°3

[exercice p. 21]

Exercice

Face à des valeurs manquantes dans un dataset industriel, quelles approches sont recommandées selon les bonnes pratiques décrites dans la leçon ? (Plusieurs réponses attendues)



Identifier si les valeurs manquantes sont concentrées sur certaines variables, certains groupes ou certaines périodes avant de choisir une stratégie

B

Supprimer systématiquement toutes les lignes contenant au moins une valeur manquante pour garantir la propreté du dataset



Utiliser des méthodes d'imputation par modèles (régression, k plus proches voisins) pour préserver les corrélations entre variables



Considérer la présence de valeurs manquantes comme un signal potentiel sur les phénomènes sous-jacents, voire comme un prédicteur

E

Appliquer systématiquement la moyenne pour toutes les variables numériques, quelle que soit la distribution



La bonne pratique commence par analyser le pattern des manques (aléatoires ou structurels) avant de choisir la stratégie. Les méthodes par modèles (régression, KNN, imputation multiple) préservent les corrélations et maîtrisent l'incertitude, contrairement à la simple moyenne qui peut amplifier les biais si les absences ne sont pas aléatoires. La présence de valeurs manquantes peut elle-même être un signal prédicteur puissant. Supprimer toutes les lignes incomplètes entraîne une perte d'information importante et peut introduire un biais si les manques sont structurels.

Exercice

Remettez dans le bon ordre les étapes d'un pipeline de nettoyage et prétraitement d'un jeu de données pour un projet IA.

A Identifier les patterns de valeurs manquantes et d'outliers par analyse statistique et visualisation

B Valider les anomalies détectées auprès d'un référent métier pour distinguer erreurs et cas légitimes

C Appliquer la stratégie d'imputation adaptée et traiter les valeurs aberrantes confirmées

D Appliquer les transformations de features (normalisation, encodage, réduction de bruit)

E Documenter chaque correction et transformation pour assurer la reproductibilité



L'ordre logique est le suivant : (1) détecter les problèmes par analyse statistique avant toute intervention ; (2) valider avec les experts métier pour éviter de corriger des cas valides mais rares ; (3) appliquer les imputations et traitements des outliers confirmés ; (4) procéder aux transformations de features (normalisation, encodage) sur des données déjà nettoyées ; (5) documenter l'ensemble pour garantir la reproductibilité et permettre un retour arrière. Inverser ces étapes — par exemple normaliser avant de traiter les outliers — peut amplifier les distorsions et rendre les corrections ultérieures inefficaces.

Solution n°4

[exercice p. 22]

Exercice

Une banque cherche à améliorer son modèle de détection de fraude. Les transactions frauduleuses représentent moins de 0,5 % du dataset. Sans traitement spécifique, quel comportement typique observera-t-on sur le modèle entraîné ?

Le modèle sera très performant sur les deux classes car il dispose d'un grand volume de données

✓ Le modèle tendra à prédire systématiquement la classe majoritaire, produisant des prédictions biaisées et inopérantes sur la classe fraude

Le modèle sur-apprendra uniquement sur les cas de fraude, ignorant les transactions normales

Le modèle sera instable et produira des prédictions aléatoires sur l'ensemble des transactions



En présence d'un fort déséquilibre de classes, un modèle non traité apprend à prédire quasi systématiquement la classe majoritaire (non-fraude), ce qui lui permet d'atteindre une précision globale élevée tout en étant totalement inutile pour détecter les fraudes. Ce biais est structurel : le modèle optimise sa fonction de coût en ignorant la classe rare. C'est précisément pourquoi des techniques comme SMOTE, la pondération de la fonction de perte ou le sous-échantillonnage intelligent sont nécessaires pour forcer le modèle à apprendre les patterns de la classe minoritaire.

Exercice

Associez chaque type de données à la technique d'augmentation qui lui est spécifiquement adaptée selon la leçon.

Rotation, recadrage, inversion miroir, changement de couleur	Back-translation et substitution lexicale par synonymes	Jittering, permutation locale et découpe en sous-séquences	Génération d'exemples synthétiques par interpolation entre points proches (SMOTE)
Images	Données textuelles	Séries temporelles	Classes déséquilibrées



Chaque type de données requiert des techniques d'augmentation adaptées à sa structure : les images supportent des transformations géométriques et colorimétriques qui préservent le sens visuel ; les textes bénéficient de la back-translation et de la substitution lexicale pour diversifier les formulations sans altérer le sens ; les séries temporelles utilisent le jittering (ajout de bruit contrôlé) et la permutation pour simuler des variations réalistes ; SMOTE est spécifiquement conçu pour les classes minoritaires en générant des exemples synthétiques par interpolation, évitant la simple duplication.

Solution n°5

[exercice p. 22]

Exercice

La documentation d'un jeu de données via une data card est une bonne pratique optionnelle, utile uniquement pour les grandes organisations disposant d'équipes data dédiées.

Vrai

✓ Faux



La data card est une exigence structurelle, pas une option réservée aux grandes structures. Elle synthétise les caractéristiques, limites, sources, modalités de collecte et risques d'un dataset, facilitant la transparence, la gouvernance et la collaboration entre équipes. Dans un contexte réglementaire comme le RGPD, documenter les transformations et décisions impactant les données est une obligation pour pouvoir expliquer un résultat algorithmique lors d'un audit externe. L'absence de documentation empêche également la reproductibilité et rend impossible un retour arrière en cas d'effet indésirable détecté ultérieurement.

Exercice

Dans une démarche d'amélioration itérative guidée par l'analyse d'erreurs, quelles pratiques sont cohérentes avec les principes décrits dans la leçon ? (Plusieurs réponses attendues)



Cibler l'enrichissement et la collecte sur les segments où le modèle échoue le plus fréquemment

B

Améliorer uniformément l'ensemble du dataset à chaque itération pour maximiser la couverture globale



Exploiter les retours d'expérience des utilisateurs finaux pour identifier les cas sous-explorés et enrichir les annotations

D

Évaluer le retour sur investissement de chaque action d'amélioration pour prioriser les efforts à fort impact

E

Déléguer exclusivement l'amélioration des données aux équipes techniques sans impliquer les référents métier



L'amélioration itérative efficace cible les zones d'échec du modèle plutôt que d'opérer des ajustements globaux coûteux et peu différenciants. Les retours utilisateurs et opérationnels sont une source précieuse pour identifier les angles morts du dataset. L'évaluation du ROI de chaque action est indispensable pour éviter le point de rendement décroissant où l'amélioration data coûte plus qu'elle ne rapporte. En revanche, améliorer uniformément sans priorisation dilue les efforts, et exclure les référents métier prive l'équipe de la connaissance terrain nécessaire pour distinguer erreurs réelles et cas légitimes.

[exercice p. 25] **Solution n°6**

Réponse attendue

Le dataset de TechnoMaint présente des déficiences sur au moins quatre dimensions critiques de la qualité des données. La **complétude** est compromise par un taux de valeurs manquantes de **22 %** sur la variable « humidité », concentré sur les sites tropicaux, ce qui prive le modèle d'un signal potentiellement déterminant pour les pannes dans ces zones. La **représentativité** est gravement déséquilibrée : les sites tropicaux ne pèsent que **8 %** du dataset alors qu'ils concentrent **27 %** des pannes réelles, ce qui conduit le modèle à sous-apprendre les patterns spécifiques à ces environnements et à générer des faux positifs sur les autres sites. La **cohérence** des annotations est fragile puisque les labels ont été posés par des techniciens différents sur 12 sites sans protocole unifié, ce qui introduit un bruit d'étiquetage susceptible de dégrader l'apprentissage supervisé. Enfin, le **déséquilibre de classes** (**96,2 %** normal vs **3,8 %** pannes) biaise le modèle vers la prédiction majoritaire et réduit sa capacité à détecter les pannes réelles avec précision.

Éléments de solution

- **Dimensions à mobiliser** : complétude, représentativité, cohérence des annotations, pertinence, et potentiellement actualité si les données les plus anciennes reflètent des équipements depuis remplacés

- **Complétude** : le taux de **22 %** de manquants sur « humidité » n'est pas aléatoire — il est structurellement lié aux sites tropicaux, ce qui constitue un biais de collecte (données MNAR — *Missing Not At Random*)
- **Représentativité** : le ratio **8 % du dataset / 27 % des pannes** pour les sites tropicaux est un signal d'alerte majeur — le modèle est entraîné sur une distribution qui ne reflète pas la réalité opérationnelle
- **Cohérence des annotations** : sans accord inter-annotateurs mesuré, il est impossible de garantir que le label « panne » signifie la même chose d'un site à l'autre (seuil de déclenchement, gravité, moment de l'étiquetage)
- **Impact sur le modèle** : chaque déficience se traduit par un mécanisme de dégradation spécifique — les faux positifs à **38 %** résultent probablement d'une combinaison de ces facteurs
- **Méthode de diagnostic** : croiser l'analyse statistique (distributions, heatmaps de valeurs manquantes, tests de Kolmogorov-Smirnov entre sites) avec la validation métier auprès des techniciens terrain

[exercice p. 25] **Solution n°7**

Réponse attendue

Le volet **nettoyage** doit prioriser le traitement des **22 %** de valeurs manquantes sur « humidité » par une imputation par modèle (k plus proches voisins ou régression multivariée) plutôt que par la moyenne, car les manquants ne sont pas aléatoires et une imputation naïve écraserait les corrélations avec les conditions climatiques tropicales. Les outliers sur « vibration » (distribution asymétrique) doivent être analysés avec un référent métier pour distinguer les artefacts capteurs des signaux précurseurs de panne. Le volet **augmentation et équilibrage** doit combiner un sur-échantillonnage synthétique de la classe « panne » via **SMOTE** et une pondération de la fonction de coût pour pénaliser davantage les faux négatifs. Pour les sites tropicaux sous-représentés, un jittering ciblé sur les séries temporelles de ces sites permettra d'accroître leur poids dans l'entraînement. Le volet **enrichissement** intégrera les données météorologiques locales (température extérieure, hygrométrie, épisodes extrêmes) via l'API publique, et les historiques de maintenance corrective de l'ERP pour contextualiser les pannes. Le risque principal est d'introduire des artefacts non réalistes par l'augmentation ou un bruit supplémentaire par des sources externes mal synchronisées.

Éléments de solution

- **Nettoyage — imputation** : privilégier l'imputation multiple ou par k-NN pour préserver les corrélations inter-variables ; éviter la moyenne/médiane sur « humidité » car les manquants sont structurels (MNAR) ; tracer chaque imputation pour audit
- **Nettoyage — outliers** : utiliser l'écart interquartile ou la distance de Mahalanobis sur « vibration » ; valider systématiquement avec un technicien avant suppression pour ne pas éliminer des signaux faibles de pré-panne
- **Augmentation — SMOTE** : générer des exemples synthétiques de la classe « panne » par interpolation entre voisins proches ; risque : créer des exemples irréalistes si les classes se chevauchent dans l'espace des features
- **Augmentation — jittering temporel** : ajouter de petites perturbations aux séries des sites tropicaux pour accroître leur diversité ; risque : altérer des motifs temporels significatifs si le bruit ajouté est trop important
- **Équilibrage — pondération du coût** : augmenter le poids des erreurs sur la classe « panne » dans la loss function ; complémentaire au SMOTE, pas substituable

- **Enrichissement** : synchroniser les données météo avec les timestamps capteurs à la même granularité ; valider la fiabilité et la couverture géographique de l'API avant intégration ; documenter chaque source dans une data card
- **Risques transversaux** : sur-correction pouvant dégrader les performances en production si la distribution réelle diffère de l'échantillon rééquilibré ; nécessité d'un suivi post-déploiement des métriques

[exercice p. 25] **Solution n°8**

Réponse attendue

Les mesures immédiates consistent à **mesurer l'accord inter-annotateurs** en sélectionnant un échantillon représentatif de cas annotés par plusieurs sites et en calculant un score de concordance (kappa de Cohen ou Fleiss). Les cas de désaccord les plus fréquents doivent être soumis à un **arbitrage par un expert senior** de la maintenance pour établir un label de référence. En parallèle, une analyse des résidus du modèle actuel permettra d'identifier les segments où les erreurs de prédiction sont systématiques, signalant probablement des incohérences d'étiquetage. À moyen terme, il faut déployer un **protocole d'annotation unifié** définissant précisément les critères de classification « panne » vs « normal » (seuils, temporalité, gravité), former les techniciens des 12 sites à ce protocole, et instaurer un processus de **double annotation** avec arbitrage sur les cas ambigus. Enfin, la mise en place d'un outil de suivi de la qualité des annotations intégré au pipeline MLOps garantira un contrôle continu.

Éléments de solution

- **Mesure immédiate — accord inter-annotateurs** : calculer le kappa de Cohen (2 annotateurs) ou de Fleiss (>2 annotateurs) sur un échantillon stratifié par site et par type de panne ; un kappa inférieur à **0,6** signale un problème critique
- **Mesure immédiate — arbitrage expert** : constituer un panel de cas litigieux et les soumettre à un expert senior pour créer un « gold standard » de référence
- **Mesure immédiate — analyse des résidus** : examiner les erreurs systématiques du modèle par site — si un site concentre les faux positifs ou faux négatifs, le problème est probablement lié à l'annotation locale
- **Mesure structurelle — protocole unifié** : définir des critères objectifs et mesurables (ex : « panne = arrêt de production supérieur à 15 minutes consécutif à une défaillance mécanique ou électrique confirmée »)
- **Mesure structurelle — formation** : organiser des sessions de calibration inter-sites où les techniciens annotent les mêmes cas et comparent leurs décisions
- **Mesure structurelle — double annotation** : instaurer une relecture systématique sur un pourcentage des cas (ex : **20 %**) avec arbitrage automatique ou expert en cas de désaccord
- **Mesure structurelle — monitoring continu** : intégrer un tableau de bord de suivi de la qualité des annotations dans le pipeline MLOps, avec alertes en cas de dérive du taux de concordance
- **Rappel méthodologique** : un biais d'annotation non corrigé se propage dans le modèle et se renforce à chaque cycle de réentraînement — la fiabilisation des labels est un investissement à fort ROI

Réponse attendue

Le dispositif de monitoring doit couvrir trois axes complémentaires. Le premier axe porte sur la **surveillance des distributions** : comparer en continu les distributions des variables d'entrée (température, vibration, pression, humidité) entre les données d'entraînement et le flux de production, en utilisant des indicateurs comme la distance de Wasserstein ou le test de Kolmogorov-Smirnov, avec un seuil d'alerte déclenché lorsque la p-value passe sous **0,01** ou que la distance dépasse un écart prédéfini. Le deuxième axe concerne la **qualité intrinsèque des données entrantes** : taux de valeurs manquantes par variable et par site, taux d'outliers détectés, et respect des contraintes de format et de plage, avec des alertes temps réel si le taux de manquants dépasse **5 %** sur une fenêtre glissante de 24 heures. Le troisième axe surveille la **performance du modèle** en production : suivi du taux de faux positifs, du recall sur la classe « panne » et du F1-score, avec un seuil de dégradation fixé à une baisse de plus de **3 points** sur une période de deux semaines. En cas d'alerte, le processus prévoit une investigation automatisée (diagnostic de la source de dérive), une notification à l'équipe data, et un protocole de décision : réentraînement ciblé, correction de la collecte, ou rollback vers la version précédente du modèle.

Éléments de solution

- **Axe 1 – Drift de distribution** : implémenter des tests statistiques automatisés (Kolmogorov-Smirnov, Wasserstein, PSI – Population Stability Index) sur chaque variable d'entrée ; comparer les distributions sur des fenêtres glissantes (quotidienne, hebdomadaire) ; seuil d'alerte : $PSI > 0,2$ ou $p\text{-value KS} < 0,01$
- **Axe 2 – Qualité intrinsèque** : monitorer le taux de valeurs manquantes, le taux d'outliers et le respect des contraintes de validité par variable et par site ; seuils recommandés : manquants $> 5 \%$ sur 24h, outliers $> 2 \%$ sur 24h ; intégrer ces contrôles dans le pipeline d'ingestion (validation automatique à la source)
- **Axe 3 – Performance modèle** : suivre le F1-score, le recall « panne » et le taux de faux positifs en production ; seuil de dégradation : baisse $> 3 \text{ points}$ sur 2 semaines ; compléter par un suivi du taux de retours terrain (interventions inutiles signalées par les clients)
- **Processus de réaction** :
 - Niveau 1 (alerte jaune) : investigation automatisée, rapport envoyé à l'équipe data
 - Niveau 2 (alerte orange) : gel des prédictions sur le segment impacté, diagnostic approfondi
 - Niveau 3 (alerte rouge) : rollback vers le modèle précédent, réentraînement sur données corrigées
- **Gouvernance** : documenter chaque alerte et chaque action corrective dans un registre centralisé ; organiser une revue mensuelle des indicateurs de qualité avec les parties prenantes métier et data
- **Rappel** : le monitoring ne remplace pas l'amélioration continue — chaque alerte doit alimenter un cycle d'analyse d'erreurs et de correction du dataset pour les versions suivantes du modèle