




Fondamentaux de l'optimisation des modèles d'IA

Table des matières

I - Contexte	3
II - Typologie des modèles d'IA et enjeux d'optimisation	4
A. Cartographie des modèles d'IA à optimiser	4
B. Contextes d'utilisation et contraintes associées	6
III - Indicateurs de performance et leur interprétation	9
A. Métriques d'évaluation selon les types de modèles	9
B. Interprétation contextuelle des performances	11
IV - Méthodologie d'optimisation systématique	13
A. Cadre d'amélioration continue.....	13
B. Préparation d'une démarche d'optimisation.....	15
V - Synthèse	18
VI - Auto-évaluation	21
VII - Exercice : Optimiser le modèle de recommandation d'une entreprise e-commerce	25
Solutions des exercices	27

I Contexte

Contexte

L'optimisation des modèles d'IA représente aujourd'hui un enjeu stratégique majeur pour les entreprises qui souhaitent tirer parti de l'intelligence artificielle. Dans un environnement concurrentiel où l'efficacité et la pertinence des solutions technologiques peuvent faire la différence entre un projet à forte valeur ajoutée et un investissement sous-optimal, maîtriser les fondamentaux de l'optimisation devient indispensable. Les secteurs comme la finance, le retail, l'industrie ou la santé déploient des modèles qui nécessitent des approches d'optimisation spécifiques, adaptées à leurs contraintes et objectifs particuliers.

Cette leçon nous permettra d'explorer les bases de l'optimisation en nous appuyant sur des cas concrets issus de différents secteurs d'activité. Nous découvrirons que l'optimisation ne consiste pas seulement à améliorer des métriques techniques, mais implique également d'aligner les performances avec les objectifs métier et les contraintes opérationnelles spécifiques à chaque contexte d'utilisation.

II Typologie des modèles d'IA et enjeux d'optimisation

A. Cartographie des modèles d'IA à optimiser

Le paysage des modèles d'IA en entreprise

Dans l'écosystème actuel de l'intelligence artificielle, les entreprises font face à une **diversité croissante de modèles**, chacun présentant des caractéristiques et des défis d'optimisation particuliers. Cette richesse technologique, si elle offre de nombreuses opportunités, complexifie également les choix stratégiques et les approches d'amélioration des performances.

Les modèles d'apprentissage supervisé constituent souvent l'épine dorsale des applications métier. Ces systèmes, entraînés sur des **données étiquetées**, excellent dans des tâches de prédiction où la vérité terrain est connue. L'optimisation de ce type de modèle se concentrera principalement sur l'amélioration de métriques comme la **précision** et le **rappel**, tout en veillant à maintenir un équilibre entre la détection des vrais positifs et la minimisation des fausses alertes qui peuvent nuire à l'expérience utilisateur.

Les modèles **non supervisés** présentent des défis d'optimisation différents. Sans vérité terrain pour guider l'évaluation, l'optimisation repose sur des **métriques internes** et la validation métier. L'optimisation ne peut se baser uniquement sur des métriques techniques comme l'inertie intra-cluster, mais doit intégrer des critères métier : les segments créés sont-ils suffisamment distincts pour justifier des stratégies différenciées ? Leur taille est-elle compatible avec les capacités opérationnelles de l'entreprise ?

Surajustement (overfitting) vs Sous-ajustement (underfitting)

Az Définition

Un modèle est dit en **surajustement (overfitting)** lorsqu'il apprend trop fidèlement les données d'entraînement, ce qui le rend très performant sur ces données mais peu généralisable sur de nouvelles données.

À l'inverse, un modèle en **sous-ajustement (underfitting)** est trop simple pour capturer les relations sous-jacentes dans les données et échoue à atteindre une précision suffisante, même sur l'entraînement.

Ces phénomènes sont centraux dans l'optimisation car ils orientent le choix d'architectures et de techniques de régularisation.

Optimisation sectorielle : cas du secteur bancaire

👁 Exemple

Dans le secteur bancaire, les établissements développent des systèmes de scoring crédit utilisant des **réseaux de neurones**. L'optimisation de ces modèles nécessite de trouver un **équilibre délicat entre précision prédictive et explicabilité réglementaire**. Les équipes doivent adapter leurs métriques d'évaluation pour intégrer non seulement la performance prédictive, mais aussi la capacité du modèle à fournir des explications compréhensibles par les régulateurs financiers. Cette approche permet d'obtenir des réductions substantielles des exigences en fonds propres tout en respectant le cadre réglementaire.

L'impact de l'IA sur la transformation des entreprises françaises

Apprentissage supervisé vs non supervisé

Az Définition

L'apprentissage **supervisé** utilise des **données étiquetées** pour entraîner le modèle, où chaque exemple d'entraînement est associé à sa sortie correcte. Le modèle apprend à établir une correspondance entre les entrées et les sorties attendues.

L'apprentissage **non supervisé**, en revanche, fonctionne avec des **données non étiquetées** et cherche à découvrir des structures cachées, des patterns ou des regroupements naturels dans les données sans connaître la réponse correcte à l'avance.

Caractéristiques spécifiques des modèles selon leur architecture

L'**architecture d'un modèle** détermine largement la stratégie d'optimisation à adopter. Les **arbres de décision** offrent une excellente interprétabilité mais peuvent souffrir de surajustement sur des données complexes. Leur optimisation se concentrera sur des techniques comme l'élagage ou l'ensemble de modèles pour améliorer la généralisation.

Les **réseaux de neurones profonds** présentent des défis d'optimisation plus complexes. Leur capacité d'apprentissage élevée s'accompagne de risques de surajustement et de difficultés d'interprétation. L'optimisation de ces modèles nécessite des approches sophistiquées combinant régularisation, ajustement d'hyperparamètres et techniques de transfert d'apprentissage.

Surajustement dans les arbres de décision

👁 Exemple

Un arbre de décision appliqué à la détection de churn client peut sembler très performant, etc. mais s'il se base sur des règles trop précises (âges exacts, dates de dernière connexion, etc.), il risque d'être incapable de généraliser sur de nouveaux clients. L'élagage (pruning) permet de limiter cela, en supprimant les branches trop spécifiques qui apportent peu de valeur en prédiction réelle.

Les modèles d'**apprentissage par renforcement** représentent une catégorie particulière où l'agent apprend par interaction avec un environnement via un système de récompenses et de pénalités. Ces modèles découvrent par eux-mêmes les stratégies optimales pour maximiser leurs gains cumulés, ce qui les rend particulièrement adaptés aux environnements complexes et dynamiques.


Les attentes business et leur traduction technique

La réussite d'un projet d'optimisation repose sur la capacité à **traduire les objectifs métier en exigences techniques mesurables**. Cette traduction constitue souvent le premier défi à relever, car elle nécessite une collaboration étroite entre les équipes techniques et les parties prenantes business.

Dans le secteur retail, un système de prévision de ventes traduit l'objectif métier « **améliorer la gestion des stocks** » en plusieurs exigences techniques : réduire l'erreur absolue moyenne des prévisions de 15 %, améliorer la précision sur les produits à forte rotation, ou encore optimiser les prédictions sur les périodes de forte saisonnalité. Chacune de ces exigences orientera différemment la stratégie d'optimisation.

Dans le secteur bancaire, un système de détection de fraude devra répondre à des attentes apparemment contradictoires : **maximiser la détection des fraudes tout en minimisant les faux positifs** qui dégradent l'expérience client. Cette tension se traduit techniquement par l'optimisation d'un compromis entre précision et rappel, avec des seuils de décision ajustés selon le profil de risque de chaque segment de clientèle.

Impliquer les parties prenantes métier dans l'optimisation



Lors de la définition des métriques techniques à optimiser, associez toujours **au moins un référent métier**. Cela assure que l'amélioration technique (par ex. +3 % de précision) se traduira bien en **gains mesurables côté business** (diminution des fraudes, meilleures prévisions de ventes, meilleure satisfaction client).

B. Contextes d'utilisation et contraintes associées

Les contraintes environnementales des modèles d'IA

L'**environnement d'exécution** d'un modèle d'IA influence fondamentalement sa stratégie d'optimisation. Un même algorithme peut nécessiter des approches d'amélioration radicalement différentes selon qu'il opère en temps réel sur des appareils mobiles, en traitement par lots sur des serveurs cloud, ou en edge computing sur des dispositifs embarqués.

Les contraintes d'infrastructure déterminent largement les axes d'optimisation prioritaires. Dans un contexte de **traitement temps réel**, comme la détection de fraude bancaire, **la latence devient un facteur critique**. Un modèle doit être capable de traiter des milliers de transactions par seconde avec un temps de réponse inférieur à 100 millisecondes. Cette contrainte oriente l'optimisation vers des architectures légères et des techniques de quantification pour réduire la complexité computationnelle.

À l'inverse, un modèle d'analyse comportementale fonctionnant en traitement par lots peut se permettre une complexité algorithmique supérieure. L'optimisation se concentrera alors sur la précision prédictive et la capacité à exploiter l'ensemble des données disponibles, la contrainte temporelle étant moins critique.

Latence vs Temps de calcul global



La **latence** désigne le **temps de réponse unitaire** d'un modèle pour fournir une prédiction (par ex. réponse en millisecondes pour une transaction).

Le **temps de calcul global** correspond à la durée totale pour traiter un ensemble volumineux de données (batch).

Ces deux notions guident des choix d'optimisation très différents selon l'environnement (temps réel vs batch processing).

AI Act et RGPD : complémentarité réglementaire



L'**AI Act** est la première réglementation européenne spécifiquement conçue pour encadrer l'intelligence artificielle, classant les systèmes selon leur niveau de risque.

Le **RGPD** (Règlement Général sur la Protection des Données) impose une gouvernance stricte des données personnelles utilisées par les modèles IA.

Ces deux cadres réglementaires se complètent : l'AI Act aborde les risques sociétaux de l'IA tandis que le RGPD protège les données individuelles, créant ensemble un environnement propice à une IA éthique et responsable.

Équilibre performance-ressources dans différents contextes

L'optimisation d'un modèle d'IA implique invariablement des **compromis entre performance, rapidité et consommation de ressources**.

Dans le secteur médical, un système de diagnostic par imagerie privilégiera la **précision diagnostique**, même si cela nécessite des temps de calcul plus importants. La vie humaine étant en jeu, l'optimisation se concentrera sur la minimisation des faux négatifs, quitte à accepter quelques faux positifs supplémentaires qui seront filtrés par l'expertise médicale.

Dans l'industrie automobile, les systèmes d'aide à la conduite doivent traiter l'information en temps réel dans un environnement aux ressources limitées. L'optimisation privilégiera des **architectures efficaces** capables de fonctionner sur des puces embarquées, avec des techniques de compression de modèles et d'optimisation des opérations pour respecter les contraintes énergétiques et de latence.

IA embarquée dans les drones industriels

👁 Exemple

Dans les drones de surveillance, un modèle de vision doit prendre des décisions rapides tout en étant contraint par une **capacité énergétique limitée**. L'optimisation se concentre donc sur la **compression et la quantification du modèle**, pour maintenir la robustesse tout en garantissant des heures d'autonomie supplémentaire.

Adaptation aux contraintes sectorielles

👁 Exemple

Dans le secteur retail, **Amazon** utilise des modèles de recommandation qui génèrent environ **35 % de son chiffre d'affaires total**. Ces systèmes doivent s'adapter à des pics de trafic considérables, notamment pendant les périodes de soldes. L'optimisation de ces systèmes privilégie la scalabilité et la robustesse, avec des architectures distribuées capables de maintenir leurs performances malgré une charge variable.

En finance, les **modèles de trading algorithmique** représentent aujourd'hui **60 à 70 % du volume des transactions** sur les principaux marchés mondiaux. Ces systèmes opèrent dans un environnement où la vitesse d'exécution se mesure en microsecondes. L'optimisation se concentre sur la minimisation de la latence, quitte à simplifier certains aspects du modèle pour gagner en réactivité.

Méthodologie de priorisation des axes d'optimisation

Face à des ressources limitées, il devient crucial de **hiérarchiser les efforts d'optimisation**. Une **matrice de priorisation** permet d'identifier les axes d'amélioration à plus forte valeur ajoutée en croisant l'impact business potentiel avec la complexité de mise en œuvre.

Pour un modèle de recommandation e-commerce, l'amélioration de la personnalisation pourrait avoir un impact élevé sur le chiffre d'affaires mais nécessiter des développements complexes. À l'inverse, l'optimisation des temps de réponse pourrait apporter une amélioration immédiate de l'expérience utilisateur avec un effort technique modéré. Cette analyse guide la **planification des itérations d'optimisation** et permet d'allouer efficacement les ressources techniques disponibles.

Matrice d'impact business vs coût technique

Remarque

Représenter les projets d'optimisation dans une **matrice à 2 axes** (impact business vs effort technique) permet de décider rapidement quelles actions mettre en priorité dans un contexte de ressources limitées).

Éviter le piège de l'optimisation technique isolée

Attention

Il est tentant de se concentrer exclusivement sur l'amélioration des métriques techniques d'un modèle. Cependant, cette approche peut conduire à des **optimisations déconnectées de la réalité opérationnelle**. Un modèle techniquement performant mais impossible à déployer en production, ou dont les prédictions ne sont pas exploitables par les équipes métier, représente un échec d'optimisation malgré d'excellentes performances sur les données de test. L'optimisation doit toujours être pensée dans une perspective **d'usage final et d'intégration** dans l'écosystème existant de l'entreprise.

III Indicateurs de performance et leur interprétation

A. Métriques d'évaluation selon les types de modèles

Taxonomie des métriques de performance

L'évaluation d'un modèle d'IA nécessite une approche méthodique dans le choix des métriques, chaque famille de modèles présentant des caractéristiques spécifiques qui orientent la sélection des indicateurs pertinents. Cette taxonomie permet d'établir un cadre structuré pour adapter les mesures de performance au **type de tâche** à accomplir.

Pour les **modèles de classification supervisée**, les métriques se concentrent sur la capacité à distinguer correctement les différentes classes. Les métriques fondamentales incluent l'**exactitude globale**, qui mesure le pourcentage de prédictions correctes, mais également des indicateurs plus nuancés comme la **précision** et le **rappel** qui permettent d'analyser finement les performances sur chaque classe.

Les **modèles de régression**, quant à eux, nécessitent des métriques qui quantifient l'écart entre les valeurs prédites et réelles. L'**erreur absolue moyenne (MAE)** fournit une mesure directe et intuitive de l'erreur moyenne, tandis que l'**erreur quadratique moyenne (RMSE)** pénalise davantage les grandes erreurs, ce qui peut être crucial dans certains contextes métier.


Précision, rappel et F1-Score

Az Définition

La **précision** mesure la proportion de prédictions positives qui sont réellement correctes, répondant à la question : « Parmi tous les éléments que le modèle a prédits comme positifs, combien étaient réellement positifs ? ».

Le **rappel** évalue la capacité du modèle à identifier toutes les instances positives, répondant à : « Parmi tous les éléments positifs réels, combien le modèle a-t-il correctement identifiés ? ».

Le **F1-Score** constitue la moyenne harmonique de la précision et du rappel, offrant une métrique équilibrée particulièrement utile lors de **classes déséquilibrées**.



Analyse avancée des métriques de classification

L'interprétation des métriques de classification dépend fortement du **contexte d'application** et des **coûts associés** aux différents types d'erreur. Dans un système de détection de fraude bancaire, privilégier un **rappel élevé** permet de capturer le maximum de fraudes, même au prix de quelques fausses alertes qui peuvent être filtrées par analyse humaine. À l'inverse, un système de recommandation de produits pourrait favoriser la **précision** pour éviter de proposer des articles non pertinents qui détériorent l'expérience utilisateur.

La **courbe ROC** (Receiver Operating Characteristic) et son aire sous la courbe (**AUC**) offrent une vision globale des performances du modèle à travers tous les seuils de décision possibles. Une AUC proche de 1 indique une **excellente capacité discriminative**, tandis qu'une valeur de 0,5 correspond à une performance aléatoire. Cette métrique présente l'avantage d'être insensible au déséquilibre des classes, la rendant particulièrement précieuse pour évaluer des modèles sur des jeux de données réels souvent déséquilibrés.

Application sectorielle des métriques

[👁 Exemple](#)

Dans le secteur médical, un système de diagnostic par imagerie privilégiera un **rappel maximal** pour minimiser les faux négatifs, même si cela génère quelques faux positifs qui seront revus par un spécialiste. Cette approche reflète le principe médical selon lequel il vaut mieux sur-diagnostiquer que passer à côté d'une pathologie grave.

Dans l'e-commerce, les systèmes de détection de fraude de **PayPal** utilisent des **métriques équilibrées** où la **précision est cruciale** pour éviter de bloquer des transactions légitimes, ce qui dégraderait l'expérience client, tout en maintenant un rappel suffisant pour capturer les vraies fraudes.

Métriques spécifiques aux modèles non supervisés et génératifs

Az Définition

L'évaluation des modèles non supervisés présente des défis particuliers en raison de l'absence de vérité terrain. Pour les algorithmes de **clustering**, l'**indice de silhouette** mesure la cohésion interne des clusters et leur séparation, avec des valeurs proches de 1 indiquant des groupes bien formés et distincts. L'**inertie intra-classe** quantifie la compacité des clusters, mais doit être interprétée en relation avec le nombre de groupes formés.

Les modèles **génératifs** nécessitent des métriques spécialisées qui évaluent la qualité et la diversité des contenus produits. La **perplexité** mesure la capacité d'un modèle de langage à prédire une séquence de mots, avec des valeurs faibles indiquant une meilleure performance prédictive. Pour la génération d'images, la **distance de Fréchet (FID)** compare la distribution des images générées à celle des images réelles, permettant d'évaluer à la fois la qualité et la diversité de la production.

B. Interprétation contextuelle des performances

Au-delà des chiffres : l'interprétation business des métriques

La **transformation des métriques techniques en valeur business** constitue l'étape cruciale qui détermine le succès d'un projet d'optimisation. Cette traduction nécessite une compréhension fine des processus métier et de l'impact économique des améliorations apportées par le modèle.

Dans le secteur retail, **une amélioration de 5 % de la précision** d'un modèle de prévision des ventes peut se traduire par une **réduction significative des ruptures de stock** et une optimisation des inventaires. Cette amélioration technique génère alors des bénéfices mesurables : diminution des coûts de stockage, réduction des pertes liées aux invendus, et augmentation de la satisfaction client grâce à une meilleure disponibilité des produits.

Pour un modèle de détection de fraude, l'évaluation du **ROI** doit intégrer non seulement les fraudes évitées, mais également les **coûts associés aux fausses alertes**, temps d'investigation des équipes, risque de blocage de transactions légitimes, et impact sur l'expérience client. Une amélioration apparemment modeste du **F1-Score** peut ainsi générer des **économies substantielles** en optimisant ce compromis délicat.

Construire un tableau de bord mixte (technique + business)

 Conseil

Ayez toujours un tableau de bord qui présente **côte à côte** des métriques techniques (F1, latence, MAE) et leur traducteur en termes business (réduction des pertes, transactions validées, satisfaction client).

Cela permet aux décideurs non techniques de suivre les progrès sans perdre en compréhension.

Quantification de l'impact business



Pour quantifier efficacement l'impact business d'une amélioration de modèle, développez une **méthodologie de traçabilité** qui relie chaque **métrique technique à un indicateur économique mesurable**. Établissez des relations causales claires entre performance du modèle et résultats business, en documentant les hypothèses et en validant les corrélations observées.

Créez des **tableaux de bord** qui affichent simultanément les métriques techniques et leurs équivalents business, permettant aux parties prenantes de comprendre immédiatement l'impact de chaque optimisation. Cette approche facilite la communication avec les décideurs et justifie les investissements futurs en optimisation.

Analyse comparative et benchmarking

Le **positionnement des performances d'un modèle dans son écosystème concurrentiel** et technologique constitue un élément essentiel pour évaluer sa maturité et identifier les axes d'amélioration prioritaires. Cette démarche comparative s'appuie sur plusieurs référentiels complémentaires.

L'analyse de la littérature académique récente, via des plateformes comme **Papers With Code**, permet de situer les performances du modèle par rapport à **l'état de l'art actuel**. Cette comparaison révèle les marges d'amélioration théoriques disponibles et identifie les techniques émergentes susceptibles d'apporter des gains significatifs.

Les **benchmarks sectoriels** offrent une perspective plus pragmatique en comparant les performances avec les **standards industriels établis**. Ces références tiennent compte des contraintes opérationnelles réelles et permettent d'évaluer la compétitivité du modèle dans son marché spécifique.

Définition d'objectifs d'optimisation réalistes

L'**établissement d'objectifs d'amélioration pertinents et atteignables** nécessite un équilibre délicat entre **ambition et réalisme**, en tenant compte des contraintes techniques, des ressources disponibles et des attentes business. Cette démarche collaborative implique l'ensemble des parties prenantes dans la définition d'une feuille de route d'optimisation cohérente.

L'**analyse des performances actuelles** constitue le point de départ pour identifier les marges d'amélioration disponibles. Cette évaluation doit considérer non seulement les métriques globales, mais également les performances sur différents segments de données pour identifier les zones de faiblesse spécifiques.

La consultation de **l'état de l'art** permet de **calibrer les attentes** en fonction des limites théoriques et pratiques connues. Certaines tâches présentent des plafonds de performance intrinsèques liés à la nature des données ou à la complexité du problème, qu'il convient d'intégrer dans la planification des objectifs.

Éviter les objectifs d'optimisation irréalistes



Fixer des **objectifs d'amélioration trop ambitieux** peut conduire à des échecs coûteux et démotivants pour les équipes. Il est essentiel d'**évaluer la faisabilité technique** des améliorations envisagées en consultant l'état de l'art et en tenant compte des contraintes spécifiques du projet.

De même, des **objectifs trop modestes** risquent de sous-exploiter le potentiel d'amélioration disponible et de limiter l'impact business du projet. L'approche optimale consiste à **définir des objectifs étapés**, avec des **jalons intermédiaires** qui permettent d'ajuster progressivement les ambitions en fonction des résultats obtenus.

IV Méthodologie d'optimisation systématique

A. Cadre d'amélioration continue

Le cycle d'amélioration continue pour les modèles d'IA

L'optimisation des modèles d'IA nécessite une approche **structurée** et **méthodique** qui s'inspire des meilleures pratiques de l'amélioration continue industrielle. Le framework **DMAIC (Define, Measure, Analyze, Improve, Control)**, issu de la méthodologie Six Sigma, s'adapte parfaitement au contexte des projets d'intelligence artificielle en fournissant une démarche **rigoureuse** et **reproductible**.

La phase « **Define** » (**Définir**) consiste à délimiter précisément le périmètre d'optimisation en identifiant les problèmes de performance, les **objectifs d'amélioration** et les contraintes spécifiques au modèle. Cette étape cruciale permet d'aligner les parties prenantes sur des **objectifs communs et mesurables**, évitant ainsi les efforts dispersés ou les optimisations déconnectées des besoins métier.

La phase « **Measure** » (**Mesurer**) établit un état des lieux quantitatif des performances actuelles du modèle. Elle comprend la collecte systématique des métriques de référence, l'analyse des patterns de performance sur différents segments de données, et la caractérisation des conditions d'usage réelles. Cette mesure initiale constitue la **baseline indispensable** pour évaluer l'efficacité des améliorations futures.

L'étape « **Analyze** » (**Analyser**) identifie les **causes racines** des limitations de performance observées. Elle mobilise des techniques d'analyse statistique, de profilage des données, et d'évaluation architecturale pour comprendre les facteurs limitants. Cette analyse peut révéler des problèmes de qualité des données, des inadéquations architecturales, ou des configurations sous-optimales.

L'étape « **Improve** » (**Améliorer**) consiste à concevoir, tester et mettre en œuvre des **solutions concrètes** pour lever les principaux freins identifiés lors de l'analyse. Cela peut prendre la forme d'un nouveau prétraitement des données, d'une optimisation des hyperparamètres, d'une restructuration de l'architecture du modèle ou de l'intégration de nouvelles fonctionnalités métiers. Chaque solution mise en œuvre doit être soigneusement testée dans l'environnement de validation pour **mesurer précisément son impact sur les métriques cibles** établies lors des phases précédentes. Il est essentiel de procéder par **incréments** pour isoler l'effet de chaque amélioration et ainsi construire un historique d'expérimentation fiable et exploitable pour les itérations suivantes.

L'étape « **Control** » (**Contrôler**) clôt le cycle en instaurant un **suivi structuré des performances** du modèle sur le long terme. Cette surveillance continue permet de détecter rapidement toute dégradation (concept drift, déphasage entre les données d'entraînement et les données réelles, nouveaux biais, etc.). Pour cela, on met en place des outils de monitoring automatisés, des alertes sur les dérives des indicateurs clés, et des procédures de réévaluation périodique. Cette étape vise à garantir que les **optimisations produisent des bénéfices durables** et à déclencher proactivement de nouveaux cycles d'amélioration dès que les performances réelles s'écartent des niveaux attendus.

Ainsi, la démarche **DMAIC adaptée à l'IA** s'inscrit dans une logique itérative : chaque boucle d'amélioration aboutit à un modèle plus performant, mieux aligné avec son contexte d'utilisation, et dont la qualité est maintenue grâce à une vigilance opérationnelle permanente.



Planification des itérations d'optimisation

L'intégration des cycles d'optimisation dans une **méthodologie agile** nécessite une planification minutieuse qui équilibre ambition et réalisme. Chaque sprint d'optimisation doit définir des objectifs d'amélioration incrémentaux et mesurables, permettant une évaluation rapide des résultats et une adaptation continue de la stratégie.

La planification commence par la **priorisation des axes d'amélioration** selon leur impact potentiel et leur complexité de mise en œuvre. Cette priorisation s'appuie sur une matrice de décision qui croise valeur business, faisabilité technique et coût de développement. Les améliorations à **forte valeur et faible complexité** sont naturellement privilégiées pour les premières itérations.

Chaque itération suit un cycle complet de **développement, test et validation**, permettant d'accumuler progressivement les **gains de performance** tout en maintenant la **stabilité du système**. Cette approche itérative facilite également l'apprentissage organisationnel et le développement des compétences d'optimisation au sein des équipes.


Documentation et traçabilité du processus d'optimisation

La **documentation rigoureuse** du processus d'optimisation constitue un pilier fondamental pour la **reproductibilité**, l'**audit** et l'**amélioration continue** des pratiques. Cette documentation dépasse la simple consignation des résultats pour capturer l'ensemble du processus décisionnel et méthodologique.

Le **système de versioning** doit couvrir non seulement le code et les modèles, mais également les jeux de données, les configurations d'**hyperparamètres**, et les **environnements d'exécution**. Cette traçabilité complète permet de reproduire fidèlement n'importe quelle version du modèle et de comprendre l'évolution des performances à travers les différentes itérations.

La documentation doit également inclure les rationnels des choix techniques, les résultats des expérimentations abandonnées, et les leçons apprises. Cette capitalisation de l'expérience évite la répétition d'**erreurs** et accélère les futurs **cycles d'optimisation** en s'appuyant sur l'historique des succès et échecs.

Mise en place d'un système de versioning efficace



Pour assurer une **traçabilité complète** de vos optimisations, implémentez un système de versioning qui va au-delà du simple code source. Utilisez des outils comme **MLFlow** ou **Weights & Biases** pour tracker simultanément les versions de modèles, les **hyperparamètres**, les **métriques de performance** et les **environnements d'exécution**.

Établissez des conventions de nommage claires qui permettent d'identifier rapidement le contexte et l'objectif de chaque version. Documentez systématiquement les changements apportés, leurs motivations et leurs impacts observés. Cette **discipline documentaire**, bien qu'exigeante initialement, se révèle rapidement indispensable pour comprendre l'évolution des performances et capitaliser sur les apprentissages.

B. Préparation d'une démarche d'optimisation

Audit initial et établissement de la baseline

L'**audit initial** constitue la phase fondatrice de toute démarche d'**optimisation systématique**. Cette analyse approfondie va bien au-delà de la simple mesure des performances globales pour caractériser finement le comportement du modèle dans ses conditions d'usage réelles.

L'audit commence par l'**évaluation exhaustive des performances actuelles** sur l'ensemble des **métriques pertinentes : précision, rappel, temps de réponse, consommation de ressources, et robustesse** face aux variations de données. Cette évaluation doit être segmentée selon différentes dimensions : types de données, périodes temporelles, charges de travail, pour identifier les zones de force et de faiblesse du modèle.

L'analyse doit également porter sur la **qualité** et la **représentativité des données** d'entraînement et de test. Un profilage détaillé révèle les déséquilibres, les biais potentiels, et les lacunes qui peuvent expliquer certaines limitations de performance. Cette compréhension fine des **données guide les stratégies d'amélioration** et permet d'anticiper les **défis de généralisation**.

L'**audit architectural** examine l'adéquation entre la **complexité du modèle** et la complexité du problème à résoudre. Un modèle trop simple peut sous-ajuster le problème, tandis qu'un modèle trop complexe risque le surajustement. Cette analyse guide les décisions d'optimisation architecturale.

Audit initial d'un chatbot d'assistance



Lors de l'audit d'un chatbot, on évalue non seulement la **précision des réponses** mais aussi la **latence des temps de réponse**, le **taux d'abandon utilisateur** et le **taux d'escalade vers des conseillers humains**. Ces métriques complémentaires aident à identifier si le problème vient du modèle, de l'infrastructure ou du design conversationnel.

Construction d'un environnement de test reproductible

La création d'un **environnement de test reproductible** représente un investissement initial crucial qui conditionne la fiabilité de toute la démarche d'optimisation. Cet environnement doit garantir que les améliorations mesurées reflètent réellement les gains de performance et non des variations liées aux conditions d'expérimentation.

La reproductibilité s'appuie sur la **standardisation complète de l'environnement d'exécution** : versions des bibliothèques, paramètres système, initialisation des générateurs aléatoires, et conditions de charge. L'utilisation de conteneurs Docker ou d'environnements virtuels dédiés facilite cette standardisation et assure la portabilité entre les environnements de développement et de production.

Les **jeux de données de test** doivent être soigneusement constitués pour être représentatifs des conditions réelles d'usage tout en restant **stables dans le temps**. Ces datasets de référence permettent des comparaisons objectives entre les différentes versions du modèle et facilitent l'identification des régressions potentielles.

Le **pipeline de test automatisé** doit couvrir l'ensemble des aspects critiques : **performance prédictive, temps de réponse, consommation mémoire, et comportement face à des cas limites**. Cette automatisation accélère les cycles d'expérimentation et réduit les risques d'erreur humaine dans l'évaluation des améliorations.

Environnement de test chez Netflix

[👁 Exemple](#)

Netflix utilise un **environnement de test hautement automatisé** pour optimiser ses **algorithmes de recommandation**. La plateforme maintient des datasets de référence figés représentant différents profils d'utilisateurs et contextes d'usage. Chaque modification algorithmique est systématiquement évaluée sur ces **benchmarks** avant déploiement, permettant de **mesurer précisément l'impact des optimisations sur l'engagement utilisateur**. Cette approche rigoureuse a permis d'améliorer de 10% l'efficacité des recommandations sur les trois dernières années.

Élaboration d'une feuille de route d'optimisation

La construction d'une **feuille de route d'optimisation** nécessite une vision **stratégique** qui intègre les **contraintes techniques**, les **priorités business** et les **ressources disponibles**. Cette planification structurée évite les approches opportunistes et maximise l'impact des efforts d'amélioration.

La feuille de route débute par une **analyse de maturité** qui évalue le niveau actuel du modèle et identifie les étapes nécessaires pour atteindre les objectifs cibles. Cette analyse considère non seulement les performances techniques, mais également les aspects opérationnels comme le monitoring, la maintenance et l'explicabilité.

La priorisation des initiatives s'appuie sur une **matrice de décision multicritères** qui évalue chaque amélioration potentielle selon son impact business, sa faisabilité technique, son coût de mise en œuvre et ses prérequis. Cette approche systématique assure que les ressources limitées sont allouées aux initiatives les plus prometteuses.

La roadmap intègre également les dépendances entre les différentes pistes d'amélioration. Certaines optimisations nécessitent des prérequis techniques ou méthodologiques qui doivent être traités en priorité. La planification tient compte de ces contraintes pour définir un séquençement optimal des initiatives.

Éviter la sur-planification

⚠ Attention

Une **feuille de route trop rigide** peut devenir contre-productive dans un contexte d'optimisation de modèles d'IA où l'apprentissage et l'adaptation sont constants. Gardez une certaine **flexibilité** pour intégrer les découvertes inattendues et ajuster les priorités en fonction des résultats obtenus.

Privilégiez une planification adaptative qui définit clairement les premières étapes tout en conservant de la souplesse pour les phases ultérieures. Cette approche permet de capitaliser sur les apprentissages de chaque itération pour affiner la stratégie d'optimisation.

V Synthèse

A. Flashcards

Apprentissage supervisé

Modèle entraîné sur données étiquetées pour prédire sorties correctes.

Apprentissage non supervisé

Modèle découvrant structures cachées dans données non étiquetées.

Surajustement (overfitting)

Modèle trop fidèle aux données d'entraînement, peu généralisable.

Sous-ajustement (underfitting)

Modèle trop simple, incapable de capturer relations sous-jacentes.

Précision

Proportion de prédictions positives réellement correctes.

Rappel

Capacité à identifier toutes les instances positives réelles.

F1-Score

Moyenne harmonique de précision et rappel, utile si classes déséquilibrées.

AUC-ROC

Aire sous courbe ROC, mesure capacité discriminative globale.

MAE

Erreur absolue moyenne, mesure directe écart entre prédictions et réalité.

RMSE

Erreur quadratique moyenne, pénalise davantage les grandes erreurs.

Indice de silhouette

Mesure cohésion interne et séparation des clusters.

DMAIC

Cycle amélioration continue : Define, Measure, Analyze, Improve, Control.

Baseline

État initial de référence pour mesurer gains d'optimisation.

Latence

Temps de réponse unitaire pour fournir une prédiction.

AI Act


Réglementation européenne encadrant IA selon niveau de risque.

La théorie en Bref

🔗 Fondamental

Les **modèles d'IA** se répartissent en grandes familles (supervisé, non supervisé, par renforcement) dont les **enjeux d'optimisation** diffèrent profondément. L'**optimisation** consiste à aligner les performances techniques avec les **objectifs métier** et les **contraintes opérationnelles** propres à chaque secteur. Les **métriques d'évaluation** (précision, rappel, F1-


Score, AUC, MAE, RMSE, silhouette, FID) doivent être choisies selon le type de modèle et interprétées dans leur contexte business pour mesurer la valeur réelle des améliorations. Une **démarche systématique** inspirée du cycle **DMAIC** (Define, Measure, Analyze, Improve, Control) garantit la reproductibilité, la traçabilité et la pérennité des gains de performance. L'optimisation réussie repose sur un **équilibre** entre ambition technique, contraintes réglementaires, attentes business et impact opérationnel, tout en intégrant les dimensions éthiques et de responsabilité sociale.



1. Modèles entraînés sur données étiquetées, optimisation centrée sur précision et rappel.
2. Sans vérité terrain, optimisation via métriques internes et validation métier.
3. Agent apprenant par récompenses, optimisation des stratégies de maximisation.
4. Arbres de décision, réseaux de neurones, modèles génératifs.
5. Précision, rappel, F1-Score, AUC-ROC.
6. MAE, RMSE, erreur quadratique moyenne.
7. Indice de silhouette, inertie intra-classe.
8. Perplexité, distance de Fréchet (FID).
9. Define, Measure, Analyze, Improve, Control.
10. Établissement de la baseline, profilage des données.
11. Reproductibilité, standardisation, automatisation.
12. Priorisation, planification adaptative, traçabilité.
13. Temps réel, batch, edge computing.
14. Performance vs ressources, précision vs latence.
15. AI Act, RGPD, explicabilité, éthique.
16. ROI, impact économique, valeur métier.

Optimisation des modèles d'IA

Les conseils pro



Comment traduire les objectifs métier en exigences techniques mesurables ?

- Impliquer au moins un référent métier dès la définition des métriques.
- Relier chaque métrique technique à un indicateur économique ou opérationnel concret.
- Documenter les hypothèses et valider les corrélations entre performance et résultats business.
- Créer un tableau de bord mixte affichant métriques techniques et équivalents business.

Comment prioriser les axes d'optimisation dans un contexte de ressources limitées ?

- Construire une matrice impact business versus effort technique.
- Privilégier les améliorations à forte valeur et faible complexité pour les premières itérations.
- Identifier les dépendances entre initiatives pour séquencer les actions.
- Garder une flexibilité pour ajuster les priorités selon les résultats obtenus.

Comment garantir la reproductibilité des expérimentations d'optimisation ?

- Standardiser l'environnement d'exécution via conteneurs ou environnements virtuels dédiés.
- Versionner simultanément code, modèles, hyperparamètres, datasets et environnements.
- Fixer les générateurs aléatoires et documenter toutes les conditions d'expérimentation.
- Automatiser les pipelines de test pour couvrir performance, latence et cas limites.

Comment choisir les métriques d'évaluation adaptées au contexte métier ?

- Analyser les coûts associés aux différents types d'erreur dans le contexte d'usage.
- Privilégier le rappel si les faux négatifs sont critiques, la précision si les faux positifs dégradent l'expérience.
- Utiliser des métriques équilibrées comme F1-Score en cas de classes déséquilibrées.
- Compléter les métriques techniques par des indicateurs de satisfaction utilisateur ou d'impact économique.

Comment structurer un audit initial de modèle d'IA efficace ?

- Évaluer les performances sur toutes les métriques pertinentes et segmenter par type de données.
- Profiler les données d'entraînement pour identifier déséquilibres, biais et lacunes.
- Analyser l'adéquation entre complexité du modèle et complexité du problème.
- Documenter les conditions d'usage réelles et les contraintes opérationnelles observées.

VI Auto-évaluation

Exercice 1 : Typologies et architectures des modèles IA

[solution n°1 p. 27]

Exercice

Un modèle d'apprentissage supervisé peut être entraîné et évalué sans avoir recours à des données étiquetées, à condition de disposer de métriques internes suffisamment robustes.

Vrai

Faux

Exercice

Vous travaillez sur un modèle de segmentation client non supervisé. Votre responsable vous demande d'évaluer si les segments obtenus sont pertinents. Quelle approche est la plus adaptée à ce contexte ?

Calculer l'exactitude globale du modèle en comparant les segments prédits à une vérité terrain.

Combiner des métriques internes comme l'indice de silhouette avec une validation métier sur la pertinence opérationnelle des segments.

Se concentrer uniquement sur la minimisation de l'inertie intra-cluster, qui garantit la qualité des groupes formés.

Utiliser la courbe ROC et l'AUC pour mesurer la capacité discriminative du modèle de segmentation.

Exercice

Parmi les propositions suivantes, lesquelles décrivent correctement les défis spécifiques d'optimisation des réseaux de neurones profonds par rapport aux arbres de décision ?

A

☐

Les réseaux de neurones profonds présentent un risque de surajustement plus élevé en raison de leur grande capacité d'apprentissage.

B

☐

Les réseaux de neurones profonds sont naturellement plus interprétables, ce qui simplifie leur optimisation réglementaire.

C

☐

L'optimisation des réseaux de neurones nécessite des approches combinant régularisation, ajustement d'hyperparamètres et transfert d'apprentissage.

D☐

Les arbres de décision peuvent souffrir de surajustement sur des données complexes, contrairement aux réseaux de neurones qui y sont naturellement résistants.

E☐

Les difficultés d'interprétation des réseaux de neurones profonds constituent un défi d'optimisation spécifique à cette architecture.

Exercice

Remettez dans le bon ordre les cinq phases du framework DMAIC appliqué à l'optimisation d'un modèle d'IA, de la première à la dernière étape.

A Mesurer les performances actuelles du modèle et établir une baseline quantitative.

B Contrôler les performances sur le long terme et détecter toute dégradation via un monitoring continu.

C Définir le périmètre d'optimisation, les objectifs d'amélioration et les contraintes spécifiques au modèle.

D Analyser les causes racines des limitations de performance identifiées.

E Concevoir, tester et mettre en œuvre des solutions concrètes pour lever les freins identifiés.

Réponse : ____ ____ ____ ____ ____

Exercice 6 : Métriques de performance et interprétation

[solution n°2 p. 29]

Exercice

La courbe ROC et son aire sous la courbe (AUC) sont particulièrement adaptées à l'évaluation de modèles sur des jeux de données déséquilibrés, car elles sont insensibles au déséquilibre des classes.

Vrai

Faux

Exercice

Un système de diagnostic par imagerie médicale doit détecter des tumeurs malignes. Quelle stratégie d'optimisation des métriques est la plus cohérente avec les enjeux de ce contexte ?

Maximiser la précision pour éviter d'alarmer inutilement les patients avec de faux positifs.

Maximiser le rappel pour minimiser les faux négatifs, quitte à générer quelques faux positifs filtrés par un spécialiste.

Optimiser l'exactitude globale, qui offre la vision la plus complète des performances du modèle.

Équilibrer précision et rappel via le F1-Score, car aucun des deux ne doit être privilégié en médecine.

Exercice

Associez chaque métrique d'évaluation au type de modèle ou contexte pour lequel elle est principalement utilisée.

A RMSE (erreur quadratique moyenne)	B Perplexité	C F1-Score	D Indice de silhouette
Modèle de clustering non supervisé	Modèle de régression supervisée	Modèle de classification avec classes déséquilibrées	Modèle de langage génératif

Exercice

Vous présentez les résultats d'optimisation d'un modèle de détection de fraude à votre direction. Parmi les éléments suivants, lesquels doivent figurer dans votre tableau de bord pour assurer une communication efficace avec les décideurs non techniques ?

- ☐ A Le F1-Score du modèle avant et après optimisation.
- ☐ B La réduction estimée des pertes financières liées aux fraudes non détectées.
- ☐ C La matrice de confusion complète avec tous les seuils de décision testés.
- ☐ D L'impact sur l'expérience client lié à la variation du nombre de faux positifs.
- ☐ E Le détail des hyperparamètres utilisés lors de la phase d'entraînement.

Exercice

Lors de la définition des objectifs d'optimisation d'un modèle, votre équipe hésite entre viser une amélioration de 2 % du F1-Score ou de 25 % en six semaines. Quelle approche est recommandée selon la méthodologie présentée dans la leçon ?

Viser l'objectif le plus ambitieux (25 %) pour maximiser l'impact business et motiver les équipes.

Choisir l'objectif le plus conservateur (2 %) pour garantir le succès et éviter tout risque d'échec.

Définir des objectifs étapés avec des jalons intermédiaires, calibrés par l'état de l'art et les contraintes du projet.

Laisser les équipes techniques fixer librement leurs objectifs, car elles seules peuvent évaluer la faisabilité.

Exercice 12 : Contraintes contextuelles et priorisation

[solution n°3 p. 31]

Exercice

Associez chaque contexte d'utilisation à l'axe d'optimisation prioritaire qui lui correspond.

A Scoring crédit avec contrainte réglementaire

B Système de vision embarqué sur drone industriel

C Analyse comportementale en traitement par lots

D Détection de fraude bancaire en temps réel

Minimisation de la latence (réponse < 100 ms)	Maximisation de la précision prédictive	Compression et quantification du modèle	Équilibre entre performance prédictive et explicabilité

Exercice

Vous réalisez l'audit initial d'un chatbot d'assistance client. Parmi les éléments suivants, lesquels doivent impérativement être évalués lors de cet audit pour obtenir un diagnostic complet ?

A La précision des réponses fournies par le chatbot.

B La latence des temps de réponse du système.

C Le nombre de développeurs ayant contribué au code du chatbot.

D Le taux d'abandon utilisateur en cours de conversation.

E Le taux d'escalade vers des conseillers humains.

F La date de la dernière mise à jour du modèle de langage sous-jacent.

VII Exercice : Optimiser le modèle de recommandation d'une entreprise e-commerce

Mise en situation professionnelle

Vous venez d'intégrer l'équipe IA de **FashionLine**, une entreprise e-commerce française spécialisée dans le prêt-à-porter, qui compte **2,5 millions de visiteurs uniques par mois** et un catalogue de **45 000 références produits**.

La direction technique vous confie la mission d'optimiser le modèle de recommandation de produits actuellement en production. Ce modèle, basé sur un **réseau de neurones profond** entraîné en apprentissage supervisé sur l'historique d'achats et de navigation des utilisateurs, est opérationnel depuis 18 mois.

Deux problèmes majeurs remontent du terrain :

- Le **service client** signale une hausse de **23 % des plaintes** liées à la non-pertinence des recommandations sur le dernier trimestre (produits hors saison, tailles indisponibles, suggestions répétitives).
- L'**équipe infrastructure** alerte sur une **latence moyenne de 420 ms** par requête de recommandation, alors que l'objectif cible est fixé à **150 ms maximum**. Lors des pics de trafic (soldes, Black Friday), cette latence dépasse régulièrement **800 ms**, provoquant des timeouts et une dégradation de l'expérience utilisateur.

Voici les données complémentaires dont vous disposez :

Données de performance actuelles du modèle

Métrique	Valeur actuelle	Objectif cible
Précision des recommandations (taux de clic sur produit recommandé)	12 %	20 %
Rappel (couverture du catalogue dans les recommandations)	8 % du catalogue	25 % du catalogue
F1-Score	0,42	0,60
Latence moyenne par requête	420 ms	150 ms
Latence en pic de charge	800 ms+	250 ms
Taux de conversion attribué aux recommandations	3,1 %	5 %
Part du CA générée par les recommandations	11 %	18 %
Taux d'abandon panier après recommandation non pertinente	34 %	< 20 %

Informations complémentaires

- Le modèle actuel n'a pas été ré-entraîné depuis **6 mois**, malgré l'évolution saisonnière du catalogue.
- Les données d'entraînement contiennent **18 mois d'historique** mais ne distinguent pas les achats pour soi des achats cadeaux.
- L'infrastructure actuelle repose sur un **serveur unique** sans mécanisme de mise en cache des recommandations.
- L'équipe dispose d'un budget de **3 mois** pour mener à bien l'optimisation, avec accès à des outils de tracking comme **MLflow**.
- Le directeur marketing souhaite que les recommandations intègrent un critère de **diversité** pour éviter les suggestions répétitives et favoriser la découverte de nouvelles catégories de produits.
- La responsable RSE demande que le modèle ne reproduise pas de **biais genrés** dans les recommandations (ex. : ne pas systématiquement recommander certaines catégories en fonction du genre détecté).

Question 1

[solution n°4 p. 32]

Présentez une démarche structurée pour diagnostiquer les sources des problèmes rencontrés par ce modèle de recommandation. Appuyez-vous sur le cadre méthodologique DMAIC et précisez les analyses spécifiques à mener pour chaque axe (pertinence et latence).

Question 2

[solution n°5 p. 33]

Identifiez et justifiez les métriques d'évaluation les plus pertinentes pour suivre l'optimisation de ce modèle, en distinguant les métriques techniques et les indicateurs business. Expliquez comment vous les articulez dans un tableau de bord mixte.

Question 3

[solution n°6 p. 34]

Proposez un plan d'optimisation structuré en axes prioritaires pour ce modèle de recommandation. Pour chaque axe, précisez les actions concrètes, leur justification à partir des données du cas, et le séquençement que vous recommandez.

Question 4

[solution n°7 p. 36]

Décrivez comment vous mettez en place la phase Control du DMAIC pour garantir que les optimisations produisent des bénéfices durables. Précisez les outils, les indicateurs de surveillance et les seuils d'alerte que vous recommandez.

Solutions des exercices

Solution n°1

[exercice p. 21]

Exercice

Un modèle d'apprentissage supervisé peut être entraîné et évalué sans avoir recours à des données étiquetées, à condition de disposer de métriques internes suffisamment robustes.

Vrai

✓ Faux



L'apprentissage supervisé repose par définition sur des données étiquetées : chaque exemple d'entraînement est associé à une sortie correcte connue. C'est précisément ce qui le distingue de l'apprentissage non supervisé, qui, lui, fonctionne sans vérité terrain et s'appuie sur des métriques internes comme l'indice de silhouette ou l'inertie intra-cluster. Confondre les deux approches conduit à des erreurs de conception fondamentales dans la stratégie d'optimisation.

Exercice

Vous travaillez sur un modèle de segmentation client non supervisé. Votre responsable vous demande d'évaluer si les segments obtenus sont pertinents. Quelle approche est la plus adaptée à ce contexte ?

Calculer l'exactitude globale du modèle en comparant les segments prédits à une vérité terrain.

✓ Combiner des métriques internes comme l'indice de silhouette avec une validation métier sur la pertinence opérationnelle des segments.

Se concentrer uniquement sur la minimisation de l'inertie intra-cluster, qui garantit la qualité des groupes formés.

Utiliser la courbe ROC et l'AUC pour mesurer la capacité discriminative du modèle de segmentation.



En l'absence de vérité terrain, l'évaluation d'un modèle non supervisé ne peut pas reposer sur l'exactitude globale ni sur la courbe ROC, qui sont des outils de classification supervisée. Minimiser l'inertie intra-cluster seul est insuffisant car cela ne garantit pas que les segments soient utiles opérationnellement. La bonne approche combine des métriques internes (indice de silhouette) avec une validation métier : les segments sont-ils suffisamment distincts pour justifier des stratégies différenciées ? Leur taille est-elle compatible avec les capacités de l'entreprise ?

Exercice

Parmi les propositions suivantes, lesquelles décrivent correctement les défis spécifiques d'optimisation des réseaux de neurones profonds par rapport aux arbres de décision ?

A

Les réseaux de neurones profonds présentent un risque de surajustement plus élevé en raison de leur grande capacité d'apprentissage.

B

Les réseaux de neurones profonds sont naturellement plus interprétables, ce qui simplifie leur optimisation réglementaire.

C

L'optimisation des réseaux de neurones nécessite des approches combinant régularisation, ajustement d'hyperparamètres et transfert d'apprentissage.

D

Les arbres de décision peuvent souffrir de surajustement sur des données complexes, contrairement aux réseaux de neurones qui y sont naturellement résistants.

E

Les difficultés d'interprétation des réseaux de neurones profonds constituent un défi d'optimisation spécifique à cette architecture.



Les réseaux de neurones profonds se distinguent des arbres de décision par trois défis majeurs : leur capacité d'apprentissage élevée les rend particulièrement vulnérables au surajustement ; leur optimisation requiert des approches sophistiquées (régularisation, hyperparamètres, transfert d'apprentissage) ; et leur faible interprétabilité complique leur usage dans des contextes réglementaires. À l'inverse, ce sont les arbres de décision qui offrent une excellente interprétabilité, et ils peuvent eux aussi souffrir de surajustement sur des données complexes – l'élagage (pruning) étant précisément une technique pour y remédier.

Exercice

Remettez dans le bon ordre les cinq phases du framework DMAIC appliqué à l'optimisation d'un modèle d'IA, de la première à la dernière étape.

A Définir le périmètre d'optimisation, les objectifs d'amélioration et les contraintes spécifiques au modèle.

B Mesurer les performances actuelles du modèle et établir une baseline quantitative.

C Analyser les causes racines des limitations de performance identifiées.

D Concevoir, tester et mettre en œuvre des solutions concrètes pour lever les freins identifiés.

E Contrôler les performances sur le long terme et détecter toute dégradation via un monitoring continu.



Le framework DMAIC suit une logique séquentielle stricte : on commence par Définir le problème et les objectifs (sans quoi les efforts sont dispersés), puis on Mesure l'état actuel pour établir une baseline (sans laquelle aucune amélioration ne peut être objectivement évaluée), ensuite on Analyse les causes racines (pour ne pas corriger les mauvais facteurs), puis on Améliore en testant des solutions concrètes par incréments, et enfin on Contrôle pour s'assurer que les gains sont durables et détecter tout concept drift. Inverser ces étapes conduit à des optimisations non traçables ou déconnectées des vrais problèmes.

Solution n°2

[exercice p. 22]

Exercice

La courbe ROC et son aire sous la courbe (AUC) sont particulièrement adaptées à l'évaluation de modèles sur des jeux de données déséquilibrés, car elles sont insensibles au déséquilibre des classes.

✓ Vrai

Faux



C'est effectivement une propriété clé de l'AUC : contrairement à l'exactitude globale, qui peut être trompeuse sur des données déséquilibrées (un modèle qui prédit toujours la classe majoritaire peut afficher une exactitude élevée), l'AUC évalue la capacité discriminative du modèle à travers tous les seuils de décision possibles, indépendamment de la distribution des classes. Une AUC proche de 1 indique une excellente discrimination, tandis qu'une valeur de 0,5 correspond à une performance aléatoire.

Exercice

Un système de diagnostic par imagerie médicale doit détecter des tumeurs malignes. Quelle stratégie d'optimisation des métriques est la plus cohérente avec les enjeux de ce contexte ?

Maximiser la précision pour éviter d'alarmer inutilement les patients avec de faux positifs.

✓ Maximiser le rappel pour minimiser les faux négatifs, quitte à générer quelques faux positifs filtrés par un spécialiste.

Optimiser l'exactitude globale, qui offre la vision la plus complète des performances du modèle.

Équilibrer précision et rappel via le F1-Score, car aucun des deux ne doit être privilégié en médecine.



Dans un contexte médical où la vie humaine est en jeu, passer à côté d'une tumeur maligne (faux négatif) est bien plus grave que de générer une alerte supplémentaire qui sera vérifiée par un spécialiste (faux positif). La stratégie d'optimisation doit donc privilégier un rappel maximal. Maximiser la précision seule risquerait de laisser passer des cas graves. L'exactitude globale est trompeuse sur des données déséquilibrées. Le F1-Score est utile pour équilibrer les deux métriques, mais dans ce contexte spécifique, le rappel prime clairement sur la précision.

Exercice

Associez chaque métrique d'évaluation au type de modèle ou contexte pour lequel elle est principalement utilisée.

Modèle de clustering non supervisé	Modèle de régression supervisée	Modèle de classification avec classes déséquilibrées	Modèle de langage génératif
Indice de silhouette	RMSE (erreur quadratique moyenne)	F1-Score	Perplexité



Chaque famille de modèles dispose de métriques adaptées à sa nature : l'indice de silhouette mesure la cohésion et la séparation des clusters en l'absence de vérité terrain ; le RMSE pénalise fortement les grandes erreurs dans les tâches de régression, ce qui est crucial dans certains contextes métier ; le F1-Score, moyenne harmonique de la précision et du rappel, est particulièrement utile lorsque les classes sont déséquilibrées ; la perplexité évalue la capacité d'un modèle de langage à prédire une séquence de mots, avec des valeurs faibles indiquant une meilleure performance.

Exercice

Vous présentez les résultats d'optimisation d'un modèle de détection de fraude à votre direction. Parmi les éléments suivants, lesquels doivent figurer dans votre tableau de bord pour assurer une communication efficace avec les décideurs non techniques ?

A

Le F1-Score du modèle avant et après optimisation.

B

La réduction estimée des pertes financières liées aux fraudes non détectées.

C

La matrice de confusion complète avec tous les seuils de décision testés.

D

L'impact sur l'expérience client lié à la variation du nombre de faux positifs.

E

Le détail des hyperparamètres utilisés lors de la phase d'entraînement.

Un tableau de bord efficace pour des décideurs non techniques doit présenter côte à côte des métriques techniques et leurs équivalents business. Le F1-Score est une métrique technique synthétique compréhensible ; la réduction des pertes financières traduit directement l'impact économique de l'optimisation ; l'impact sur l'expérience client via les faux positifs illustre le compromis opérationnel. En revanche, la matrice de confusion complète avec tous les seuils est trop technique pour des décideurs, et le détail des hyperparamètres n'apporte aucune valeur décisionnelle à ce niveau.

Exercice

Lors de la définition des objectifs d'optimisation d'un modèle, votre équipe hésite entre viser une amélioration de 2 % du F1-Score ou de 25 % en six semaines. Quelle approche est recommandée selon la méthodologie présentée dans la leçon ?

Viser l'objectif le plus ambitieux (25 %) pour maximiser l'impact business et motiver les équipes.

Choisir l'objectif le plus conservateur (2 %) pour garantir le succès et éviter tout risque d'échec.

✓ Définir des objectifs étagés avec des jalons intermédiaires, calibrés par l'état de l'art et les contraintes du projet.

Laisser les équipes techniques fixer librement leurs objectifs, car elles seules peuvent évaluer la faisabilité.

La leçon met en garde contre les deux extrêmes : des objectifs trop ambitieux conduisent à des échecs coûteux et démotivants, tandis que des objectifs trop modestes sous-exploitent le potentiel d'amélioration. L'approche recommandée consiste à définir des objectifs étagés avec des jalons intermédiaires, en consultant l'état de l'art pour calibrer les attentes et en tenant compte des contraintes spécifiques du projet. Cette démarche collaborative implique les parties prenantes techniques et métier, et permet d'ajuster progressivement les ambitions en fonction des résultats obtenus.

Solution n°3

[exercice p. 24]

Exercice

Associez chaque contexte d'utilisation à l'axe d'optimisation prioritaire qui lui correspond.

Minimisation de la latence (réponse < 100 ms)	Maximisation de la précision prédictive	Compression et quantification du modèle	Équilibre entre performance prédictive et explicabilité
Détection de fraude bancaire en temps réel	Analyse comportementale en traitement par lots	Système de vision embarqué sur drone industriel	Scoring crédit avec contrainte réglementaire



L'environnement d'exécution détermine fondamentalement la stratégie d'optimisation. La détection de fraude en temps réel impose une latence inférieure à 100 ms, orientant vers des architectures légères. L'analyse en batch peut se permettre plus de complexité algorithmique au profit de la précision. Un drone embarqué est contraint par son énergie, ce qui impose la compression et la quantification du modèle. Le scoring crédit bancaire doit concilier performance prédictive et explicabilité pour satisfaire les régulateurs financiers – un équilibre délicat qui constitue un défi d'optimisation spécifique au secteur.

Exercice

Vous réalisez l'audit initial d'un chatbot d'assistance client. Parmi les éléments suivants, lesquels doivent impérativement être évalués lors de cet audit pour obtenir un diagnostic complet ?

A

La précision des réponses fournies par le chatbot.

B

La latence des temps de réponse du système.

C

Le nombre de développeurs ayant contribué au code du chatbot.

D

Le taux d'abandon utilisateur en cours de conversation.

E

Le taux d'escalade vers des conseillers humains.

F

La date de la dernière mise à jour du modèle de langage sous-jacent.



Un audit initial complet d'un chatbot doit couvrir des métriques complémentaires qui permettent d'identifier si le problème vient du modèle, de l'infrastructure ou du design conversationnel. La précision des réponses évalue la qualité du modèle ; la latence révèle les problèmes d'infrastructure ; le taux d'abandon indique si les utilisateurs trouvent le chatbot utile ; le taux d'escalade mesure la capacité du système à résoudre les demandes de façon autonome. Le nombre de développeurs et la date de mise à jour sont des informations contextuelles qui n'évaluent pas directement les performances du système.

[exercice p. 26] **Solution n°4**

Réponse attendue

Pour diagnostiquer les sources des problèmes, vous appliquez les deux premières phases du cadre **DMAIC** – **Define** et **Measure** – avant d'entrer dans la phase **Analyze**.

Dans la phase **Define**, vous délimitez deux périmètres distincts : d'une part le problème de **pertinence des recommandations** (hausse de 23 % des plaintes, F1-Score à 0,42 contre un objectif de 0,60), d'autre part le problème de **latence** (420 ms en moyenne, 800 ms+ en pic, contre des cibles respectives de 150 ms et 250 ms). Vous identifiez les parties prenantes concernées – service client, équipe infrastructure, direction marketing – et formalisez des objectifs mesurables pour chaque axe.

Dans la phase **Measure**, vous établissez la **baseline** complète en segmentant les métriques de précision et de rappel par catégorie de produits, par profil utilisateur et par période temporelle. Côté latence, vous profilez les temps de réponse selon la charge serveur, la taille des requêtes et les moments de la journée. Cette segmentation permet de repérer si les problèmes sont globaux ou concentrés sur des segments spécifiques.

Dans la phase **Analyze**, vous menez trois investigations ciblées : premièrement, un **audit des données d'entraînement** pour détecter l'obsolescence (modèle non ré-entraîné depuis 6 mois, absence de distinction achats personnels/cadeaux) et les biais potentiels ; deuxièmement, un **audit architectural** pour évaluer si la complexité du réseau de neurones est adaptée et si le surajustement sur des données anciennes explique la perte de pertinence ; troisièmement, un **audit d'infrastructure** pour identifier les goulots d'étranglement (serveur unique, absence de cache) responsables de la latence excessive.

Éléments de solution

- **Savoirs à mobiliser :**
 - Le cadre **DMAIC** (Define, Measure, Analyze, Improve, Control) et son adaptation aux projets IA
 - La distinction entre **surajustement** et **sous-ajustement** pour orienter le diagnostic
 - Les notions de **latence unitaire** vs **temps de calcul global** pour analyser les problèmes de performance
 - L'importance de la **segmentation des métriques** (par catégorie, profil, période) pour un diagnostic fin
- **Rappel de méthode :**
 - Toujours commencer par **délimiter le périmètre** (Define) avant de mesurer : un diagnostic sans cadrage précis risque de disperser les efforts
 - Établir une **baseline chiffrée et segmentée** (Measure) avant toute tentative d'amélioration
 - Séparer les causes liées aux **données**, à l'**architecture du modèle** et à l'**infrastructure** pour éviter de traiter un symptôme sans résoudre la cause racine
- **Feedback d'auto-évaluation :**
 - Vérifiez que votre démarche distingue bien les deux axes problématiques (pertinence et latence) comme des chantiers séparés avec des métriques propres
 - Votre diagnostic doit identifier l'obsolescence des données d'entraînement (6 mois sans ré-entraînement) comme une cause probable majeure de la perte de pertinence
 - L'absence de cache et le serveur unique doivent apparaître comme des facteurs explicatifs évidents de la latence, indépendamment du modèle lui-même

[exercice p. 26] **Solution n°5**

Réponse attendue

Pour piloter l'optimisation du modèle de FashionLine, vous construisez un **tableau de bord mixte** articulant métriques techniques et indicateurs business, car une amélioration technique n'a de valeur que si elle se traduit en résultats opérationnels mesurables.

Côté **métriques techniques**, vous retenez le **F1-Score** (actuellement à 0,42, cible 0,60) comme indicateur synthétique équilibrant précision et rappel — essentiel ici car le modèle souffre à la fois de recommandations non pertinentes (précision faible) et d'une couverture insuffisante du catalogue (rappel à 8 %). Vous ajoutez la **latence moyenne et au percentile 95** pour suivre les

performances en conditions normales et en pic de charge. Enfin, un **indice de diversité** des recommandations mesure la variété des catégories proposées, répondant à la demande du directeur marketing.

Côté **indicateurs business**, vous suivez le **taux de conversion** attribué aux recommandations (3,1 % → 5 %), la **part du chiffre d'affaires** générée (11 % → 18 %), le **taux d'abandon panier** post-recommandation (34 % → < 20 %) et le **volume de plaintes clients** liées à la pertinence. Chaque métrique technique est reliée à son équivalent business : par exemple, l'amélioration du F1-Score se traduit directement en hausse du taux de conversion et en baisse des plaintes.

Ce tableau de bord est conçu pour être **partagé avec les décideurs non techniques** : les métriques techniques et business sont affichées côte à côte, permettant à chaque partie prenante de suivre les progrès dans son propre référentiel.

Éléments de solution

- **Savoirs à mobiliser :**
 - Les métriques de classification supervisée : **précision, rappel, F1-Score, AUC-ROC**
 - La distinction entre **latence moyenne** et **latence en pic** (percentile 95/99) pour évaluer la robustesse
 - La traduction des métriques techniques en **valeur business** (ROI, taux de conversion, satisfaction client)
 - Le concept de **tableau de bord mixte** technique/business pour aligner les équipes
- **Rappel de méthode :**
 - Le **F1-Score** est particulièrement adapté ici car les classes sont déséquilibrées (un utilisateur clique sur très peu de produits parmi des milliers)
 - Ne pas se limiter à la latence moyenne : le **percentile 95** révèle le vécu réel des utilisateurs en période de forte charge
 - Chaque métrique technique doit être **reliée causalement** à un indicateur business pour justifier les investissements d'optimisation
- **Feedback d'auto-évaluation :**
 - Vérifiez que vous n'avez pas proposé uniquement des métriques techniques : l'absence d'indicateurs business est une erreur fréquente qui déconnecte l'optimisation de sa finalité
 - L'indice de diversité est un élément différenciant qui montre votre capacité à intégrer des exigences métier spécifiques (demande du directeur marketing)
 - Votre réponse doit expliciter le lien causal entre métriques techniques et business, pas simplement les lister côte à côte

[exercice p. 26] **Solution n°6**

Réponse attendue

Vous structurez votre plan d'optimisation autour de **trois axes prioritaires**, séquencés selon une logique de **matrice impact/effort** : les actions à fort impact et faible complexité sont traitées en premier.

Axe 1 — Optimisation de l'infrastructure (semaines 1 à 3) : c'est l'axe prioritaire car il produit des gains immédiats sans modifier le modèle. Vous déployez un **système de cache** pour les recommandations les plus fréquentes, ce qui réduit drastiquement la latence. Vous mettez en place une **architecture distribuée** (load balancing) pour absorber les pics de charge. Ces actions

répondent directement au problème de latence (420 ms → cible 150 ms) et au dépassement des 800 ms en pic. La justification est claire : le serveur unique sans cache est un goulot d'étranglement identifié, indépendant de la qualité du modèle.

Axe 2 — Amélioration de la qualité des données et ré-entraînement (semaines 3 à 8) : le modèle n'a pas été ré-entraîné depuis 6 mois, ce qui explique les recommandations hors saison. Vous nettoyez et enrichissez les données d'entraînement en distinguant les **achats personnels des achats cadeaux**, vous intégrez les **données récentes** reflétant les tendances actuelles, et vous mettez en place un **pipeline de ré-entraînement périodique** via MLflow pour éviter que le problème ne se reproduise. Vous intégrez également un **filtre de disponibilité** (tailles en stock) pour éliminer les recommandations de produits indisponibles. Cet axe cible directement la hausse de 23 % des plaintes de pertinence.

Axe 3 — Optimisation architecturale et diversité (semaines 6 à 12) : vous explorez des techniques de **compression du modèle** (quantification, distillation) pour réduire la latence côté modèle. Vous intégrez un **critère de diversité** dans la fonction objectif pour répondre à la demande du directeur marketing et améliorer la couverture du catalogue (rappel de 8 % → 25 %). Vous veillez à auditer les **biais générés** dans les recommandations, conformément à la demande de la responsable RSE. Cet axe, plus complexe, s'appuie sur les fondations posées par les deux premiers.

Ce séquençement respecte la logique **DMAIC** : les axes 1 et 2 relèvent de la phase Improve avec des gains rapides et mesurables, tandis que l'axe 3 prépare la phase Control avec des améliorations structurelles et durables.

Éléments de solution

- **Savoirs à mobiliser :**

- La **matrice de priorisation** impact business vs complexité technique pour séquencer les actions
- Les techniques de **compression de modèles** (quantification, distillation) pour réduire la latence
- Le concept de **concept drift** : un modèle non ré-entraîné se dégrade face à l'évolution des données réelles
- L'importance de la **traçabilité** via des outils comme MLflow pour documenter chaque itération
- Les enjeux **éthiques** : audit des biais générés dans les recommandations

- **Rappel de méthode :**

- Toujours commencer par les **quick wins** (cache, infrastructure) avant de modifier le modèle : cela produit des résultats visibles rapidement et crédibilise la démarche auprès des parties prenantes
- Procéder par **incréments isolés** : chaque amélioration est testée séparément pour mesurer précisément son impact sur les métriques cibles
- Intégrer la phase **Control** dès la conception : le pipeline de ré-entraînement périodique et le monitoring automatisé évitent la récurrence des problèmes

- **Feedback d'auto-évaluation :**

- Vérifiez que votre plan est **justifié par les données du cas** : chaque action doit être reliée à un problème identifié dans l'énoncé (latence, obsolescence des données, plaintes clients)
- Un plan qui commence par modifier l'architecture du modèle sans traiter l'infrastructure est mal séquencé : les gains d'infrastructure sont plus rapides et moins risqués

- L'intégration des dimensions **RSE** (biais genrés) et **diversité** des recommandations montre une vision complète de l'optimisation, au-delà des seules métriques techniques

[exercice p. 26] **Solution n°7**

Réponse attendue

La phase **Control** vise à pérenniser les gains obtenus et à détecter toute dégradation avant qu'elle n'impacte les utilisateurs. Vous mettez en place un dispositif de surveillance structuré autour de trois piliers.

Premièrement, vous déployez un **système de monitoring automatisé** via MLflow qui suit en continu les métriques clés : F1-Score, latence au percentile 95, taux de conversion des recommandations et indice de diversité. Vous définissez des **seuils d'alerte** précis : une alerte est déclenchée si le F1-Score descend en dessous de **0,55** (seuil intermédiaire entre la baseline de 0,42 et la cible de 0,60), si la latence moyenne dépasse **200 ms**, ou si le taux de conversion chute de plus de **15 %** par rapport à la moyenne glissante sur 30 jours.

Deuxièmement, vous instaurez un **pipeline de ré-entraînement périodique** (mensuel) pour contrer le **concept drift** lié à l'évolution saisonnière du catalogue et des comportements d'achat. Chaque nouveau modèle est automatiquement évalué sur le jeu de test de référence avant mise en production, garantissant qu'aucune régression ne passe inaperçue.

Troisièmement, vous mettez en place une **revue trimestrielle** associant les équipes techniques, le service client et la direction marketing. Cette revue croise les métriques techniques avec les indicateurs business et le feedback qualitatif des utilisateurs, permettant d'identifier des axes d'amélioration que les seules métriques automatisées ne capturent pas. Cette gouvernance collaborative déclenche de nouveaux cycles DMAIC lorsque les performances s'écartent des objectifs ou que de nouvelles opportunités d'optimisation émergent.

Éléments de solution

• Savoirs à mobiliser :

- La phase **Control** du DMAIC : surveillance continue, alertes automatisées, procédures de réévaluation périodique
- Le concept de **concept drift** (dérive des données) et ses impacts sur les performances d'un modèle en production
- Les outils de **MLOps** (MLflow, Weights & Biases) pour le versioning et le monitoring des modèles
- L'importance d'un **environnement de test reproductible** avec des datasets de référence stables

• Rappel de méthode :

- Les seuils d'alerte doivent être définis **entre la baseline et la cible**, pas au niveau de la cible elle-même : cela laisse le temps de réagir avant une dégradation critique
- Le ré-entraînement périodique ne suffit pas : il doit être accompagné d'une **validation automatique** sur un jeu de test de référence pour éviter les régressions
- La surveillance purement technique est insuffisante : le **feedback utilisateur** et les **indicateurs business** captent des dégradations que les métriques automatisées peuvent manquer

- **Feedback d'auto-évaluation :**

- Vérifiez que vous avez proposé des **seuils d'alerte chiffrés** et pas uniquement des principes généraux de surveillance
- Votre réponse doit mentionner le concept drift comme risque principal justifiant le ré-entraînement périodique, en lien avec le problème initial (modèle non mis à jour depuis 6 mois)
- La dimension **collaborative** de la phase Control (revue avec les parties prenantes métier) est un élément différenciant qui montre votre compréhension de l'optimisation comme processus organisationnel, pas uniquement technique