




Méthodologies de diagnostic des erreurs dans les modèles d'IA

Table des matières

I - Contexte	3
II - Taxonomie des erreurs dans les modèles d'IA	4
A. Erreurs liées aux données.....	4
B. Contextes d'utilisation et contraintes associées	5
III - Méthodes structurées de diagnostic	8
A. Approche systématique de localisation des erreurs.....	8
B. Outils et techniques de diagnostic avancés	10
IV - Analyse des erreurs spécifiques aux types de modèles	14
A. Diagnostic des modèles de Machine Learning classiques	14
B. Diagnostic des modèles de Deep Learning	15
V - Synthèse	17
VI - Auto-évaluation	20
VII - Exercice : Diagnostiquer les erreurs d'un modèle de prévision des ventes en e-commerce	25
Solutions des exercices	27

I Contexte

Contexte

Dans les organisations, mêmes les meilleurs modèles d'intelligence artificielle peuvent, une fois déployés, rencontrer des **comportements inattendus** ou une **dégradation des performances**. Ces difficultés proviennent souvent de sources variées : données imparfaites, biais cachés, choix de modélisation inadaptés, ou problèmes de convergence. Une démarche rigoureuse de **diagnostic des erreurs** s'impose : elle permet d'identifier précisément les causes réelles des écarts entre résultats attendus et réels, et de prioriser les actions correctives à mettre en œuvre.

Cette leçon propose d'explorer **méthodiquement** les **sources d'erreurs** les plus courantes dans les projets d'IA, ainsi que les **approches structurées** pour les diagnostiquer. À travers des cas concrets issus de secteurs variés (**finance, santé, industrie**), vous découvrirez comment les équipes de data scientists françaises abordent le diagnostic, depuis l'apparition des « *symptômes* » jusqu'à la localisation fine des causes réelles.

La rigueur dans la phase de diagnostic conditionne l'efficacité et la durabilité de toutes les actions d'amélioration ultérieures : maîtriser ces méthodes est donc un prérequis incontournable pour tout professionnel de l'IA.

II Taxonomie des erreurs dans les modèles d'IA

A. Erreurs liées aux données

Typologie des problèmes de données

Dans la pratique, la **qualité des données** reste le point d'entrée prioritaire lors d'un diagnostic d'erreur. Un modèle, même très performant en théorie, se retrouve très vite limité lorsqu'il doit composer avec des **données incomplètes, bruitées, biaisées ou obsolètes**.

Par exemple, dans le domaine médical, on constate souvent que certains groupes de patients sont **sous-représentés** dans les jeux de données historiques : un modèle entraîné sur ces données risque de moins bien prédire les cas rares, ce qui peut avoir des conséquences significatives sur la prise en charge. En finance également, il arrive qu'une évolution du comportement des clients ne soit prise en compte qu'avec du retard dans les données, conduisant à des **prédictions désynchronisées avec la réalité**.

Cette question de la robustesse des données ne concerne pas seulement leur quantité ou leur fraîcheur, mais aussi leur cohérence d'ensemble et leur capacité à représenter tous les scénarios pouvant survenir après le déploiement du modèle. **La première démarche d'un diagnostic efficace est donc de vérifier la complétude, la cohérence et la représentativité du dataset utilisé.**

Données bruitées vs données manquantes

Az Définition

On parle de **données bruitées** lorsqu'elles contiennent des valeurs erronées, irrégulières ou peu fiables (par ex. capteur industriel qui enregistre des valeurs aberrantes).

Les **données manquantes** sont les observations absentes du tableau d'analyse (lignes ou colonnes partiellement vides).

Ces deux phénomènes sont très fréquents dans les diagnostics et nécessitent des approches différentes : nettoyage, imputation ou exclusion raisonnée pour les données manquantes, détection puis correction/filtrage pour les données bruitées.

Les dérives de distribution et leur impact

Les **dérives de distribution** – ou « *drifts* » - se manifestent lorsque la répartition statistique des variables change entre la phase d'entraînement et la réalité rencontrée en production. Par exemple, un modèle de **prévision de consommation énergétique** entraîné sur des hivers plutôt doux peut s'avérer incapable de prédire correctement la demande lors d'un épisode de froid extrême.

De même, un modèle de **détection de fraude bancaire** doit constamment s'adapter à de nouvelles tactiques des fraudeurs : **l'apparition de comportements inédits** introduit un écart entre les données de référence et les nouvelles données, et cela peut causer une augmentation brutale des faux négatifs.

Identifier, caractériser et suivre ces dérives de distribution est crucial pour anticiper les périodes où les performances vont baisser et déclencher des alertes ou des réapprentissage préventifs.

Drift dans un modèle e-commerce

 Exemple

Un modèle de recommandation formé avec la pandémie COVID-19 proposait surtout des produits de consommation courante. Après le passage massif aux achats en ligne, la distribution des achats clients a changé brutalement. Sans mise à jour régulière des données, le modèle a multiplié les erreurs en suggérant des articles devenus beaucoup moins demandés.

Les biais dans les données et leurs conséquences

Un des défis majeurs en IA est la **reproduction automatique des biais présents dans l'historique**.

Prenons l'exemple d'un modèle de recrutement : si, dans le passé, le processus favorisait involontairement certains groupes (par le genre, l'âge, la provenance géographique, etc.), le modèle apprendra ces tendances et continuera à **favoriser ou exclure** selon les mêmes motifs.

De même, dans le secteur bancaire, un modèle de score de crédit peut désavantager des catégories entières de clients ayant été moins bien servies historiquement, sans justification liée à leur situation réelle.

Les biais dans les données sont donc particulièrement insidieux : **ils ne se manifestent pas toujours par une chute globale des performances, mais souvent par une injustice ou une inégalité dans les prédictions**.

Détecter, documenter et corriger ces biais est une responsabilité éthique autant que technique.

Mettre en place des audits d'équité

 Conseil

Intégrez systématiquement une étape de **contrôle de l'équité** en auditant vos modèles par tranche démographique ou segment métier. Cela permet de détecter des discriminations cachées même si les métriques globales semblent correctes.

Ne négligez jamais la qualité des données

 Attention

Même le meilleur algorithme ne peut compenser des défauts majeurs dans les données. Prendre le temps de vérifier que le dataset utilisé est fiable, complet, et réellement pertinent pour le contexte métier reste une étape incontournable du diagnostic.

B. Contextes d'utilisation et contraintes associées

Les métriques de spécification du modèle

Le choix de la **bonne architecture algorithmique** est une étape cruciale, mais il reste une source fréquente d'erreurs. Trop souvent, par manque de recul ou d'analyse préalable, une équipe opte pour une famille de modèles par habitude (par exemple un modèle linéaire parce qu'il est facile à interpréter) sans vérifier **l'adéquation réelle avec la complexité des relations dans les données**.

Par exemple, une entreprise française spécialisée dans la livraison a constaté que le recours à une **régression linéaire** pour optimiser les tournées fonctionnait mal : la réalité logistique introduisait de subtiles interactions non linéaires que seul un modèle plus flexible pouvait mieux appréhender.

Dans certains cas, c'est l'inverse : utiliser un modèle très complexe (par exemple un réseau de neurones profond) sur des données peu nombreuses ou peu variées peut conduire à l'effet opposé : un modèle qui s'ajuste trop à l'échantillon, mais devient **instable ou incohérent en production**.

L'adéquation entre la nature du problème, la quantité et la qualité des données, et le choix du modèle est fondamentale : c'est la base d'une performance juste et stable.

Spécification du modèle

Az Définition

La **spécification du modèle** décrit l'adéquation entre le type de modèle choisi (linéaire, non linéaire, réseau de neurones, etc.), la nature des données utilisées et la complexité du problème. Une mauvaise spécification se traduit par des erreurs récurrentes que ni les hyperparamètres ni les données supplémentaires ne corrigent complètement.

Comment choisir la bonne architecture de modèle

Les problèmes d'optimisation et de convergence

Lorsque l'entraînement d'un modèle stagne ou échoue à produire une amélioration mesurable même après de multiples essais, il s'agit probablement d'un **problème d'optimisation ou de convergence**. Ces difficultés sont particulièrement fréquentes avec les réseaux de neurones :

- Une mauvaise initialisation des poids
- Des taux d'apprentissages inadaptés
- Des architectures trop profondes ou mal pensées

Dans l'industrie, par exemple, l'apprentissage d'un modèle pour la détection d'anomalies sur des images de production peut se figer très tôt si les paramètres ne sont pas calibrés, ou partir en « *explosion du gradient* » et diverger.

Savoir repérer un problème d'optimisation permet d'éviter de s'acharner inutilement sur les données ou de remettre en cause le modèle tout entier alors que seuls des réglages sont en cause.

Divergence dans un modèle de NLP

👁 Exemple

Lors de l'entraînement d'un modèle de traduction automatique, le gradient a divergé après quelques itérations. L'analyse a révélé un **taux d'apprentissage trop élevé**, provoquant une instabilité croissante. Ajuster ce paramètre a suffi à stabiliser le training.


Erreurs d'hyperparamétrage et leurs symptômes

Dans la phase d'expérimentation, un **hyperparamétrage maladroit** est souvent à l'origine de symptômes comme une convergence partielle, un surajustement rapide, ou une incapacité à apprendre.


Un **taux d'apprentissage trop élevé** empêche la stabilité, alors qu'un taux trop faible ne conduit jamais à de vrais progrès. Trop de couches ou de nœuds dans un réseau de neurones provoque parfois un surapprentissage rapide, ou bien aboutit à un modèle peu interprétable et difficile à diagnostiquer.

Dans le monde industriel ou en reconnaissance d'images, on a vu des cas où la seule modification d'un paramètre (par exemple, la taille du batch ou la fonction d'activation) transformait radicalement la capacité d'un modèle à apprendre ou à généraliser.

Le diagnostic doit toujours inclure une analyse raisonnée et tracée des hyperparamètres testés, pour ajuster le modèle par paliers et documenter les effets constatés.

Itérez par incréments

N'ajustez pas plusieurs hyperparamètres en même temps. Modifiez un paramètre à la fois, relancez l'entraînement, et documentez les résultats. Cela permet d'isoler l'effet de chaque réglage et d'accélérer le diagnostic.

Tracez vos essais pour accélérer le diagnostic

En tenant un journal des expérimentations (modèle, paramètres, résultats, courbes), il devient beaucoup plus simple, lors d'un problème complexe, de retracer l'origine d'une erreur et d'identifier ce qui, dans l'évolution des essais, a agi de façon positive ou négative.

III Méthodes structurées de diagnostic

A. Approche systématique de localisation des erreurs

La démarche d'investigation par isolation


Face à un modèle d'IA qui se comporte de façon inattendue, la démarche la plus fiable consiste à **localiser progressivement la source de l'erreur**, par élimination.

L'expérience des grandes entreprises françaises du CAC 40 montre que le processus débute toujours par une **vérification rigoureuse des données** : qualité, cohérence, fraîcheur, couverture des scénarios d'usage.

Si aucune faute n'est détectée, on procède alors à l'analyse du **modèle lui-même** (structure, choix algorithmique, réglages, sur- ou sous-apprentissage) avant de s'intéresser à l'**implémentation logicielle** (bugs, incohérences dans les scripts, erreurs d'intégration).

Avancer étape par étape permet de **circonscrire le périmètre du problème**, d'éviter de perdre du temps sur des pistes secondaires et de garantir une action corrective ciblée et efficiente.

Schéma d'un arbre de diagnostic

**Outlier (valeur atypique)****Az Définition**

On appelle **outlier** une instance du jeu de données pour laquelle le modèle commet une erreur très marquée ou qui présente des caractéristiques extrêmes par rapport au reste de la population. Leur analyse détaillée constitue une source d'information précieuse pour comprendre des zones d'ombre ou des cas limites du système.

Analyse des cas particuliers et des outliers

L'étude attentive des **erreurs spectaculaires** commises par un modèle est souvent plus instructive que l'examen de la performance globale.

Par exemple, dans la détection d'objets pour l'industrie, l'échec systématique dans certaines conditions d'éclairage peut révéler une insuffisance de représentativité dans les données d'entraînement.

En crédit, un nombre restreint de refus injustifiés pour une même catégorie de profils peut signaler un **biais structurel**, voire un défaut de logique métier dans le prétraitement ou la segmentation initiale.

Chercher à comprendre les « *pourquoi* » cachés derrière quelques cas particuliers éclaire aisément des **faiblesses généralisées du modèle**.

Ne pas ignorer les anomalies rares

⚠ Attention

Même si elles représentent une faible proportion des données, les **erreurs spectaculaires** sont souvent révélatrices d'un problème systémique. Les négliger revient à masquer une faiblesse structurelle du modèle.

Stratégies de segmentation de l'analyse d'erreurs

Plutôt que de s'arrêter à la moyenne des métriques d'évaluation, il est toujours pertinent de **décomposer les erreurs par segments pertinents** : zone géographique, catégorie de produit, tranche d'âge, saison, etc.

Cette méthode met ainsi parfois au jour des défaillances majeures qui passent inaperçues dans l'analyse globale : un modèle de recommandation qui fonctionne bien en région parisienne mais échoue en province, ou un outil de prévision très précis en basse saison mais perdu lors des soldes.

Apprendre à segmenter l'analyse rend la démarche de diagnostic plus fine, plus rapide et surtout plus actionnable en termes de correctifs à envisager.

Impliquer les parties prenantes métiers dans l'analyse segmentée

💡 Conseil

Les retours terrain ou retours utilisateurs sont précieux pour révéler rapidement des zones d'incompréhension ou d'inefficacité du modèle : leur perception complète utilement le diagnostic technique fondé sur les données.

B. Outils et techniques de diagnostic avancés

Analyse des courbes d'apprentissage et de validation

Les **courbes d'apprentissage** permettent de suivre, lors de l'entraînement, l'évolution des principales métriques sur le jeu d'entraînement et de validation.

Une **divergence anormale** entre les deux signale un problème de **surapprentissage** : le modèle apprend trop bien sur ses données connues au détriment de sa capacité à généraliser.

À l'inverse, si les deux courbes stagnent à un niveau de performance faible, le **sous-apprentissage** est probable – manque d'entraînement, données pauvres ou modèle inadapté.

Les ingénieurs IA dans l'industrie et la finance s'appuient sur ces graphiques pour repérer très tôt les échecs de convergence, avant même de lancer une batterie de tests complémentaires.

Surapprentissage (overfitting)**Az Définition**

Le **surapprentissage** désigne la situation où un modèle d'IA « colle » trop aux spécificités de son jeu d'entraînement et perd sa capacité à traiter correctement de nouvelles données. Il s'observe très bien sur les courbes d'apprentissage, par l'écart croissant entre performance sur entraînement et performance en validation.

Sous-apprentissage (underfitting)**Az Définition**


Le **sous-apprentissage** survient lorsqu'un modèle d'IA n'arrive pas à capter la structure ou la complexité du phénomène qu'il doit prédire. On dit alors qu'il est « *trop simple* » : il généralise mal, affiche des performances faibles aussi bien sur les données d'entraînement que sur des données inédites, et reste insensible aux variations des paramètres ou des données.

Ce symptôme se repère visuelle sur les courbes d'apprentissage : la performance stagne à un niveau bas, sans amélioration notable, quel que soit le nombre d'itérations ou la durée de l'entraînement.

Le sous-apprentissage appelle à enrichir le modèle (ajout de paramètres, choix d'une architecture plus complexe) ou à améliorer la qualité des données utilisées.

Exemples de courbes d'apprentissage

Exemples de courbes d'apprentissage



Les matrices de confusion avancées et leur interprétation

Au-delà du simple taux de mauvaise classification, la **matrice de confusion** – et ses variantes avancées comme les matrices normalisées ou stratifiées – permettent d'analyser la nature et l'impact exact des erreurs commises.

Un coût d'erreur asymétrique (erreur beaucoup plus grave dans un sens que dans un autre) peut justifier d'ajuster le seuil de décision ou de pondérer la fonction de perte, surtout dans la **détection de fraude** ou le **diagnostic médical** où le « *faux négatif* » est potentiellement catastrophique.

La bonne lecture de ces matrices est indispensable pour adapter les modèles aux enjeux métier réels.

Coût d'erreur asymétrique

Az Définition

Dans certaines applications, toutes les erreurs ne se valent pas. Par exemple, en santé, **faux négatif (maladie non détectée)** est beaucoup plus grave qu'un **faux positif (erreur de détection corrigée ensuite)**. On parle alors de **coût d'erreur asymétrique**.

Matrice de confusion en détection de fraude

Exemple

Dans une grande banque française, l'équipe IA a adopté une matrice de confusion pondérée pour évaluer le modèle : le coût d'une transaction frauduleuse non détectée y est évalué à 50 fois celui d'un faux positif. Grâce à cette approche, des ajustements de seuils ont permis de diviser par deux le coût total des erreurs en trois mois.

Diagnostic par ablation et perturbation

Pour aller plus loin dans le diagnostic, les équipes avancées n'hésitent pas à mener des **tests expérimentaux** :

- Supprimer certaines variables (« *ablation* »)
- Perturber le jeu de données
- Geler certaines couches dans les réseaux de neurones

Ces méthodes permettent d'**isoler l'impact de chaque composant ou réglage** sur la performance finale et d'identifier très précisément les facteurs bloquants. Il s'agit d'une approche souvent utilisée en secteur industriel pour comprendre par l'expérimentation contrôlée, ce qui génère réellement la valeur – ou la perte de performance – d'un modèle complexe.

La visualisation comme moyen de partage

Conseil

Une bonne visualisation fait gagner du temps : elle permet de rendre les diagnostics compréhensibles par tous, favorise l'acceptation des actions à mener, et installe une culture métier-data commune autour de l'amélioration du modèle.

Toutes ces méthodes, du raisonnement pas-à-pas à l'usage d'outils avancés, structurent un diagnostic solide et reproductible. L'essentiel est toujours de croiser les constats statistiques et l'intuition métier, pour qu'aucune erreur significative ne passe inaperçue.

IV Analyse des erreurs spécifiques aux types de modèles

A. Diagnostic des modèles de Machine Learning classiques

Diagnostic des modèles de classification non neuronaux

Pour les **modèles de classification classiques** comme les SVM, arbres de décision ou k-plus proches voisins, le diagnostic repose souvent sur l'étude de la **structure des régions de décision** et l'**analyse de l'importance des variables explicatives**. Par exemple, il peut s'agir de visualiser comment l'algorithme sépare deux classes dans un espace de variables, ou de détecter si certaines features dominent les décisions.

Les faiblesses de ces modèles se manifestent fréquemment dans les situations où les frontières entre classes sont complexes, ou lorsque certaines variables, mal traitées ou corrélées, brouillent la clarté du découpage.

Dans des applications comme la **détection de fraude** ou la **segmentation client**, il est au courant d'appliquer ces analyses pour comprendre pourquoi certains segments génèrent systématiquement plus d'erreurs ou de faux positifs que d'autres.

L'analyse détaillée des zones de confusion, de la distribution des distances aux frontières de décision, et des variables clés, permet d'orienter la recherche des causes d'erreurs et d'imaginer des améliorations concrètes : enrichissement des variables, changement de modèle, ou segmentation préalable.

Région de décision

Az Définition

Une **région de décision** désigne, dans un espace de variables, la zone où le modèle prédit une même classe. Observer la géométrie de ces régions offre un diagnostic des points de confusion ou des manques de flexibilité dans le modèle.

Diagnostic d'un SVM en santé

👁 Exemple

Un modèle SVM de détection de cancer s'est révélé performant globalement, mais présentait une zone grise autour de certains seuils. L'analyse des **régions de décision** a montré une confusion forte entre patients sains et malades dans une petite région de l'espace. L'ajout de nouvelles variables cliniques a permis de clarifier la frontière.

Analyse des erreurs dans les modèles de régression

Le diagnostic d'un **modèle de régression** s'appuie sur l'examen minutieux des **résidus** : il s'agit de la différence entre la valeur prédite et la valeur réelle. Une analyse graphique (résidus vs valeurs prédites, tests de normalité, homoscedasticité) révèle souvent des patrons caractéristiques d'erreur :

- **Distribution non centrée** : signalant un biais du modèle,
- **Variance changeante** (hétéroscédasticité) : les erreurs augmentent ou diminuent avec le niveau de la variable cible,

- **Corrélations inexpliquées** : révélatrice d'un effet de variables omises ou d'une multicollinéarité. Par exemple, dans une prévision immobilière, si les résidus augmentent pour les biens très chers, le modèle ne capture sans doute pas les spécificités du haut de gamme.

L'interprétation rigoureuse des résidus et des diagnostics associés mène souvent à l'introduction de nouvelles variables, à une transformation de la cible ou des inputs, ou au choix d'un nouveau modèle.

Prévision de consommation énergétique

👁 Exemple

Dans l'industrie énergétique, des ingénieurs ont diagnostiqué, via l'étude des résidus, une sous-estimation systématique lors des pics de froid. L'intégration de nouvelles variables météorologiques et l'usage d'un modèle non linéaire ont corrigé cette faiblesse.

Analyse des erreurs dans les modèles non supervisés

Pour les **modèles de clustering ou de réduction de dimensionnalité** (comme PCA, t-SNE), l'absence de vérité terrain rend le diagnostic plus délicat. On s'intéresse donc à la **qualité et à la stabilité des clusters**, à la robustesse des regroupements obtenus, ainsi qu'aux anomalies éventuelles dans la position des objets ou la séparation visuelle entre groupes.

Analyser les distances intra- et inter-clusters, la répartition des classes connues (lorsqu'on en dispose), ou la répliquabilité des clusters lors de relances permet de repérer des projections trompeuses ou des axes mal identifiés. Des méthodes comme l'**indice de silhouette** ou la validation croisée sur différents échantillons sont précieuses pour ce diagnostic.

En segmentation client, cela permet d'éviter de bâtir des segments opérationnels sur des regroupements instables ou sans signification marketing claire.

Le diagnostic poussé sur les modèles non supervisés s'attache donc à détecter tout artefact structurel ou tout manque de robustesse à des variables faibles dans les données.

B. Diagnostic des modèles de Deep Learning

Erreurs spécifiques aux réseaux de neurones convolutifs

Dans les modèles de **vision par ordinateur**, de nombreux échecs viennent d'une **sensibilité excessive aux variations d'images** : changement d'éclairage, d'angle ou d'arrière-plan. Les réseaux convolutifs peuvent aussi surajuster à des « *artefacts* » du dataset ou apprendre à reconnaître des détails inutiles, négligeant les véritables invariants du problème.

Dans l'industrie et en imagerie médicale, ces modèles rencontrent parfois des difficultés à généraliser à des nouveaux environnements ou à des données issues de capteurs différents.

Diagnostiquer ces situations nécessite des tests ciblés sur des jeux de données variés, l'analyse croisée des erreurs et l'usage de visualisations pour comprendre quelles caractéristiques guident réellement la prédiction.

Le risque d'un faux sentiment de robustesse

⚠ Attention

Même avec un grand volume d'images annotées, un modèle peut échouer sur des cas hors distribution, ou face à de simples transformations (bruit, rotation, contraste, etc.). Seule une campagne de tests systématique dévoile les vraies limites.

Diagnostic des architectures complexes (RNN, transformers)

Avec les **réseaux récurrents** et les **transformers**, des problématiques avancées émergent :

- **Dépendances à long terme** dans le texte ou la séquence mal captées (RNN).
- **Attention mal dirigée** ou dilution de l'information (transformers).
- Difficultés d'apprentissage, surtout dans les architectures hybrides ou peu régularisées. Dans la traduction automatique ou la prévision de séries financières, cela se traduit par des pertes brusques de sens, des accumulations d'erreurs sur la durée, ou des défaillances à l'apparition d'événements rares.

Le diagnostic passe alors par la visualisation des mécanismes d'attention, la manipulation de séquences de test spécifiques, et l'examen détaillé des gradients et des points de rupture dans l'apprentissage.

Erreurs dans la traduction automatique

[👁 Exemple](#)

Un modèle Transformer entraîné sur de l'anglais-français traduisait correctement des phrases courtes mais échouait sur de longues phrases complexes. L'analyse des **poids d'attention** a montré que le modèle se « *perdait* » en diluant l'information sur les dépendances longues. L'introduction d'un mécanisme de « *relative position encoding* » a corrigé ce défaut.

Analyse des représentations internes et des embeddings

Comprendre ce que **le modèle a réellement appris** est la clé des diagnostics avancés. L'analyse des **embeddings** (représentations vectorielles), l'examen des activations de neurones, et l'utilisation de **cartes de saillance** permettent d'identifier si un modèle apprend des informations utiles ou non, et repérer celles qui, en entrée, génèrent des confusions ou des erreurs répétées.

Dans le diagnostic, ces méthodes ouvrent la possibilité de « *voir* » l'apprentissage, de corriger une attention trop forte sur des variables inutiles, ou d'analyser des biais non détectés par les seules métriques classiques.

C'est souvent cet examen minutieux de l'intérieur du réseau qui permet d'élaborer les corrections les plus fines et d'améliorer la robustesse globale du système.

V Synthèse

A. Flashcards

Drift (dérive de distribution)

Changement de la répartition statistique des variables entre entraînement et production.

Biais dans les données

Reproduction automatique de discriminations ou inégalités présentes dans l'historique.

Spécification du modèle

Adéquation entre type de modèle choisi, données et complexité du problème.

Surapprentissage (overfitting)

Le modèle colle trop aux données d'entraînement et perd sa capacité de généralisation.

Sous-apprentissage (underfitting)

Le modèle est trop simple et ne capte pas la complexité du phénomène.

Outlier (valeur atypique)

Instance pour laquelle le modèle commet une erreur très marquée ou présente des caractéristiques extrêmes.

Matrice de confusion

Tableau croisant prédictions et réalité pour analyser la nature des erreurs commises.

Coût d'erreur asymétrique

Situation où certaines erreurs sont beaucoup plus graves que d'autres selon le contexte métier.

Région de décision

Zone de l'espace de variables où le modèle prédit une même classe.

Analyse des résidus

Examen des écarts entre valeurs prédites et réelles pour détecter biais ou patrons d'erreur.

Test par ablation

Suppression de variables ou composants pour isoler leur impact sur la performance.

Embeddings


Représentations vectorielles apprises par le modèle pour encoder l'information.

La théorie en Bref

🔗 Fondamental

Les **méthodologies de diagnostic des erreurs** dans les modèles d'IA permettent d'identifier les causes réelles des écarts entre résultats attendus et réels. Les erreurs proviennent principalement de trois sources : les **données** (incomplètes, bruitées, biaisées, obsolètes), la **modélisation** (choix d'architecture inadapté, problèmes d'optimisation, hyperparamétrage maladroit) et l'**implémentation**. La démarche de diagnostic repose sur une **localisation progressive par élimination**, en commençant toujours par vérifier la qualité des données avant d'analyser le modèle. Les **dérives de distribution** (drift) et les **biais cachés** constituent des sources fréquentes de dégradation des performances en production. L'analyse des **courbes d'apprentissage**, des **matrices de confusion** et des **résidus** permet de repérer le


surapprentissage (overfitting) ou le **sous-apprentissage** (underfitting). Une approche structurée combinant analyse segmentée, visualisation et tests par ablation garantit un diagnostic rigoureux et actionnable.



1. Valeurs erronées, irrégulières ou absentes dans le dataset.
2. Écart statistique entre données d'entraînement et production.
3. Reproduction automatique de discriminations historiques.
4. Modèle trop simple ou trop complexe pour le problème.
5. Convergence bloquée, gradient instable ou divergent.
6. Taux d'apprentissage, batch, architecture mal calibrés.
7. Vérifier données, puis modèle, puis implémentation.
8. Décomposer les erreurs par segment métier pertinent.
9. Analyser les erreurs spectaculaires pour révéler les faiblesses.
10. Supprimer ou perturber des composants pour isoler l'impact.
11. Détecter surapprentissage ou sous-apprentissage.
12. Analyser la nature et le coût des erreurs.
13. Identifier biais, hétéroscédasticité, variables omises.
14. Comprendre ce que le modèle a réellement appris.
15. Régions de décision, importance des variables, résidus.
16. Attention, activations, sensibilité aux variations.
17. Stabilité des clusters, indices de silhouette.

Diagnostic des erreurs en IA

Les conseils pro



Conseil

Comment structurer un diagnostic d'erreur face à un modèle d'IA défaillant en production ?

- Commencer systématiquement par vérifier la qualité, la complétude et la représentativité des données avant d'analyser le modèle.
- Procéder par élimination successive : données, puis modélisation, puis implémentation logicielle.

- Documenter chaque étape du diagnostic dans un journal d'investigation pour tracer les hypothèses testées et les résultats obtenus.
- Impliquer les parties prenantes métier pour croiser l'analyse technique et la connaissance terrain des cas d'usage.

Comment détecter et corriger les dérives de distribution dans un modèle déployé ?

- Mettre en place un monitoring continu des distributions statistiques des variables en production versus entraînement.
- Définir des seuils d'alerte sur les écarts de distribution pour déclencher des actions préventives.
- Planifier des cycles de réapprentissage réguliers ou déclenchés automatiquement en cas de drift détecté.
- Enrichir le dataset d'entraînement avec des données récentes représentatives des nouveaux comportements observés.

Comment identifier et traiter les biais cachés dans un modèle d'IA ?

- Auditer systématiquement les performances du modèle par segment démographique, géographique ou métier pertinent.
- Analyser les matrices de confusion segmentées pour repérer des discriminations invisibles dans les métriques globales.
- Intégrer des contraintes d'équité dans la fonction de perte ou ajuster les seuils de décision par segment.
- Documenter et communiquer les biais détectés aux parties prenantes pour garantir la transparence et l'amélioration continue.

Comment exploiter les courbes d'apprentissage pour diagnostiquer un problème de convergence ?

- Comparer systématiquement l'évolution des métriques sur jeu d'entraînement et jeu de validation pour repérer divergences ou stagnations.
- Identifier un surapprentissage par l'écart croissant entre performance d'entraînement et validation.
- Détecter un sous-apprentissage par la stagnation des deux courbes à un niveau de performance faible.
- Ajuster les hyperparamètres un par un en relançant l'entraînement et en observant l'impact sur les courbes.

Comment analyser les erreurs spécifiques aux modèles de Deep Learning ?

- Visualiser les mécanismes d'attention ou les activations de neurones pour comprendre ce que le modèle a réellement appris.
- Tester la robustesse du modèle face à des transformations simples (rotation, bruit, contraste) pour révéler les faiblesses de généralisation.
- Analyser les embeddings et cartes de saillance pour identifier les variables ou zones d'entrée générant des confusions.
- Mener des tests par ablation en gelant certaines couches ou en supprimant des composants pour isoler l'origine des erreurs.

VI Auto-évaluation

Exercice 1 : Sources d'erreurs liées aux données

[solution n°1 p. 27]

Exercice

Un modèle présentant des métriques globales satisfaisantes peut tout de même contenir des biais discriminatoires envers certains groupes d'utilisateurs.

Vrai

Faux

Exercice

Parmi les situations suivantes, lesquelles illustrent une dérive de distribution (data drift) susceptible de dégrader les performances d'un modèle en production ?

A

☐

Un modèle de prévision de consommation énergétique entraîné sur des hivers doux est confronté à un épisode de froid extrême.

B

☐

Un modèle de détection de fraude bancaire fait face à de nouvelles tactiques de fraude non présentes dans les données d'entraînement.

C

☐

Un modèle de recommandation e-commerce continue de proposer des produits populaires pendant la pandémie alors que les habitudes d'achat ont radicalement changé.

D

☐

Un modèle de régression linéaire est appliqué à un problème présentant des relations non linéaires complexes.

Exercice

Un capteur industriel enregistre ponctuellement des valeurs aberrantes très éloignées de la plage normale de fonctionnement. De quel type de problème de données s'agit-il, et quelle approche est la plus adaptée pour le traiter ?

Des données manquantes, à traiter par imputation statistique.

Des données bruitées, à traiter par détection puis correction ou filtrage.

Une dérive de distribution, à corriger par réentraînement du modèle.

Un biais de sélection, à corriger par rééchantillonnage du dataset.

Exercice 5 : Spécification et optimisation du modèle

[solution n°2 p. 28]

Exercice

Pour diagnostiquer efficacement l'effet d'un hyperparamètre sur les performances d'un modèle, il est recommandé de modifier plusieurs hyperparamètres simultanément afin de gagner du temps.

Vrai

Faux

Exercice

Sur les courbes d'apprentissage d'un réseau de neurones, vous observez que la performance sur le jeu d'entraînement continue de progresser tandis que la performance sur le jeu de validation se dégrade progressivement. Quel phénomène ce schéma indique-t-il ?

Un sous-apprentissage : le modèle est trop simple pour capturer la complexité des données.

Un problème de convergence : le taux d'apprentissage est trop élevé.

Un surapprentissage : le modèle s'ajuste trop aux spécificités du jeu d'entraînement.

Une dérive de distribution : les données de validation sont issues d'une période différente.

Exercice

Associez chaque symptôme observé lors de l'entraînement d'un modèle à la cause la plus probable parmi celles proposées.

A La performance sur l'entraînement est excellente mais chute fortement sur de nouvelles données.

B Le modèle performe bien globalement mais échoue systématiquement sur un sous-groupe spécifique.

C La loss diverge et devient instable après quelques itérations.

D Les deux courbes (entraînement et validation) stagnent à un niveau de performance faible dès le début de l'entraînement.

Sous-apprentissage : modèle trop simple ou données insuffisantes	Taux d'apprentissage trop élevé provoquant une explosion du gradient	Surapprentissage : le modèle a mémorisé les données d'entraînement	Biais dans les données ou sous- représentation d'un segment dans le dataset
---	---	---	---

Exercice 9 : Méthodes structurées de diagnostic

[solution n°3 p. 30]

Exercice

Remettez dans le bon ordre les étapes d'une démarche structurée de diagnostic d'erreurs pour un modèle d'IA déployé en production.

A Inspecter l'implémentation logicielle pour détecter d'éventuels bugs ou incohérences d'intégration.

B Examiner les erreurs spectaculaires et les outliers pour identifier des faiblesses systémiques.

C Analyser la structure du modèle : choix algorithmique, spécification, réglages des hyperparamètres.

D Vérifier la qualité, la cohérence et la représentativité des données utilisées pour l'entraînement.

E Segmenter l'analyse des erreurs par sous-populations ou contextes d'utilisation pertinents.

Réponse : ____ ____ ____ ____ ____

Exercice

Vous diagnostiquez un modèle de détection de fraude bancaire qui semble performant globalement mais génère un coût opérationnel élevé. Quels outils ou approches sont les plus pertinents pour approfondir ce diagnostic ?

☐ **A** Une matrice de confusion pondérée intégrant le coût asymétrique des erreurs (faux négatif vs faux positif).

☐ **B** Une analyse segmentée des erreurs par type de transaction, montant ou profil client.

☐ **C** Une augmentation systématique du volume de données d'entraînement sans autre modification.

☐ **D** Des tests d'ablation pour isoler l'impact de chaque variable sur les prédictions du modèle.

Exercice

Dans un modèle de crédit scoring, vous constatez qu'un petit nombre de dossiers d'une même catégorie de profils sont systématiquement refusés à tort. Quelle est la démarche la plus appropriée pour exploiter cette observation dans votre diagnostic ?

Ignorer ces cas car ils représentent une proportion négligeable des données et n'affectent pas les métriques globales.

Analyser en détail ces erreurs spectaculaires pour identifier un biais structurel ou un défaut de logique dans le prétraitement.

Supprimer ces profils du jeu de données pour améliorer les métriques globales du modèle.

Réentraîner immédiatement le modèle avec un dataset plus volumineux sans analyse préalable.

Exercice 13 : Diagnostic selon le type de modèle

[solution n°4 p. 31]

Exercice

Associez chaque famille de modèles à la technique de diagnostic qui lui est la plus spécifiquement adaptée.

A Transformer (NLP)

B Réseau de neurones convolutif (vision)

C Modèle de régression

D Modèle de clustering non supervisé

Analyse des résidus (distribution, hétéroscédasticité, corrélations inexpliquées)	Visualisation des cartes de saillance et tests sur jeux de données variés	Calcul de l'indice de silhouette et analyse de la stabilité des clusters	Visualisation des poids d'attention et manipulation de séquences de test spécifiques
---	---	--	--

Exercice

Lors du diagnostic d'un modèle de prévision immobilière, vous observez que les résidus augmentent systématiquement pour les biens de très haute valeur. Quelle interprétation est la plus cohérente avec cette observation ?

Le modèle souffre de sous-apprentissage global : il faut augmenter sa complexité pour l'ensemble du dataset.

Le modèle présente une hétéroscédasticité : ses erreurs varient selon le niveau de la variable cible, suggérant qu'il ne capture pas les spécificités du segment haut de gamme.

Le modèle est victime d'une dérive de distribution : les données de production sont issues d'une période différente de celle de l'entraînement.

Le modèle présente un surapprentissage sur les biens de haute valeur : il faut réduire sa complexité.

VII Exercice : Diagnostiquer les erreurs d'un modèle de prévision des ventes en e-commerce

Mise en situation professionnelle

Vous venez d'intégrer l'équipe Data & IA de **VentaPlus**, une entreprise française de e-commerce spécialisée dans la vente d'articles de sport et de loisirs en ligne. L'entreprise réalise un chiffre d'affaires annuel de **45 millions d'euros** et gère un catalogue de **12 000 références** réparties sur **3 entrepôts** en France.

Depuis 18 mois, l'équipe exploite un modèle de **prévision des ventes** basé sur un algorithme de **gradient boosting** (XGBoost) pour optimiser la gestion des stocks et anticiper les réapprovisionnements. Ce modèle a été entraîné sur **3 ans d'historique de ventes** (2021-2023) et utilise les variables suivantes :

Variable	Description
Historique des ventes	Volumes quotidiens par référence
Prix catalogue	Prix unitaire TTC
Catégorie produit	Sport, outdoor, fitness, accessoires
Jour de la semaine	Lundi à dimanche
Promotions actives	Oui/Non + taux de remise
Trafic web	Nombre de visites quotidiennes sur la fiche produit
Stock disponible	Quantité en entrepôt au jour J

En fonctionnement normal, le modèle affiche une **erreur moyenne absolue (MAE) de 8%**, jugée satisfaisante par la direction logistique. Cependant, l'équipe a identifié un problème récurrent : **lors des périodes saisonnières** (soldes d'été et d'hiver, Black Friday, fêtes de fin d'année), le modèle sous-estime systématiquement les volumes de vente, avec une **MAE qui grimpe à 35-40%** sur ces périodes. Cette sous-estimation a provoqué **4 épisodes de rupture de stock majeurs** au cours des 12 derniers mois, représentant un **manque à gagner estimé à 1,2 million d'euros**.

Voici un extrait des performances du modèle sur les 6 derniers mois :

Période	MAE globale	MAE catégorie Fitness	MAE catégorie Outdoor	Remarque
Juillet (hors soldes)	7,5%	6,8%	8,1%	Performance nominale
Soldes d'été (2 semaines)	38%	42%	31%	Sous-estimation massive
Septembre	8,2%	7,9%	9,0%	Retour à la normale
Black Friday (1 semaine)	41%	45%	36%	Pic d'erreur maximal

Période	MAE globale	MAE catégorie Fitness	MAE catégorie Outdoor	Remarque
Décembre (hors fêtes)	9,1%	8,5%	10,2%	Légère hausse
Fêtes de fin d'année	36%	39%	33%	Sous-estimation récurrente

La directrice data, Mme Karim, vous confie la mission suivante : « *Nous avons besoin d'un diagnostic complet et structuré. Avant de modifier quoi que ce soit, je veux comprendre précisément pourquoi le modèle échoue sur ces périodes. Vos conclusions orienteront nos investissements correctifs pour le prochain trimestre.* »

Vous disposez de l'ensemble des données d'entraînement, des logs d'expérimentation du modèle, des courbes d'apprentissage, et d'un accès aux métriques de production via le tableau de bord MLOps de l'entreprise.

Données complémentaires

L'analyse préliminaire menée par un collègue avant votre arrivée a révélé les éléments suivants :

- Les **périodes saisonnières** représentent environ **15% des jours de l'année** mais concentrent **35% du chiffre d'affaires annuel**
- Le dataset d'entraînement (2021-2023) ne contient que **6 occurrences de Black Friday** et **6 périodes de soldes**, soit un nombre limité d'exemples pour ces événements
- La variable « **promotions actives** » est codée en binaire (Oui/Non) sans distinction entre une remise de 10% et une remise de 50%
- Aucune variable calendaire spécifique (indicateur de période saisonnière, distance au prochain événement commercial) n'a été intégrée au modèle
- Les courbes d'apprentissage montrent un **écart croissant** entre la performance sur le jeu d'entraînement (MAE 3%) et le jeu de validation (MAE 8%) à partir de la 200^e itération
- Le modèle utilise **500 arbres** avec une profondeur maximale de **12 niveaux**

Question 1

[solution n°5 p. 32]

Présentez une démarche structurée pour diagnostiquer la source du problème rencontré par ce modèle de prévision des ventes.

Question 2

[solution n°6 p. 33]

Identifiez et justifiez au moins deux techniques d'analyse pertinentes pour diagnostiquer ce problème spécifique de sous-estimation saisonnière.

Question 3

[solution n°7 p. 34]

Élaborez un plan d'investigation listant les hypothèses à tester, l'ordre des vérifications à réaliser et les éléments sur lesquels vous focaliserez votre attention.

Question 4

[solution n°8 p. 34]

Décrivez les métriques ou visualisations que vous utiliseriez pour confirmer ou infirmer chacune de vos hypothèses, en explicitant leur intérêt pour le contexte de VentaPlus.

Solutions des exercices

Solution n°1

[exercice p. 20]

Exercice

Un modèle présentant des métriques globales satisfaisantes peut tout de même contenir des biais discriminatoires envers certains groupes d'utilisateurs.

✓ Vrai

Faux



C'est précisément la subtilité des biais dans les données : ils ne se manifestent pas nécessairement par une chute globale des performances. Un modèle de score de crédit ou de recrutement peut afficher un bon taux global tout en désavantageant systématiquement certaines catégories de profils. C'est pourquoi un audit d'équité par segment démographique ou métier est indispensable, même quand les indicateurs agrégés semblent corrects.

Exercice

Parmi les situations suivantes, lesquelles illustrent une dérive de distribution (data drift) susceptible de dégrader les performances d'un modèle en production ?

A

☐

Un modèle de prévision de consommation énergétique entraîné sur des hivers doux est confronté à un épisode de froid extrême.

B

☐

Un modèle de détection de fraude bancaire fait face à de nouvelles tactiques de fraude non présentes dans les données d'entraînement.

C

☐

Un modèle de recommandation e-commerce continue de proposer des produits populaires pendant la pandémie alors que les habitudes d'achat ont radicalement changé.

D

Un modèle de régression linéaire est appliqué à un problème présentant des relations non linéaires complexes.



Les trois premières situations décrivent bien un écart entre la distribution des données d'entraînement et celle rencontrée en production : changement climatique extrême, nouvelles tactiques de fraude, et évolution brutale des comportements d'achat. La quatrième option décrit en revanche une erreur de spécification du modèle (mauvais choix d'architecture), et non une dérive de distribution.

Exercice

Un capteur industriel enregistre ponctuellement des valeurs aberrantes très éloignées de la plage normale de fonctionnement. De quel type de problème de données s'agit-il, et quelle approche est la plus adaptée pour le traiter ?

Des données manquantes, à traiter par imputation statistique.

✓ Des données bruitées, à traiter par détection puis correction ou filtrage.

Une dérive de distribution, à corriger par réentraînement du modèle.

Un biais de sélection, à corriger par rééchantillonnage du dataset.



Des valeurs aberrantes produites par un capteur défaillant correspondent à la définition des données bruitées : des valeurs erronées ou peu fiables présentes dans le dataset. Le traitement approprié est la détection de ces anomalies, suivie de leur correction ou de leur filtrage. L'imputation concerne les données manquantes (observations absentes), la dérive de distribution un changement statistique global, et le biais de sélection une sous-représentation structurelle de certains groupes.

Solution n°2

[exercice p. 21]

Exercice

Pour diagnostiquer efficacement l'effet d'un hyperparamètre sur les performances d'un modèle, il est recommandé de modifier plusieurs hyperparamètres simultanément afin de gagner du temps.

Vrai

✓ Faux



C'est l'inverse : modifier plusieurs hyperparamètres en même temps rend impossible l'isolation de l'effet de chacun. Si les performances changent, on ne sait pas quel paramètre en est responsable. La bonne pratique consiste à modifier un seul paramètre à la fois, relancer l'entraînement, documenter les résultats, puis passer au suivant. Cette approche incrémentale est la seule qui permette un diagnostic fiable et reproductible.

Exercice

Sur les courbes d'apprentissage d'un réseau de neurones, vous observez que la performance sur le jeu d'entraînement continue de progresser tandis que la performance sur le jeu de validation se dégrade progressivement. Quel phénomène ce schéma indique-t-il ?

Un sous-apprentissage : le modèle est trop simple pour capturer la complexité des données.

Un problème de convergence : le taux d'apprentissage est trop élevé.

✓ Un surapprentissage : le modèle s'ajuste trop aux spécificités du jeu d'entraînement.

Une dérive de distribution : les données de validation sont issues d'une période différente.

Q L'écart croissant entre la courbe d'entraînement (qui progresse) et la courbe de validation (qui se dégrade) est le signe caractéristique du surapprentissage (overfitting). Le modèle mémorise les particularités de ses données d'entraînement au lieu d'apprendre des patterns généralisables. Le sous-apprentissage se manifeste par deux courbes qui stagnent à un niveau bas. Un problème de convergence se traduit par une instabilité ou un plateau précoce, pas par cette divergence progressive.

Exercice

Associez chaque symptôme observé lors de l'entraînement d'un modèle à la cause la plus probable parmi celles proposées.

Sous-apprentissage : modèle trop simple ou données insuffisantes	Taux d'apprentissage trop élevé provoquant une explosion du gradient	Surapprentissage : le modèle a mémorisé les données d'entraînement	Biais dans les données ou sous- représentation d'un segment dans le dataset
Les deux courbes (entraînement et validation) stagnent à un niveau de performance faible dès le début de l'entraînement.	La loss diverge et devient instable après quelques itérations.	La performance sur l'entraînement est excellente mais chute fortement sur de nouvelles données.	Le modèle performe bien globalement mais échoue systématiquement sur un sous-groupe spécifique.

Q Chaque symptôme pointe vers une cause distincte : la stagnation précoce des deux courbes à un niveau bas est le signe classique du sous-apprentissage. La divergence de la loss après quelques itérations est typique d'un taux d'apprentissage trop élevé (explosion du gradient). L'écart entre performance en entraînement et en production caractérise le surapprentissage. Enfin, des erreurs concentrées sur un sous-groupe spécifique révèlent un biais ou une sous-représentation dans les données d'entraînement.

Solution n°3

Exercice

Remettez dans le bon ordre les étapes d'une démarche structurée de diagnostic d'erreurs pour un modèle d'IA déployé en production.

A Vérifier la qualité, la cohérence et la représentativité des données utilisées pour l'entraînement.

B Analyser la structure du modèle : choix algorithmique, spécification, réglages des hyperparamètres.

C Examiner les erreurs spectaculaires et les outliers pour identifier des faiblesses systémiques.

D Segmenter l'analyse des erreurs par sous-populations ou contextes d'utilisation pertinents.

E Inspecter l'implémentation logicielle pour détecter d'éventuels bugs ou incohérences d'intégration.



La démarche rigoureuse commence toujours par le contrôle des données, car la majorité des problèmes en production y trouvent leur origine. On analyse ensuite le modèle lui-même (spécification, hyperparamètres), puis on examine les cas d'erreurs marquants qui révèlent souvent des faiblesses généralisées. La segmentation de l'analyse permet de détecter des défaillances invisibles dans une vue globale. L'inspection de l'implémentation logicielle intervient en dernier, une fois les sources de données et de modélisation écartées.

Exercice

Vous diagnostiquez un modèle de détection de fraude bancaire qui semble performant globalement mais génère un coût opérationnel élevé. Quels outils ou approches sont les plus pertinents pour approfondir ce diagnostic ?

A



Une matrice de confusion pondérée intégrant le coût asymétrique des erreurs (faux négatif vs faux positif).

B



Une analyse segmentée des erreurs par type de transaction, montant ou profil client.

C

Une augmentation systématique du volume de données d'entraînement sans autre modification.

D



Des tests d'ablation pour isoler l'impact de chaque variable sur les prédictions du modèle.

Q Dans la détection de fraude, un faux négatif (transaction frauduleuse non détectée) est bien plus coûteux qu'un faux positif : une matrice de confusion pondérée est donc l'outil idéal pour quantifier et réduire ce coût asymétrique. La segmentation des erreurs permet de révéler des patterns invisibles dans les métriques globales. Les tests d'ablation permettent d'isoler les variables qui contribuent réellement à la performance. En revanche, augmenter le volume de données sans diagnostic préalable ne résout pas un problème de seuil de décision ou de pondération des erreurs.

Exercice

Dans un modèle de crédit scoring, vous constatez qu'un petit nombre de dossiers d'une même catégorie de profils sont systématiquement refusés à tort. Quelle est la démarche la plus appropriée pour exploiter cette observation dans votre diagnostic ?

Ignorer ces cas car ils représentent une proportion négligeable des données et n'affectent pas les métriques globales.

✓ Analyser en détail ces erreurs spectaculaires pour identifier un biais structurel ou un défaut de logique dans le prétraitement.

Supprimer ces profils du jeu de données pour améliorer les métriques globales du modèle.

Réentraîner immédiatement le modèle avec un dataset plus volumineux sans analyse préalable.

Q Les erreurs concentrées sur un sous-groupe spécifique, même minoritaire, sont souvent révélatrices d'un problème systémique : biais structurel dans les données historiques, défaut de logique dans la segmentation ou le prétraitement. Les ignorer ou supprimer ces profils masquerait une faiblesse réelle du modèle. Réentraîner sans diagnostic préalable ne ferait que reproduire le même biais. L'analyse détaillée de ces cas particuliers est précisément ce qui permet d'identifier et de corriger la cause racine.

Solution n°4

[exercice p. 23]

Exercice

Associez chaque famille de modèles à la technique de diagnostic qui lui est la plus spécifiquement adaptée.

Analyse des résidus (distribution, hétéroscédasticité, corrélations inexpliquées)	Visualisation des cartes de saillance et tests sur jeux de données variés	Calcul de l'indice de silhouette et analyse de la stabilité des clusters	Visualisation des poids d'attention et manipulation de séquences de test spécifiques
Modèle de régression	Réseau de neurones convolutif (vision)	Modèle de clustering non supervisé	Transformer (NLP)



Chaque famille de modèles présente des faiblesses spécifiques qui appellent des outils de diagnostic adaptés. Pour la régression, l'analyse des résidus révèle les biais, l'hétéroscédasticité et les variables omises. Pour les CNN, les cartes de saillance permettent de comprendre ce que le modèle 'regarde' réellement. Pour le clustering, l'indice de silhouette mesure la cohérence et la séparation des groupes. Pour les transformers, la visualisation des poids d'attention permet de détecter une dilution de l'information sur les longues séquences.

Exercice

Lors du diagnostic d'un modèle de prévision immobilière, vous observez que les résidus augmentent systématiquement pour les biens de très haute valeur. Quelle interprétation est la plus cohérente avec cette observation ?

Le modèle souffre de sous-apprentissage global : il faut augmenter sa complexité pour l'ensemble du dataset.

✓ Le modèle présente une hétéroscédasticité : ses erreurs varient selon le niveau de la variable cible, suggérant qu'il ne capture pas les spécificités du segment haut de gamme.

Le modèle est victime d'une dérive de distribution : les données de production sont issues d'une période différente de celle de l'entraînement.

Le modèle présente un surapprentissage sur les biens de haute valeur : il faut réduire sa complexité.



Lorsque les résidus augmentent avec le niveau de la variable cible (ici, la valeur des biens), c'est le signe caractéristique de l'hétéroscédasticité : la variance des erreurs n'est pas constante. Cela indique que le modèle ne capture pas les mécanismes spécifiques au segment haut de gamme. Ce n'est pas un sous-apprentissage global (les performances sont bonnes sur le reste), ni une dérive de distribution (le problème est structurel, pas temporel), ni un surapprentissage sur ce segment (les erreurs sont élevées, pas faibles).

[exercice p. 26] **Solution n°5**

Réponse attendue

La démarche structurée de diagnostic repose sur une **investigation par isolation**, en éliminant progressivement les sources potentielles d'erreur selon un ordre logique. Vous commencez par examiner les **données** : vérifier si les périodes saisonnières sont suffisamment représentées dans le dataset d'entraînement, si les variables capturent réellement les dynamiques propres à ces événements (ici, l'absence de variable calendaire spécifique et le codage binaire trop simpliste des promotions sont des signaux forts). Ensuite, vous analysez le **modèle lui-même** : l'écart croissant entre performance d'entraînement et de validation suggère un surapprentissage, et la profondeur élevée des arbres (12 niveaux) combinée à 500 itérations renforce cette hypothèse. Enfin, vous vérifiez l'**implémentation** : cohérence du pipeline de données en production, absence de bugs dans le prétraitement des variables temporelles. Cette approche par paliers garantit un diagnostic ciblé et évite de disperser les efforts correctifs.

Éléments de solution

- **Étape 1 – Diagnostic des données** : contrôler la représentativité des périodes saisonnières (seulement 6 occurrences de Black Friday sur 3 ans), vérifier la granularité du codage des promotions (binaire vs. taux réel), rechercher d'éventuelles dérives de distribution entre données d'entraînement et données de production
- **Étape 2 – Diagnostic du modèle** : analyser les courbes d'apprentissage pour confirmer le surapprentissage (écart MAE 3% vs. 8%), évaluer l'adéquation des hyperparamètres (500 arbres, profondeur 12), vérifier si le modèle dispose de suffisamment de signaux pour distinguer les périodes normales des pics saisonniers
- **Étape 3 – Diagnostic de l'implémentation** : s'assurer que les données arrivent correctement en production, que le pipeline de feature engineering est identique entre entraînement et inférence
- **Rappel méthodologique** : la démarche d'investigation par isolation consiste à avancer étape par étape, en vérifiant d'abord les données, puis le modèle, puis l'implémentation – ce qui permet de circonscrire le périmètre du problème
- **Feedback** : une réponse complète doit mentionner explicitement les trois niveaux d'investigation (données, modèle, implémentation) et justifier l'ordre de priorité en s'appuyant sur les indices fournis dans l'énoncé

[exercice p. 26] **Solution n°6**

Réponse attendue

Deux techniques d'analyse sont particulièrement adaptées à ce cas. La première est l'**analyse segmentée des erreurs** : plutôt que de se fier à la MAE globale de 8%, vous décomposez les performances par période (saisonnière vs. hors saison), par catégorie de produit et par niveau de remise. Les données montrent déjà que la catégorie Fitness souffre davantage (MAE 42-45% en période de pic) que la catégorie Outdoor (31-36%), ce qui oriente le diagnostic vers des dynamiques de demande différentes selon les segments. La seconde technique est l'**analyse des courbes d'apprentissage** : l'écart croissant entre MAE d'entraînement (3%) et MAE de validation (8%) à partir de la 200^e itération signale un surapprentissage. Le modèle mémorise les patterns du jeu d'entraînement – où les pics saisonniers sont rares – au lieu de généraliser. Une troisième technique pertinente serait le **diagnostic par ablation** : supprimer ou ajouter des variables (par exemple, introduire un indicateur de période saisonnière) pour mesurer l'impact sur la performance en période de pic.

Éléments de solution

- **Analyse segmentée des erreurs** : décomposer la MAE par période temporelle, catégorie produit, et intensité promotionnelle – cette technique révèle que le problème est concentré sur les périodes saisonnières et touche plus fortement certaines catégories, ce qui exclut un défaut généralisé du modèle
- **Analyse des courbes d'apprentissage** : l'écart entraînement/validation croissant est un indicateur classique de surapprentissage – le modèle avec 500 arbres et profondeur 12 est probablement trop complexe par rapport au nombre limité d'exemples saisonniers disponibles
- **Diagnostic par ablation** : tester l'ajout de variables calendaires (indicateur saisonnier, distance au prochain événement) et le remplacement du codage binaire des promotions par le taux de remise réel, puis mesurer l'impact sur la MAE saisonnière
- **Matrices de confusion adaptées** (si le problème est reformulé en classification de niveaux de demande) : identifier si le modèle confond systématiquement les niveaux de demande « élevé » et « normal »

- **Feedback** : la justification de chaque technique doit être ancrée dans les données du cas (chiffres, indices fournis) et non générique — une bonne réponse relie explicitement la technique choisie aux symptômes observés

[exercice p. 26] **Solution n°7**

Réponse attendue

Le plan d'investigation s'articule autour de quatre hypothèses classées par ordre de probabilité décroissante. **Hypothèse 1 — Insuffisance des variables explicatives** : l'absence de variable calendaire spécifique et le codage binaire des promotions privent le modèle des signaux nécessaires pour anticiper les pics saisonniers. Vous vérifiez en priorité cette hypothèse car elle est directement observable dans la description du feature set. **Hypothèse 2 — Sous-représentation des événements saisonniers** : avec seulement 6 occurrences de chaque type d'événement sur 3 ans, le modèle manque d'exemples pour apprendre les dynamiques de pic. **Hypothèse 3 — Surapprentissage du modèle** : les courbes d'apprentissage et les hyperparamètres (500 arbres, profondeur 12) suggèrent que le modèle colle trop aux données d'entraînement, où les périodes normales dominent largement. **Hypothèse 4 — Dérive de distribution** : les comportements d'achat saisonniers ont peut-être évolué entre 2021 et 2024, rendant les patterns historiques partiellement obsolètes. L'attention se focalise sur le croisement entre les résultats des tests et les retours métier de l'équipe logistique.

Éléments de solution

- **Hypothèse 1 (variables manquantes)** — Priorité haute : vérifier l'impact de l'ajout d'un indicateur saisonnier, d'une variable de distance temporelle au prochain événement commercial, et du remplacement du codage binaire des promotions par le taux de remise réel
- **Hypothèse 2 (sous-représentation)** — Priorité haute : analyser la distribution des exemples d'entraînement par type de période, calculer le ratio périodes normales/périodes saisonnières, évaluer si un suréchantillonnage ou une pondération des exemples saisonniers améliore les résultats
- **Hypothèse 3 (surapprentissage)** — Priorité moyenne : réduire la complexité du modèle (diminuer le nombre d'arbres, limiter la profondeur), appliquer une régularisation plus forte, et comparer les courbes d'apprentissage avant/après
- **Hypothèse 4 (dérive de distribution)** — Priorité moyenne : comparer les distributions des variables clés entre les données 2021-2022 et 2023-2024, notamment les volumes de vente saisonniers et les taux de remise pratiqués
- **Ordre de vérification** : commencer par les hypothèses liées aux données (H1, H2) car elles sont les plus fréquentes et les plus rapides à valider, puis passer au modèle (H3) et enfin à la dérive (H4)
- **Feedback** : un plan d'investigation rigoureux hiérarchise les hypothèses selon leur probabilité et leur facilité de vérification, et prévoit un ordre séquentiel pour isoler l'effet de chaque facteur

[exercice p. 26] **Solution n°8**

Réponse attendue

Pour chaque hypothèse, des métriques et visualisations spécifiques permettent de trancher. Pour l'**hypothèse 1 (variables manquantes)**, vous réalisez un test d'ablation inversé : entraîner le modèle avec les nouvelles variables (indicateur saisonnier, taux de remise continu) et comparer la MAE saisonnière avant/après — une amélioration significative confirme l'hypothèse. L'**importance des variables** (feature importance du gradient boosting) permet aussi de vérifier si les variables

actuelles captent le signal saisonnier. Pour l'**hypothèse 2 (sous-représentation)**, vous visualisez la distribution temporelle des exemples d'entraînement et calculez le ratio entre exemples saisonniers et non saisonniers ; un histogramme des erreurs par densité d'exemples similaires dans le training set révèle la corrélation entre rareté et erreur. Pour l'**hypothèse 3 (surapprentissage)**, les courbes d'apprentissage segmentées par période montrent si l'écart entraînement/validation est plus marqué sur les données saisonnières. Enfin, pour l'**hypothèse 4 (dérive)**, un test statistique de comparaison de distributions (Kolmogorov-Smirnov ou PSI – Population Stability Index) entre les données d'entraînement et les données récentes quantifie objectivement la dérive.

Éléments de solution

- **H1 – Variables manquantes :**
 - Métrique : comparaison de la MAE saisonnière avant/après ajout des nouvelles variables
 - Visualisation : graphique de feature importance pour vérifier le poids des variables existantes vs. nouvelles variables
 - Intérêt : permet de quantifier directement le gain apporté par un enrichissement du feature set, action corrective la plus rapide à mettre en œuvre
- **H2 – Sous-représentation :**
 - Métrique : ratio d'exemples saisonniers/non saisonniers dans le training set (ici environ **15% vs. 85%**)
 - Visualisation : histogramme de la distribution des erreurs en fonction de la densité d'exemples similaires dans l'entraînement
 - Intérêt : confirme si le modèle manque simplement de matière pour apprendre les patterns de pic
- **H3 – Surapprentissage :**
 - Métrique : écart MAE entraînement/validation segmenté par type de période
 - Visualisation : courbes d'apprentissage superposées (globale vs. saisonnière uniquement)
 - Intérêt : un écart plus marqué sur les données saisonnières confirme que le surapprentissage touche spécifiquement ces cas rares
- **H4 – Dérive de distribution :**
 - Métrique : **PSI** (Population Stability Index) ou test de **Kolmogorov-Smirnov** entre distributions d'entraînement et de production
 - Visualisation : superposition des distributions des variables clés (volumes, prix, trafic) entre périodes d'entraînement et périodes récentes
 - Intérêt : quantifie objectivement si les comportements d'achat ont évolué au point de rendre le modèle obsolète sur certains segments
- **Feedback** : une réponse complète associe à chaque hypothèse au moins une métrique quantitative et une visualisation, en justifiant leur pertinence par rapport au contexte métier de VentaPlus (coût des ruptures de stock, enjeu sur 35% du CA annuel)