




Interprétabilité, biais et explicabilité des modèles

Table des matières

I - Contexte	3
II - Pourquoi l'interprétabilité est cruciale dans les projets IA	4
A. Enjeux éthiques et réglementaires	4
B. Interprétabilité globale et compréhension des modèles	6
III - Exploiter l'interprétabilité pour détecter les biais et améliorer les modèles	8
A. Interprétabilité locale et analyse de cas individuels	8
B. Détection des biais et actions correctives.....	10
IV - Synthèse	12
V - Auto-évaluation	15
VI - Exercice : Détecter et corriger un biais de ciblage dans un modèle de résiliation client	19
Solutions des exercices	21

I Contexte

Contexte

À l'heure où l'IA s'intègre dans des secteurs de plus en plus sensibles, l'**interprétabilité** des modèles est devenue un enjeu central, aussi bien pour la **conformité réglementaire** que pour la confiance des utilisateurs et la robustesse scientifique des projets. Les systèmes d'intelligence artificielle prennent désormais des décisions qui ont un **impact concret sur les individus**, que ce soit pour l'octroi d'un crédit, le recrutement, la médecine ou la gestion de droits sociaux. Dans ces contextes, il ne suffit plus d'obtenir une prédiction : il faut pouvoir **expliquer comment et pourquoi le modèle en est arrivé à cette décision**.

Les **attentes réglementaires** se renforcent en Europe : le RGPD garantit le droit à l'explication pour toute décision automatisée importante, et le futur **AI Act** impose de nouvelles exigences pour les systèmes classés « à *haut risque* », incluant la nécessité de rendre les modèles plus **explicables et auditables**. Les audits internes et externes, la conformité aux normes (ISO/IEC) et la documentation explicite des choix algorithmiques deviennent autant d'exigences à anticiper dès la conception.

Mais l'interprétabilité ne se limite pas à une réponse aux obligations légales. Elle s'impose comme **un atout majeur pour l'acceptabilité et la collaboration** : une IA dont les choix restent opaques expose l'entreprise à la méfiance des utilisateurs, à des blocages organisationnels et à des risques réputationnels. À l'inverse, un modèle interprétable permet de **gagner la confiance**, de faciliter le dialogue entre data scientists, métiers et parties prenantes externes, et de corriger rapidement les faiblesses détectées.

Enfin, l'**analyse explicable** est un levier pratique d'**amélioration continue** : elle rend visible les effets indésirables (« *biais cachés* »), permet de tester des hypothèses métier, de prioriser les axes de correction, et oriente la stratégie d'optimisation avec une nouvelle granularité.

Dans un monde où la robustesse, l'éthique et la responsabilité prennent de plus en plus de poids, **l'interprétabilité devient indispensable pour garantir le succès durable des projets d'IA**.

II Pourquoi l'interprétabilité est cruciale dans les projets IA

A. Enjeux éthiques et réglementaires

L'interprétabilité comme exigence juridique

Dans l'Union européenne, la question de l'**interprétabilité** des modèles d'intelligence artificielle dépasse largement la seule technique : elle relève désormais d'une **exigence juridique formelle**. Le RGPD (Règlement Général sur la Protection des Données) impose à toute organisation utilisant des décisions automatisées à fort impact d'être capable de **fournir une explication compréhensible** à toute personne concernée par la décision. Désormais, il n'est plus possible de se retrancher derrière des algorithmes « *boîte noire* » : les entreprises doivent engager une démarche proactive de **transparence** et de **justification** algorithmique.

Le futur **AI Act** va encore plus loin : il introduit une catégorisation des systèmes d'IA dits « à *haut risque* » (recrutement, crédit, santé, justice, etc.), pour lesquels **la capacité à expliquer, documenter et justifier chaque décision du modèle devient une obligation légale**. Un projet IA ne peut plus être lancé sans envisager la production d'une documentation claire, la traçabilité des variables utilisées, et la possibilité d'auditer la logique de décision à tout instant.

L'ensemble de ces évolutions transforme profondément les pratiques en entreprise. Il ne s'agit plus seulement de faire preuve de conformité en cas d'audit : l'interprétabilité devient un volet fondamental de la gestion du risque juridique et de la stratégie de transparence vis-à-vis des clients, partenaires et autorités.

En maîtrisant l'explicabilité du modèle, on se dote d'un gage de conformité et d'anticipation face aux évolutions réglementaires rapides.

Interprétabilité vs Explicabilité

Az Définition

L'**interprétabilité** est la capacité à comprendre le fonctionnement interne d'un modèle (par ex. logique de décision dans un arbre).

L'**explicabilité** est la capacité à fournir une **explication intelligible** du résultat, même pour un modèle « *boîte noire* » (par exemple via SHAP ou LIME).

Une IA peut être explicable sans être interprétable (ex : deep learning justifié par des méthodes d'explication locales).

Des attentes fortes côté utilisateurs

L'exigence d'**interprétabilité** ne vient pas uniquement du droit. Sur le terrain, de plus en plus d'utilisateurs - clients finaux, agents terrain, managers métier - réclament une **compréhension des décisions prises par les systèmes IA**. Cette aspiration à la clarté est particulièrement forte dans les domaines sensibles comme la santé (diagnostic automatisé), le crédit (acceptation/refus), la gestion RH (recrutement, promotion), ou encore la justice (analyse des risques de récidive).

Un système jugé opaque peut nourrir des **sentiments d'injustice, de défiance voire de rejet complet de l'outil**. Par contraste, un modèle dont les logiques sont expliquées de manière compréhensible suscite la **confiance**, ouvre le dialogue entre data scientists et métiers, et facilite l'intégration concrète dans les usages quotidiens. Par exemple, une équipe RH pouvant expliquer précisément pour quelles raisons un candidat a été retenu ou non sera plus sereine face à une contestation, tout en renforçant l'adoption de l'IA comme outil d'aide à la décision plutôt que comme substitut désincarné.

L'interprétabilité permet aussi à l'utilisateur de corriger des incompréhensions sur le fonctionnement des systèmes, d'ajuster sa pratique (ex : compléter un dossier, améliorer la collecte de données) et d'alerter sur des situations d'abus ou d'erreur que la simple analyse statistique ne permettrait pas de repérer.

La transparence algorithmique devient ainsi le socle de l'acceptabilité sociale et opérationnelle de l'IA en entreprise.

Refus de crédit opaque

 Exemple

En France, certains établissements bancaires ont vu se multiplier les réclamations de clients suite à des refus de crédit sans justification compréhensible. En rendant explicites les variables déterminantes (revenus, dettes, historique), ces banques ont restauré la confiance et réduit les litiges.

Valoriser la transparence auprès des utilisateurs

 Conseil

Ne limitez pas l'interprétabilité à un dossier juridique destiné aux auditeurs : faites-en un argument pédagogique et de confiance envers les utilisateurs, en organisant des séances d'explication, des ateliers « *démos* » et des documents synthétiques sur « *Comment fonctionne notre IA ?* » adaptés au niveau métier.

Une opportunité d'amélioration continue

Aborder l'**interprétabilité** sous l'angle du simple respect réglementaire serait passer à côté de sa plus grande utilité : celle d'un **puissant levier d'amélioration continue**. En rendant leurs règles de décisions tangibles et contrôlables, les modèles d'IA offrent aux équipes techniques la possibilité de repérer et de **corriger rapidement des effets indésirables** : corrélations parasites, effets de seuils non souhaités, biais hérités de l'histoire des données, etc.

Cette démarche de transparence permet une collaboration enrichie entre métiers et data scientists : lorsque les résultats du modèle sont discutés sur la base de visualisations simples (importance des variables, règles extraites, graphes de dépendance), les équipes peuvent pointer des incohérences, proposer des correctifs ciblés et contribuer réellement à la maturation du projet IA.

La documentation régulière des zones d'ombre, faiblesses ou biais alimente un processus d'**amélioration itératif**, qui s'appuie sur l'analyse permanente de la qualité des décisions et des usages, et qui renforce à terme la robustesse, la valeur business et l'adoption du modèle par le terrain.

En résumé, l'interprétabilité s'impose comme un outil d'audit continu, de remédiation rapide et de diffusion de la culture data dans toute l'organisation.

Le risque d'une interprétation trop simplifiée

 Attention

Attention à ne pas **sur-simplifier** l'explication d'un modèle complexe en la réduisant à une règle unique (« *on refuse les moins de 25 ans* »). Une explication partielle ou caricaturale peut être **plus dangereuse qu'une absence d'explication**, en induisant en erreur usagers et régulateurs.

Interprétabilité et conformité : obligations et bonnes pratiques

B. Interprétabilité globale et compréhension des modèles

Mesurer l'influence moyenne des variables

L'**interprétabilité globale** a pour objectif de fournir une vue d'ensemble fiable du fonctionnement d'un modèle, indépendamment des cas particuliers. Elle permet de répondre à des questions majeures : « *Quels paramètres décident le plus du résultat ?* », « *Le modèle fonctionne-t-il de manière cohérente avec l'expertise métier ?* ».

Les outils fondamentaux sont la **feature importance** (importance moyenne d'une variable, obtenue par permutation ou par le gain de critères dans certains modèles comme les arbres) et l'analyse de l'importance des variables sur la totalité du dataset.

Dans la pratique, ces outils révèlent rapidement si le modèle s'appuie sur des facteurs logiques (âge, salaire, historique, etc.) ou si, à l'inverse, une variable inattendue ou absurde influence trop le résultat (corrélation parasite, fuite de donnée).

Des vérifications régulières des listes de variables importantes, croisées avec l'expertise métier, constituent une véritable **alerte automatique sur les décalages et les risques de dérive**.

En assurance comme en logistique, cette analyse permet par exemple de mettre en évidence qu'une variable comme la météo ou la localisation pèse anormalement lourd, ce qui questionne l'équité et la fiabilité de la modélisation.

Feature Importance vs Feature Attribution

Az Définition

La **Feature Importance** est la mesure de l'influence moyenne d'une variable sur toutes les prédictions.

La **Feature Attribution** est la contribution d'une variable **dans un cas particulier** (locale).

L'un donne une **vue synthétique**, l'autre une **explication individuelle**.


Visualiser les effets des variables

Au-delà de l'importance globale, il est fondamental de **visualiser l'effet précis de chaque variable sur la prédiction** : les méthodes de graphiques de dépendance partielle (PDP - Partial Dependence Plot) ou les courbes ICE (Individual Conditional Expectation) permettent de « *découper* » la relation : est-elle linéaire, montre-t-elle des seuils, des paliers critiques ou des inversions inattendues ?

Dans la banque par exemple, un PDP peut révéler que la probabilité d'octroi d'un crédit chute brusquement à partir d'un certain ratio d'endettement, ce que les analystes métier pourront confirmer, etc., ou contester, si cela n'a pas de sens au regard de la politique commerciale réelle.

Ces visualisations servent non seulement à détecter d'éventuels comportements aberrants, mais aussi à rassurer les parties prenantes en montrant que « *le modèle se comporte bien* » dans les zones connus, tout en signalant les cas hors zone.

Image



Importance des variables dans la logistique

👁 Exemple

Dans une entreprise logistique, l'analyse des « *feature importance* » a révélé que la météo locale avait davantage d'impact sur les retards de livraison que la densité de circulation habituelle. Cette découverte inattendue a amené l'équipe métier à retravailler la collecte de données météo en temps réel et à développer de nouvelles stratégies préventives pour les pics d'intempéries.

Extraire des règles simples et compréhensibles

Même pour des modèles *a priori* complexes, il est possible pour les équipes data d'**extraire ou reconstituer des règles métier** simplifiées, que l'on puisse expliquer et vérifier collectivement. Les arbres de décision en sont l'exemple emblématique : ils transforment des calculs compliqués en suites de conditions qui peuvent être discutées avec les métiers, modifiées, priorisées et auditées.

Pour les modèles de type « *boîte noire* », des techniques permettent d'**approximer le fonctionnement global** à l'aide d'arbres simplifiés (« *surrogate models* »), qui facilitent l'explication lors d'un audit, la formation des utilisateurs ou la documentation à destination des régulateurs.

Croiser toujours avec les experts métier

👤 Conseil

Une règle **logique pour l'IA** n'est pas toujours **pertinente pour le métier**. Par exemple, un seuil technique détecté par PDP peut sembler arbitraire pour un conseiller financier. La validation métier est incontournable pour éviter les optimisations déconnectées de la réalité.

III Exploiter l'interprétabilité pour détecter les biais et améliorer les modèles

A. Interprétabilité locale et analyse de cas individuels

Expliquer une prédiction précise

La capacité à **expliquer en détail chaque prédiction** produite par un modèle d'intelligence artificielle est devenue un impératif, non seulement pour rassurer les utilisateurs mais aussi pour respecter les obligations réglementaires. L'**interprétabilité locale** vise à éclairer, pour un cas donné, les mécanismes qui ont guidé la décision de l'algorithme. Cette approche est particulièrement précieuse dès lors que le modèle est utilisé dans des secteurs à fort enjeu (santé, crédit, assurance, emploi, etc.) ou en présence d'utilisateurs souhaitant comprendre les raisons d'un refus, d'un score ou d'une recommandation.

Concrètement, cela signifie qu'il est possible de répondre à la question : « *Pourquoi ma demande a-t-elle été rejetée ?* » ou « *Sur quels critères le modèle a-t-il basé ce calcul ?* » grâce à des outils qui attribuent à chaque variable une contribution explicite dans le résultat. Au-delà de l'aspect réglementaire, cette transparence locale est déterminante pour identifier des anomalies, comprendre des erreurs spectaculaires ou pour investiguer les points singuliers révélés lors de la validation : on peut ainsi détecter si le modèle s'appuie trop sur une variable peu pertinente, ou s'il est sensible à des modifications mineures d'un paramètre dans des situations concrètes.

Dans la pratique d'un projet IA en entreprise, l'analyse locale complète l'interprétabilité globale : elle permet de passer du tableau d'ensemble au diagnostic individuel, ce qui est crucial dans la gestion des risques, l'explication aux clients, et la détection des dérives ou des injustices spécifiques.

Assurance santé - refus litigieux

[👁 Exemple](#)

Un modèle de résiliation santé désignait systématiquement les jeunes clients. Grâce à SHAP, on a montré que **l'âge contribuait excessivement** à la prédiction, révélant un biais issu de données historiques déséquilibrées.

SHAP et LIME : deux approches complémentaires

Pour rendre l'interprétabilité locale vraiment opérationnelle, les équipes IA s'appuient aujourd'hui sur des outils comme **SHAP** et **LIME**. Ces deux méthodes ont révolutionné la façon d'expliquer les décisions des modèles complexes.

SHAP (SHapley Additive exPlanations) propose une approche inspirée de la théorie des jeux, où chaque variable d'entrée se voit attribuer une valeur représentant sa contribution précise à la prédiction finale. Cela donne une explication cohérente, stable et complète pour chaque prédiction : chaque facteur (âge, revenu, historique, etc.) est pondéré en fonction de son impact sur le risque calculé ou la recommandation produite. Cette granularité permet de comprendre si, dans un cas individuel, la décision repose sur des critères logiques et attendus ou si, au contraire, elle est expliquée par des combinaisons atypiques de variables.

LIME (Local Interpretable Model-agnostic Explanations) fonctionne en construisant un modèle local simplifié (par exemple, une régression linéaire) autour du cas étudié, en perturbant légèrement les entrées pour voir comment la prédiction change. Cela permet d'identifier rapidement les variables qui, au voisinage du cas cible, pilotent le plus fort la décision. L'avantage

de LIME est sa rapidité et sa capacité à s'adapter à tous types de modèles, même sans connaissance précise de leur architecture interne. Cependant, il peut manquer parfois de stabilité si les frontières de décision globales sont très complexes.

En entreprise, l'usage de ces deux outils permet d'explicitier des décisions controversées, de justifier un refus de dossier, de répondre à un contrôle métier ou réglementaire, ou encore de détecter la naissance d'un biais au niveau d'un segment de population précis.

En combinant SHAP et LIME, on peut d'une part obtenir une explication détaillée et robuste, d'autre part gagner en rapidité pour des analyses ponctuelles, tout en gardant la capacité à travailler sur tous les types de modèles, y compris les « *boîtes noires* ».

Carte de saillance

Az Définition

Une **carte de saillance** est une technique visuelle utilisée principalement dans le domaine de la vision par ordinateur. Elle permet de représenter de façon intuitive, sur une image, les zones qui ont eu le plus de poids dans la prise de décision du modèle : ainsi, on voit immédiatement où l'attention du modèle s'est portée. Cette visualisation est précieuse en santé : on vérifie par exemple qu'un algorithme de détection de tumeurs réagit bien sur la lésion visée, et non sur des éléments de décor, de bruit ou d'annotations involontaires.


Cartes de saillance pour les modèles d'images

Pour les modèles de vision par ordinateur (détection d'objets, reconnaissance de pathologies, analyse d'images médicales, etc.), comprendre le raisonnement du modèle exige une traduction visuelle : c'est là tout l'intérêt des **cartes de saillance** ou d'activation. Ces cartes donnent à voir les pixels ou les régions de l'image qui ont déterminé la prédiction. Grâce à elles, l'équipe projet peut repérer rapidement si le modèle est robuste : s'il se concentre sur les éléments pertinents, comme la surface d'une tumeur ou la silhouette d'un objet, ou s'il est biaisé par des détails inutiles du fond, des artefacts dus à la numérisation ou à la qualité d'éclairage.

En analysant systématiquement ces cartes sur des échantillons d'images variés, il est possible de détecter des faiblesses invisibles dans les statistiques globales : un modèle qui « *fonctionne* » en laboratoire mais qui se trompe dans des contextes réels inhabituels, ou qui se révèle moins robuste pour un équipement de numérisation spécifique, par exemple.

Les cartes de saillance sont donc un outil clé de la validation et de la robustesse des modèles d'IA dans la vision.

Image



B. Détection des biais et actions correctives

Identifier les biais par groupe

L'un des apports majeurs de l'analyse explicable est la possibilité de **détecter des biais structurels dans un modèle là où les statistiques globales peuvent masquer les inégalités**. En réalisant une analyse des explications (par SHAP/LIME ou d'autres outils) **segmentée** par critère (âge, genre, statut social, localisation, etc.), on peut révéler des tendances préoccupantes : par exemple, le fait que la contribution d'une variable soit systématiquement très forte (ou très faible) pour un groupe particulier, entraînant une surreprésentation des alertes ou des refus dans ce groupe.

C'est cette granularité qui permet d'aller au-delà de simples tests d'équité arithmétiques. On voit alors, preuve visuelle à l'appui, qu'un modèle favorise ou exclut inconsciemment un segment, souvent pour des raisons de sous-représentation dans les données d'entraînement, de corrélations parasites ou de variables « *proxy* » cachées.

En entreprise, cet usage de l'explicabilité s'impose désormais comme la meilleure pratique en audit interne, préparation réglementaire ou amélioration de l'acceptabilité sociale et commerciale des modèles.

Variable « *proxy* »

Az Définition

Une **variable proxy** est une variable en apparence neutre mais qui reflète indirectement un facteur sensible (par exemple le code postal utilisé comme proxy de l'origine ethnique). Ces proxies créent des biais invisibles si l'on n'y prête pas attention.

Valider ou infirmer les hypothèses métiers


Grâce à l'interprétabilité, il devient possible de confronter **les hypothèses ou attentes métiers** à la réalité du fonctionnement du modèle.

Si une variable jugée « *centrale* » par les experts terrain ne ressort pas comme importante localement ou globalement, cela signe soit une faiblesse dans la collecte/codage de la variable, soit une mauvaise intégration métier au moment de la conception.

À l'inverse, un paramètre jugé accessoire peut devenir le critère dominant pour un segment de client, révélant un contournement (« *proxy* ») ou un biais dans l'historique des décisions humaines.

Cette boucle d'ajustement entre « *ce que le modèle fait* » et « *ce que les métiers attendaient qu'il fasse* » permet de renforcer **la cohérence, la pertinence et la robustesse** du système et de s'assurer qu'aucune variable clé n'a été oubliée ou sous-exploitée.

Prolonger l'analyse explicable par des ateliers collaboratifs



Pour véritablement progresser, il est recommandé de partager les résultats d'analyses explicables dans des ateliers ou revues mêlant data scientists, experts métier, qualité, conformité et parfois usagers. Cet échange de regards croisés permet de décider en connaissance de cause des actions à prioriser (ajout/modification de variables, segmentation de modèles, rééchantillonnage de la donnée, etc.).

Définir une stratégie d'optimisation

L'explicabilité ne s'arrête pas à la détection des biais ou faiblesses : elle doit guider la mise en place d'un **plan correctif précis et justifié**. Cela implique de :

- Prioriser les variables à corriger, à supprimer ou à transformer,
- Mettre en œuvre des techniques d'équilibrage du dataset si certains groupes sont sous-représentés,
- Proposer la segmentation des modèles, la création de règles explicites ou la documentation de ces limites à suivre dans le temps,
- Proposer aux métiers de valider, par des expériences ou simulations, que la solution retenue corrige réellement le souci constaté sans en générer de nouveaux.

Ce cycle explicabilité → correctif → validation s'inscrit dans une démarche d'**amélioration continue** des modèles.

Justice prédictive



Dans certains logiciels d'évaluation du risque de récidive aux États-Unis, des biais de discrimination ont été détectés grâce aux analyses SHAP. Les correctifs appliqués ont inclus la suppression de certaines variables sensibles (lieu de résidence) et l'ajout de mécanismes de pondération équitable.

IV Synthèse

A. Flashcards

Interprétabilité

Capacité à comprendre le fonctionnement interne d'un modèle d'IA et sa logique de décision.

Explicabilité

Capacité à fournir une explication intelligible du résultat, même pour un modèle boîte noire.

RGPD et IA

Règlement imposant le droit à l'explication pour toute décision automatisée à fort impact.

AI Act

Futur règlement européen imposant explicabilité et auditabilité pour systèmes IA à haut risque.

Feature Importance

Mesure de l'influence moyenne d'une variable sur l'ensemble des prédictions du modèle.

PDP

Graphique de dépendance partielle visualisant l'effet précis d'une variable sur la prédiction.

SHAP

Méthode attribuant à chaque variable sa contribution précise dans une prédiction donnée.

LIME

Outil construisant un modèle local simplifié pour expliquer une prédiction individuelle rapidement.

Carte de saillance

Visualisation des zones d'une image ayant le plus influencé la décision du modèle.

Variable proxy

Variable neutre en apparence mais reflétant indirectement un facteur sensible ou discriminant.

Interprétabilité globale

Vue d'ensemble du fonctionnement du modèle, indépendamment des cas particuliers analysés.

Interprétabilité locale

Explication détaillée d'une prédiction précise pour un cas individuel donné.

Biais structurel

Inégalité systématique dans les prédictions d'un modèle affectant un groupe spécifique.

Surrogate model


Modèle simplifié approximant le fonctionnement d'un modèle complexe pour faciliter l'explication.

La théorie en Bref

💡 Fondamental

L'**interprétabilité** désigne la capacité à comprendre le fonctionnement interne d'un modèle d'IA, tandis que l'**explicabilité** permet de fournir une explication intelligible du résultat, même pour un modèle boîte noire. Face aux exigences du **RGPD** et du futur **AI Act**, l'interprétabilité devient une obligation juridique pour les systèmes à haut risque, garantissant le droit à l'explication des décisions automatisées. Elle se décline en **interprétabilité globale**, qui mesure l'influence moyenne des variables via la **feature importance** et les **PDP**, et en


interprétabilité locale, qui explique chaque prédiction grâce à des outils comme **SHAP** et **LIME**. Au-delà de la conformité, l'explicabilité permet de détecter les **biais structurels**, de valider les hypothèses métier et d'engager une amélioration continue des modèles IA.



1. RGPD, AI Act, droit à l'explication, systèmes à haut risque.
2. Acceptabilité sociale, dialogue métier, réduction de la défiance.
3. Détection d'effets indésirables, correction rapide, robustesse.
4. Influence moyenne d'une variable sur toutes les prédictions.
5. Visualisation de l'effet précis des variables, détection de seuils.
6. Extraction de règles simples, arbres de décision, surrogate models.
7. Contribution précise de chaque variable par prédiction, théorie des jeux.
8. Modèle local simplifié autour du cas étudié, rapide et agnostique.
9. Visualisation des zones d'attention dans les modèles d'images.
10. Identification des biais par groupe, variables proxy, inégalités cachées.
11. Confrontation hypothèses métier vs fonctionnement réel du modèle.
12. Rééquilibrage, segmentation, suppression de variables, documentation.

Interprétabilité des modèles IA

Les conseils pro



Comment choisir entre SHAP et LIME pour expliquer une prédiction individuelle ?

- Utiliser SHAP pour des explications robustes, cohérentes et complètes sur tous types de modèles.
- Privilégier LIME pour des analyses ponctuelles rapides ou des modèles très complexes.
- Combiner les deux outils pour croiser les résultats et renforcer la fiabilité de l'explication.
- Vérifier la stabilité des explications en testant plusieurs perturbations ou échantillons voisins.

Comment détecter efficacement les biais dans un modèle IA en production ?

- Segmenter les analyses explicables par critère sensible : âge, genre, localisation, statut social.
- Comparer les contributions des variables entre groupes pour repérer les surpondérations anormales.

- Auditer régulièrement les prédictions sur des échantillons représentatifs de chaque segment.
- Documenter les biais détectés et tracer les actions correctives dans un registre de conformité.

Comment intégrer l'interprétabilité dès la phase de conception d'un projet IA ?

- Définir les exigences d'explicabilité en amont avec les métiers, conformité et utilisateurs finaux.
- Privilégier des modèles intrinsèquement interprétables si le contexte réglementaire l'impose.
- Prévoir dès le départ les outils d'analyse globale et locale dans le pipeline de validation.
- Organiser des ateliers collaboratifs réguliers pour confronter hypothèses métier et résultats explicables.

Comment communiquer les résultats d'une analyse explicable à des parties prenantes non techniques ?

- Traduire les contributions des variables en langage métier, éviter le jargon technique.
- Utiliser des visualisations simples : graphiques PDP, cartes de saillance, diagrammes de contribution.
- Préparer des synthèses courtes avec exemples concrets et cas d'usage réels du terrain.
- Organiser des sessions de démonstration interactives pour répondre aux questions en direct.

Comment corriger un biais détecté sans dégrader la performance globale du modèle ?

- Identifier la ou les variables responsables du biais via l'analyse segmentée des contributions.
- Tester la suppression ou la transformation de ces variables sur un échantillon de validation.
- Rééquilibrer le dataset d'entraînement si un groupe est sous-représenté ou surpondéré.
- Valider l'impact des correctifs sur la performance métier et l'équité avant déploiement en production.

V Auto-évaluation

Exercice 1 : Interprétabilité et explicabilité : fondements

[solution n°1 p. 21]

Exercice

Un modèle de deep learning peut être considéré comme explicable même s'il n'est pas interprétable, à condition d'utiliser des méthodes d'explication locales comme SHAP ou LIME.

Vrai

Faux

Exercice

Dans le cadre du RGPD, quelle obligation s'impose aux organisations qui utilisent des décisions automatisées à fort impact sur les individus ?

Fournir une explication compréhensible à toute personne concernée par la décision

Publier l'intégralité du code source de leurs algorithmes

Obtenir systématiquement le consentement explicite avant toute prédiction

Remplacer les modèles complexes par des arbres de décision simples

Exercice

Parmi les propositions suivantes, lesquelles correspondent à des bénéfices concrets de l'interprétabilité des modèles IA en entreprise ?

A Détecter des biais cachés dans les données d'entraînement

B Garantir automatiquement une performance maximale du modèle

C Faciliter le dialogue entre data scientists et équipes métier

D Permettre une amélioration continue par identification des faiblesses du modèle

E Éliminer tout risque de décision erronée du modèle

Exercice

Associez chaque concept à sa définition correcte.

A Surrogate model**B** Variable proxy**C** Feature Attribution**D** Feature Importance

Mesure de l'influence moyenne d'une variable sur l'ensemble des prédictions du modèle	Contribution d'une variable à une prédiction spécifique et individuelle	Variable en apparence neutre qui reflète indirectement un facteur sensible	Modèle simplifié construit pour approximer le fonctionnement global d'un modèle complexe
---	---	--	--

Exercice 6 : Interprétabilité globale et visualisation

[solution n°2 p. 22]

Exercice

Un graphique de dépendance partielle (PDP) permet uniquement de confirmer que le modèle se comporte comme prévu, mais ne peut pas révéler des seuils ou des inversions inattendues dans la relation entre une variable et la prédiction.

Vrai

Faux

Exercice

Lors de l'analyse de la feature importance d'un modèle logistique de prédiction de retards de livraison, vous constatez que la variable « météo locale » pèse davantage que la densité de circulation. Quelle est la première action à entreprendre ?

Supprimer immédiatement la variable météo du modèle car elle semble incohérente

Croiser ce résultat avec les experts métier pour valider ou questionner sa pertinence

Conclure que le modèle est biaisé et le rejeter sans autre analyse

Remplacer la variable météo par une variable proxy plus neutre

Exercice

Quels outils ou méthodes relèvent de l'interprétabilité globale d'un modèle ?

A La feature importance par permutation**B** Les graphiques de dépendance partielle (PDP)**C** Les valeurs SHAP appliquées à un cas individuel

D Les courbes ICE (Individual Conditional Expectation)

E Les surrogate models (arbres de décision simplifiés)

Exercice 10 : SHAP, LIME et interprétabilité locale

[solution n°3 p. 24]

Exercice

Comment LIME produit-il une explication locale pour une prédiction donnée ?

En calculant la contribution de chaque variable à partir de la théorie des jeux coopératifs

En construisant un modèle simplifié autour du cas étudié en perturbant légèrement les entrées

En générant une carte de saillance sur les pixels les plus influents de l'image

En extrayant les règles de décision de l'arbre de décision sous-jacent au modèle

Exercice

Associez chaque caractéristique à la méthode d'explicabilité locale à laquelle elle correspond.

A Construit un modèle simplifié en perturbant les entrées autour du cas cible

B S'inspire de la théorie des jeux pour attribuer une contribution à chaque variable

C Peut manquer de stabilité lorsque les frontières de décision globales sont très complexes

D Fournit des explications cohérentes, stables et complètes pour chaque prédiction

SHAP	LIME	SHAP	LIME

Exercice

Remettez dans le bon ordre les étapes d'une démarche d'analyse et de correction d'un biais détecté grâce à l'interprétabilité locale (SHAP).

A Valider avec les experts métier que la correction ne génère pas de nouveaux problèmes

B Appliquer SHAP pour analyser la contribution de chaque variable sur les cas du groupe concerné

C Définir un plan correctif : suppression, transformation de variable ou rééchantillonnage des données

D Identifier la ou les variables responsables du biais (variable directe ou proxy)

E Constater une anomalie dans les prédictions (ex. : surreprésentation d'un groupe dans les alertes)

Réponse : ____

VI Exercice : Détecter et corriger un biais de ciblage dans un modèle de résiliation client

Mise en situation professionnelle

Vous êtes data scientist au sein de la direction Data & IA d'une mutuelle santé française, **MutualVie**, qui compte **420 000 adhérents** sur l'ensemble du territoire. Votre équipe a déployé il y a six mois un modèle de machine learning (gradient boosting) destiné à prédire le **risque de résiliation** des adhérents, afin d'alimenter les campagnes de fidélisation pilotées par la direction marketing.

Les performances globales du modèle sont jugées satisfaisantes :

Indicateur	Valeur
AUC-ROC	0.83
Précision globale	78 %
Rappel global	72 %
Volume d'alertes mensuelles	3 200 adhérents

Cependant, lors d'une revue trimestrielle, la responsable marketing, Nadia Ferreira, soulève un problème préoccupant : **62 % des alertes de risque de résiliation concernent des adhérents de moins de 30 ans**, alors que cette tranche d'âge ne représente que **18 % du portefeuille**. Les campagnes de fidélisation ciblées sur ce segment affichent un taux de conversion très faible (**4 %**, contre **15 %** en moyenne sur les autres segments), ce qui génère des coûts inutiles et une perte de confiance de l'équipe commerciale envers le modèle.

Par ailleurs, le service conformité rappelle que le **RGPD** impose la capacité à expliquer toute décision automatisée ayant un impact significatif sur les adhérents, et que la mutuelle doit se préparer aux exigences du futur **AI Act** pour les systèmes classés à haut risque.

Voici les **variables principales** utilisées par le modèle :

Variable	Description
Âge	Âge de l'adhérent
Ancienneté contrat	Durée depuis la souscription
Nombre de sinistres (12 mois)	Sinistres déclarés sur l'année
Montant cotisation mensuelle	Prime mensuelle payée
Canal de souscription	Agence, en ligne, courtier
Nombre d'interactions SAV	Appels, mails, réclamations
Code postal	Localisation géographique
Type de garantie	Formule basique, intermédiaire, premium

Lors d'une première analyse exploratoire, vous constatez que :

- Les moins de 30 ans souscrivent majoritairement **en ligne** et choisissent la **formule basique**
- Leur **ancienneté contrat** est naturellement plus faible
- Le **nombre d'interactions SAV** est plus élevé dans cette tranche (questions sur les remboursements, changements de formule)

Nadia Ferreira vous demande un diagnostic complet et des recommandations actionnables pour la prochaine réunion du comité data, prévue dans deux semaines.

Ressources à votre disposition

Pour mener votre analyse, vous disposez des éléments suivants :

- Accès aux bibliothèques **SHAP** et **LIME** déjà configurées dans l'environnement de travail
- Jeu de données d'entraînement et de test complet (avec les variables listées ci-dessus)
- Possibilité de générer des **graphiques de dépendance partielle (PDP)** et des **courbes ICE**
- Résultats de feature importance globale déjà calculés par permutation :

Rang	Variable	Importance (permutation)
1	Ancienneté contrat	0.31
2	Âge	0.24
3	Nombre d'interactions SAV	0.16
4	Canal de souscription	0.12
5	Montant cotisation mensuelle	0.08
6	Type de garantie	0.05
7	Nombre de sinistres	0.03
8	Code postal	0.01

Vous remarquez que les trois premières variables (ancienneté, âge, interactions SAV) cumulent **71 %** de l'importance totale.

Question 1

[solution n°4 p. 25]

Sélectionnez et justifiez les techniques d'interprétabilité (globale et/ou locale) les plus pertinentes pour comprendre pourquoi le modèle cible de manière disproportionnée les moins de 30 ans. Précisez ce que chaque technique vous permettra d'observer concrètement.

Question 2

[solution n°5 p. 26]

À partir des données fournies et des résultats de feature importance, identifiez si le ciblage excessif des moins de 30 ans provient d'une variable isolée ou d'une combinaison de facteurs. Argumentez votre diagnostic en vous appuyant sur les éléments du contexte.

Question 3

[solution n°6 p. 27]

Proposez des pistes d'actions concrètes pour corriger ce biais, en distinguant les interventions sur les données, sur le modèle et sur les usages métier. Justifiez la pertinence de chaque action.

Question 4

[solution n°7 p. 27]

Rédigez une synthèse claire et structurée des biais détectés et des solutions envisagées, destinée à l'équipe marketing de MutualVie lors du prochain comité data. Cette synthèse doit être compréhensible par des interlocuteurs non techniques.

Solutions des exercices

Solution n°1

[exercice p. 15]

Exercice

Un modèle de deep learning peut être considéré comme explicable même s'il n'est pas interprétable, à condition d'utiliser des méthodes d'explication locales comme SHAP ou LIME.

✓ Vrai

Faux



L'interprétabilité et l'explicabilité sont deux notions distinctes. L'interprétabilité désigne la capacité à comprendre le fonctionnement interne du modèle (par exemple, la logique d'un arbre de décision). L'explicabilité, elle, désigne la capacité à fournir une explication intelligible du résultat, même pour un modèle opaque. Un modèle de deep learning reste une boîte noire sur le plan interne, mais des outils comme SHAP ou LIME permettent d'en expliquer les prédictions au cas par cas. L'explicabilité sans interprétabilité est donc tout à fait possible.

Exercice

Dans le cadre du RGPD, quelle obligation s'impose aux organisations qui utilisent des décisions automatisées à fort impact sur les individus ?

✓ Fournir une explication compréhensible à toute personne concernée par la décision

Publier l'intégralité du code source de leurs algorithmes

Obtenir systématiquement le consentement explicite avant toute prédiction

Remplacer les modèles complexes par des arbres de décision simples



Le RGPD impose aux organisations d'être capables de fournir une explication compréhensible à toute personne concernée par une décision automatisée à fort impact. Il ne s'agit pas de publier le code source, ni d'imposer un type de modèle particulier. L'obligation de consentement existe dans d'autres contextes du RGPD, mais ce n'est pas la réponse à l'exigence d'explicabilité des décisions automatisées. L'enjeu est bien la transparence et la justification algorithmique, pas la divulgation technique intégrale.

Exercice

Parmi les propositions suivantes, lesquelles correspondent à des bénéfices concrets de l'interprétabilité des modèles IA en entreprise ?

- A** Détecter des biais cachés dans les données d'entraînement
- B** Garantir automatiquement une performance maximale du modèle
- C** Faciliter le dialogue entre data scientists et équipes métier
- D** Permettre une amélioration continue par identification des faiblesses du modèle
- E** Éliminer tout risque de décision erronée du modèle

🔍 L'interprétabilité permet effectivement de détecter des biais cachés (corrélations parasites, variables proxy, etc.), de faciliter la collaboration entre data scientists et métiers grâce à des visualisations accessibles, et d'alimenter un processus d'amélioration continue. En revanche, elle ne garantit pas une performance maximale : un modèle peut être très interprétable mais peu performant, et inversement. Elle ne supprime pas non plus tout risque d'erreur — elle aide à les identifier et à les corriger, mais ne les élimine pas structurellement.

Exercice

Associez chaque concept à sa définition correcte.

Mesure de l'influence moyenne d'une variable sur l'ensemble des prédictions du modèle	Contribution d'une variable à une prédiction spécifique et individuelle	Variable en apparence neutre qui reflète indirectement un facteur sensible	Modèle simplifié construit pour approximer le fonctionnement global d'un modèle complexe
Feature Importance	Feature Attribution	Variable proxy	Surrogate model

🔍 La Feature Importance donne une vue synthétique du poids moyen de chaque variable sur l'ensemble du dataset, tandis que la Feature Attribution s'applique à un cas particulier (approche locale). Une variable proxy est dangereuse car elle introduit un biais indirect : par exemple, le code postal peut refléter l'origine ethnique sans que cela soit explicite. Enfin, un surrogate model est un modèle simplifié (souvent un arbre de décision) construit pour imiter le comportement d'un modèle boîte noire, afin de le rendre auditable et explicable.

Solution n°2

[exercice p. 16]

Exercice

Un graphique de dépendance partielle (PDP) permet uniquement de confirmer que le modèle se comporte comme prévu, mais ne peut pas révéler des seuils ou des inversions inattendues dans la relation entre une variable et la prédiction.

Vrai

✓ Faux

🔍 Cette affirmation est fausse. Le PDP (Partial Dependence Plot) sert précisément à visualiser l'effet précis d'une variable sur la prédiction, y compris des comportements non linéaires : seuils brusques, paliers critiques, inversions inattendues. Dans l'exemple bancaire de la leçon, un PDP peut révéler que la probabilité d'octroi d'un crédit chute brusquement à partir d'un certain ratio d'endettement. Le PDP est donc autant un outil de détection d'anomalies que de confirmation de cohérence.

Exercice

Lors de l'analyse de la feature importance d'un modèle logistique de prédiction de retards de livraison, vous constatez que la variable « météo locale » pèse davantage que la densité de circulation. Quelle est la première action à entreprendre ?

Supprimer immédiatement la variable météo du modèle car elle semble incohérente

✓ Croiser ce résultat avec les experts métier pour valider ou questionner sa pertinence

Conclure que le modèle est biaisé et le rejeter sans autre analyse

Remplacer la variable météo par une variable proxy plus neutre

🔍 Une variable inattendue dans le classement des importances ne doit pas être supprimée ou rejetée d'emblée. La bonne pratique consiste à croiser ce résultat avec les experts métier : dans l'exemple de la leçon, la météo locale s'est révélée effectivement déterminante pour les retards, ce qui a conduit à améliorer la collecte de données météo en temps réel. Supprimer la variable sans validation métier serait une erreur, tout comme conclure hâtivement à un biais. L'interprétabilité globale est un point de départ pour le dialogue, pas une conclusion automatique.

Exercice

Quels outils ou méthodes relèvent de l'interprétabilité globale d'un modèle ?

A La feature importance par permutation

B Les graphiques de dépendance partielle (PDP)

C Les valeurs SHAP appliquées à un cas individuel

D Les courbes ICE (Individual Conditional Expectation)

E

Les surrogate models (arbres de décision simplifiés)



La feature importance par permutation, les PDP, les courbes ICE et les surrogate models sont tous des outils d'interprétabilité globale : ils donnent une vue d'ensemble du comportement du modèle sur l'ensemble du dataset. En revanche, les valeurs SHAP appliquées à un cas individuel relèvent de l'interprétabilité locale : elles expliquent une prédiction spécifique, pas le fonctionnement général du modèle. La distinction global/local est fondamentale pour choisir le bon outil selon l'objectif d'analyse.

Solution n°3

[exercice p. 17]

Exercice

Comment LIME produit-il une explication locale pour une prédiction donnée ?

En calculant la contribution de chaque variable à partir de la théorie des jeux coopératifs

✓ En construisant un modèle simplifié autour du cas étudié en perturbant légèrement les entrées

En générant une carte de saillance sur les pixels les plus influents de l'image

En extrayant les règles de décision de l'arbre de décision sous-jacent au modèle



LIME (Local Interpretable Model-agnostic Explanations) fonctionne en perturbant légèrement les valeurs d'entrée autour du cas étudié, puis en construisant un modèle local simplifié (par exemple une régression linéaire) pour identifier les variables qui influencent le plus la prédiction dans ce voisinage. C'est l'approche de SHAP qui s'inspire de la théorie des jeux coopératifs. Les cartes de saillance concernent les modèles de vision par ordinateur. L'extraction de règles d'arbres est une technique d'interprétabilité globale distincte.

Exercice

Associez chaque caractéristique à la méthode d'explicabilité locale à laquelle elle correspond.

SHAP	LIME	SHAP	LIME
S'inspire de la théorie des jeux pour attribuer une contribution à chaque variable	Construit un modèle simplifié en perturbant les entrées autour du cas cible	Fournit des explications cohérentes, stables et complètes pour chaque prédiction	Peut manquer de stabilité lorsque les frontières de décision globales sont très complexes

Q SHAP s'appuie sur la théorie des jeux coopératifs (valeurs de Shapley) pour attribuer à chaque variable une contribution précise et cohérente à la prédiction finale. Ses explications sont réputées stables et complètes. LIME, de son côté, construit un modèle local simplifié en perturbant les entrées, ce qui le rend rapide et agnostique au type de modèle, mais potentiellement moins stable lorsque les frontières de décision sont très complexes. Ces deux outils sont complémentaires : SHAP pour la robustesse, LIME pour la rapidité et la flexibilité.

Exercice

Remettez dans le bon ordre les étapes d'une démarche d'analyse et de correction d'un biais détecté grâce à l'interprétabilité locale (SHAP).

A Constater une anomalie dans les prédictions (ex. : surreprésentation d'un groupe dans les alertes)

B Appliquer SHAP pour analyser la contribution de chaque variable sur les cas du groupe concerné

C Identifier la ou les variables responsables du biais (variable directe ou proxy)

D Définir un plan correctif : suppression, transformation de variable ou rééchantillonnage des données

E Valider avec les experts métier que la correction ne génère pas de nouveaux problèmes

Q La démarche logique commence par la détection d'une anomalie observable (surreprésentation d'un groupe), puis passe par l'analyse SHAP pour identifier les variables en cause. Une fois la source du biais identifiée (variable directe ou proxy), un plan correctif est défini et mis en œuvre. La dernière étape, souvent négligée, est la validation métier : s'assurer que la correction améliore réellement l'équité sans introduire de nouveaux biais ou dégrader les performances. Ce cycle correspond à la démarche d'amélioration continue décrite dans la leçon.

[exercice p. 20] **Solution n°4**

Réponse attendue

Pour comprendre le ciblage disproportionné des moins de 30 ans, vous devez combiner des techniques d'interprétabilité **globale** et **locale**. Au niveau global, l'analyse de la **feature importance par permutation** (déjà disponible) confirme que l'âge et l'ancienneté contrat dominant le modèle, mais ne suffit pas à comprendre *comment* ces variables agissent. Les **graphiques de dépendance partielle (PDP)** permettent de visualiser la relation entre chaque variable et la probabilité de résiliation : vous pourrez ainsi vérifier si la probabilité chute brutalement après un seuil d'âge ou d'ancienneté, révélant un effet de seuil non souhaité. Les **courbes ICE** complètent cette analyse en montrant la variabilité individuelle autour de la tendance moyenne. Au niveau local, l'application de **SHAP** sur un échantillon d'adhérents de moins de 30 ans et un échantillon comparable de plus de 30 ans permet de comparer les contributions variable par variable et de vérifier si l'âge ou l'ancienneté contribuent de manière excessive à la prédiction pour le premier groupe. **LIME** peut être utilisé en complément pour des cas individuels litigieux, afin de produire des explications simplifiées destinées à l'équipe marketing.

Éléments de solution

- **Savoirs à mobiliser** : distinction entre interprétabilité globale (feature importance, PDP, ICE) et locale (SHAP, LIME) ; compréhension de leurs apports respectifs
- **Méthode applicable** :
 - Étape 1 : Analyser la feature importance globale pour identifier les variables dominantes
 - Étape 2 : Tracer les PDP et courbes ICE sur les variables âge, ancienneté contrat et interactions SAV pour détecter des effets de seuil ou des non-linéarités
 - Étape 3 : Calculer les valeurs SHAP segmentées par tranche d'âge (moins de 30 ans vs. plus de 30 ans) pour comparer les contributions
 - Étape 4 : Utiliser LIME sur quelques cas individuels représentatifs pour produire des explications accessibles
- **Feedback** : une réponse complète articule les deux niveaux (global et local) en justifiant l'apport spécifique de chaque outil. Se limiter à la feature importance sans PDP ni SHAP serait insuffisant pour diagnostiquer le mécanisme du biais. L'outil LIME est pertinent ici pour sa dimension communicationnelle auprès des non-techniciens.

[exercice p. 20] **Solution n°5**

Réponse attendue

Le ciblage excessif des moins de 30 ans ne provient pas d'une variable isolée mais d'une **combinaison de facteurs corrélés** qui se renforcent mutuellement. L'**ancienneté contrat** (importance : **0.31**) est mécaniquement faible chez les jeunes adhérents, ce qui constitue un **proxy indirect de l'âge**. L'**âge** lui-même (importance : **0.24**) contribue directement à la prédiction. Le **nombre d'interactions SAV** (importance : **0.16**), plus élevé chez les moins de 30 ans (questions sur les remboursements, changements de formule), renforce encore le signal de risque. Enfin, le **canal de souscription en ligne** et la **formule basique**, caractéristiques de ce segment, ajoutent des facteurs convergents. Le modèle capte donc un profil type — jeune, récemment souscrit, formule d'entrée de gamme, actif au SAV — qu'il associe massivement au risque de résiliation, alors que ces caractéristiques reflètent davantage un comportement exploratoire normal qu'un véritable risque de départ.

Éléments de solution

- **Savoirs à mobiliser** : notion de **variable proxy** (ancienneté comme proxy de l'âge), corrélations parasites entre variables, effet de renforcement mutuel dans les modèles ensemblistes
- **Méthode applicable** :
 - Croiser les distributions des variables clés par tranche d'âge pour mettre en évidence les corrélations structurelles
 - Vérifier via les PDP si l'ancienneté et l'âge présentent des effets de seuil convergents
 - Analyser les valeurs SHAP moyennes par segment pour quantifier la contribution cumulée des variables corrélées
 - Tester l'hypothèse du proxy en retirant temporairement la variable ancienneté et en observant l'impact sur la répartition des alertes
- **Feedback** : une réponse qui se limite à incriminer l'âge seul est incomplète. Le diagnostic doit mettre en évidence le mécanisme de **renforcement croisé** entre variables corrélées (âge, ancienneté, canal, formule). C'est cette combinaison qui explique la surreprésentation massive des jeunes dans les alertes, et non un simple effet direct de l'âge.

[exercice p. 20] **Solution n°6**

Réponse attendue

Trois axes d'intervention complémentaires doivent être envisagés. **Sur les données** : rééquilibrer le jeu d'entraînement par des techniques de rééchantillonnage (suréchantillonnage des profils non-jeunes à risque réel, sous-échantillonnage des jeunes à faible risque avéré) et envisager la création de variables dérivées plus pertinentes, comme l'ancienneté normalisée par tranche d'âge, pour casser la corrélation mécanique. **Sur le modèle** : tester la suppression ou la transformation de la variable âge brut, introduire des contraintes d'équité (seuils de parité démographique sur les alertes), et envisager une segmentation du modèle avec un sous-modèle spécifique pour les moins de 30 ans intégrant des variables comportementales plus fines. **Sur les usages métier** : définir avec l'équipe marketing des règles de post-traitement des alertes (par exemple, ne déclencher une campagne de fidélisation pour les moins de 30 ans que si le score dépasse un seuil rehaussé), et mettre en place un tableau de bord de suivi mensuel de la répartition des alertes par segment pour détecter toute dérive future.

Éléments de solution

- **Savoirs à mobiliser** : techniques de rééchantillonnage, feature engineering, contraintes d'équité algorithmique, segmentation de modèles, post-traitement des prédictions, monitoring de la dérive
- **Méthode applicable** :
 - Axe données : rééchantillonnage stratifié, création de variables normalisées, suppression ou transformation des proxies identifiés
 - Axe modèle : test A/B avec et sans la variable âge, introduction de métriques d'équité (demographic parity, equalized odds), entraînement de sous-modèles segmentés
 - Axe métier : co-construction de règles de seuil avec le marketing, mise en place d'un dashboard de monitoring des biais, revue trimestrielle croisée data/métier
- **Feedback** : une réponse complète couvre les trois axes (données, modèle, usages). Se limiter à "supprimer la variable âge" serait insuffisant car les proxies (ancienneté, canal) maintiendraient le biais. La dimension métier (post-traitement, monitoring) est essentielle pour garantir que la correction technique se traduit en amélioration opérationnelle réelle.

[exercice p. 20] **Solution n°7**

Réponse attendue

La synthèse doit être rédigée dans un langage accessible, sans jargon technique non expliqué, et structurée de manière à répondre aux préoccupations opérationnelles de l'équipe marketing. Elle doit comporter : un **constat factuel** (62 % des alertes concernent les moins de 30 ans qui ne représentent que 18 % du portefeuille, avec un taux de conversion de seulement 4 %), une **explication du mécanisme** (le modèle associe un profil type — jeune, récent, formule basique, actif au SAV — à un risque élevé, car ces caractéristiques sont corrélées dans les données historiques sans refléter un vrai risque de départ), les **risques identifiés** (campagnes inefficaces, gaspillage budgétaire, perte de confiance des équipes commerciales, risque de non-conformité RGPD si un adhérent conteste une décision basée sur l'âge), et un **plan d'action en trois volets** présenté simplement : ajustement des données d'entraînement, adaptation du modèle pour réduire l'influence excessive de l'âge et de l'ancienneté, et mise en place de règles de filtrage des alertes et d'un tableau de bord de suivi. La synthèse doit conclure sur un calendrier indicatif et les bénéfices attendus (meilleur ciblage, réduction des coûts de campagne, conformité renforcée).

Éléments de solution

- **Savoirs à mobiliser** : capacité à vulgariser des concepts techniques (biais algorithmique, variable proxy, interprétabilité), structuration d'une communication à destination de parties prenantes non techniques, articulation entre diagnostic et plan d'action
- **Méthode applicable** :
 - Structure recommandée : Constat → Explication → Risques → Plan d'action → Calendrier
 - Utiliser des analogies simples (ex : "le modèle confond jeunesse et instabilité") plutôt que du vocabulaire technique
 - Appuyer chaque point sur des **chiffres concrets** issus du contexte (62 %, 18 %, 4 % vs 15 %)
 - Éviter les termes comme "feature importance", "SHAP", "proxy" sans les expliquer en langage courant
- **Feedback** : une synthèse qui reste trop technique ou qui ne propose pas de plan d'action concret manque sa cible. L'enjeu est de **traduire un diagnostic data en décisions métier**. La qualité de la communication non technique est un critère d'évaluation à part entière : c'est cette compétence qui permet de faire adopter les corrections par les équipes opérationnelles.