




Tests de robustesse et sécurité des modèles IA

Table des matières

I - Contexte	3
II - Évaluer la robustesse des modèles IA	4
A. Principes et objectifs des tests de robustesse	4
B. Méthodes de test et indicateurs	6
III - Sécurité et résilience face aux attaques adverses	8
A. Comprendre les menaces spécifiques aux modèles IA.....	8
B. Stratégies de défense et sécurisation des modèles	10
IV - Synthèse	12
V - Auto-évaluation	17
VI - Exercice : Sécuriser un modèle IA de classification documentaire en administration publique	21
Solutions des exercices	23

I Contexte

Contexte

À mesure que les **systèmes d'intelligence artificielle** s'implantent dans des **environnements critiques**, la question de leur **robustesse** et de leur **sécurité** devient centrale. Contrairement aux évaluations classiques qui se concentrent uniquement sur la **précision** ou l'**exactitude** sur des jeux de tests « *propres* », les modèles déployés doivent être capables de conserver un niveau fiable de performance même lorsque les conditions d'utilisation changent, que les **données d'entrée sont bruitées**, incomplètes, ou qu'elles proviennent d'un contexte de distribution différent de celui rencontré à l'entraînement.

Un modèle performant en laboratoire peut se dégrader brutalement en **production** face à des variations minimales : légère perturbation visuelle sur une image, changement de tonalité dans un enregistrement vocal, données textuelles au vocabulaire inhabituel, etc. Ces **failles de robustesse** sont particulièrement problématiques dans des secteurs où l'erreur peut avoir un fort impact, comme la **médecine**, la **finance**, la **sécurité** ou l'**industrie automobile**.

En parallèle, les **risques de sécurité** propres aux modèles d'IA se multiplient. Les **attaques adversariales**, qui exploitent des modifications imperceptibles des données d'entrée pour tromper un modèle, démontrent qu'il est possible de manipuler ou de détourner son comportement. D'autres menaces incluent l'**injection de données malveillantes** dans le pipeline d'apprentissage, l'**extraction d'informations confidentielles** à partir du modèle entraîné, ou l'**inversion de modèle** permettant de reconstituer des données sensibles. Ces vulnérabilités peuvent remettre en cause non seulement la **fiabilité** du système, mais aussi sa **conformité légale** et le respect de la **confidentialité**.

Tester et renforcer les modèles suppose donc deux axes complémentaires :

- D'une part, **évaluer la robustesse** grâce à des méthodologies réalistes, allant des tests de résistance simples à l'**environnement simulé** ou quasi-réel, pour identifier les points faibles face à des perturbations variées.
- D'autre part, **sécuriser la chaîne IA** dans son ensemble, du prétraitement à l'inférence, afin de limiter l'exposition aux attaques et de mettre en place des **stratégies de défense** préventives et réactives.

II Évaluer la robustesse des modèles IA

A. Principes et objectifs des tests de robustesse

Pourquoi tester la robustesse des modèles IA

Évaluer la **robustesse** d'un modèle n'est pas une option lorsque celui-ci est destiné à opérer dans un environnement réel. Même un modèle très performant sur des données propres et bien préparées peut s'avérer **extrêmement vulnérable** dès que les conditions changent. En pratique, il suffit parfois d'un léger écart dans les entrées pour provoquer une dégradation sévère : une variation de luminosité sur une image, un bruit ambiant dans un enregistrement, un caractère inattendu dans une donnée texte.

Les secteurs les plus sensibles, tels que la **médecine**, la **finance**, les **systèmes de sécurité** ou l'**automobile autonome**, ne peuvent tolérer ce type de défaillance. Un algorithme de diagnostic médical incapable de reconnaître une anomalie à cause d'un contraste légèrement différent représente un risque médical. Un moteur de scoring de crédit qui se trompe après un simple changement de format de champ client peut provoquer des décisions injustes ou illégales.

Tester la robustesse consiste donc à **préparer le modèle à la réalité**, qui est toujours plus complexe, plus bruitée et plus variable que les données d'entraînement. Cela implique de reproduire en laboratoire des scénarios « *hors-norme* » pour observer comment les performances réagissent sous contrainte, et de mettre en place des correctifs ou parades lorsque le modèle montre des signes de faiblesse. Une telle culture du test augmente la **confiance métier** et réduit le risque d'échec post-déploiement.

Robustesse d'un modèle IA

Az Définition

La **robustesse** est la capacité d'un modèle à maintenir des résultats fiables même lorsque les données d'entrée présentent des variations, perturbations ou conditions inattendues. Elle se mesure grâce à des tests spécifiques visant à reproduire des situations réelles ou simulées en dehors du contexte exact d'entraînement.

Robustesse en imagerie médicale

👁 Exemple

Un modèle de détection de nodules pulmonaires performant en laboratoire est devenu inutilisable lorsqu'il a été confronté à des scanners issus d'un hôpital équipé d'un autre fournisseur d'imagerie. La **différence de contraste et de calibration a suffi pour diviser par deux ses performances**. Un test de robustesse précoce aurait mis en évidence cette dépendance aux appareils de collecte.

Différences entre performance et robustesse

La plupart des évaluations IA confondent **performance brute** et **robustesse** alors que les deux notions répondent à des logiques très différentes.

La performance mesure la qualité du modèle **dans les conditions pour lesquelles il a été calibré**, avec des données reflétant la distribution de l'entraînement. Elle produit des indicateurs rassurants comme la précision, le rappel ou le score F1, mais ces chiffres ne révèlent pas la capacité du modèle à s'adapter à l'imprévu. La robustesse, à l'inverse, mesure la stabilité des performances **lorsque l'on perturbe ou modifie les conditions d'entrée**.

Un moteur de reconnaissance d'objets dans le retail pourra identifier correctement 99 % des produits en studio photo (performance élevée), mais tomber à 60 % sur des photos client mal éclairées ou prises à travers une vitrine (robustesse faible).

Cette dissociation explique pourquoi des projets réussissant brillamment en phase pilote peuvent échouer la semaine du déploiement : parce que seuls les indicateurs de performance « *idéaux* » ont été examinés, et pas la résilience du modèle.

Ne pas s'arrêter aux scores de test

 Attention

Un modèle peut afficher un score de validation impeccable tout en étant extrêmement fragile. Sans mesures de robustesse, cette faiblesse reste invisible jusqu'à la confrontation avec les aléas du terrain.

Types de perturbations à tester

Les **perturbations** à introduire lors des tests de robustesse doivent refléter les contextes auxquels le modèle sera confronté en exploitation. Elles incluent :

- **Le bruit aléatoire** : fluctuations visuelles, sonores ou numériques injectées pour simuler des dégradations mineures,
- **Les déformations** : rotations, flous, compressions d'images ; distorsions ou changements de fréquence audio ; réorganisation de colonnes dans un dataset tabulaire,
- **Les changements de distribution** : apparition de nouvelles classes, évolutions saisonnières des comportements, différences régionales,
- **Les données incomplètes** : valeurs manquantes, capteurs hors service, textes tronqués,
- **Les valeurs extrêmes** : mesures hors plage habituelle, événements rares mais plausibles.

Le choix des perturbations à tester se fait **en fonction du contexte métier**. En maintenance industrielle, on simulera des pannes de capteurs et des pics de vibration ; en cybersécurité, on injectera des paquets réseau aux structures inhabituelles ; en reconnaissance faciale, on testera les performances avec différentes conditions de lumière ou d'occlusion (masque, lunettes, écharpe).

Données hors distribution (OOD)

 Az Définition

On parle de **données hors distribution (Out-Of-Distribution, OOD)** lorsque les données rencontrées en production diffèrent fondamentalement de celles vues à l'entraînement (ex : nouvelles classes d'objets, vocabulaires inédits, capteurs différents). Les tests de robustesse doivent **systematiquement inclure ce cas** pour anticiper les failles critiques.

Prioriser selon l'impact métier

 Conseil

Concentrez les efforts de test sur les perturbations qui, dans le contexte d'utilisation, pourraient avoir les conséquences les plus graves en cas de défaillance du modèle.

Comprendre les enjeux de robustesse des modèles IA

 Vidéo

B. Méthodes de test et indicateurs

Techniques classiques de test de robustesse

Les tests de robustesse classiques consistent à **appliquer systématiquement des altérations contrôlées aux données d'entrée** pour mesurer la réaction du modèle. Cela peut aller de l'ajout progressif de bruit visuel ou sonore, à la suppression de variables essentielles dans un modèle tabulaire, en passant par la réduction volontaire de la résolution d'images ou de la qualité audio.

Ces manipulations, bien que simples, permettent souvent de révéler les dépendances cachées du modèle : une variable mise en avant par le modèle peut s'avérer être un **point de fragilité** si sa disparition ou son altération provoque un effondrement disproportionné de la performance.

Dans l'industrie, un opérateur de maintenance prédictive a découvert qu'un modèle était quasi intégralement dépendant d'un seul capteur de vibration. Un test de suppression simulée de cette source a fait chuter la précision de plus de 50 %. Ce genre d'informations est précieux pour redessiner un modèle plus équilibré et moins vulnérable à un point unique de défaillance.

Indicateurs pour mesurer la robustesse

Mesurer la robustesse suppose de choisir des **métriques adaptées** à ce type de test. On retrouvera :

- **La variance des résultats** entre différents scénarios perturbés : plus la variance est faible, plus le modèle est stable.
- **Les courbes de dégradation** : elles tracent la performance en fonction de l'intensité de la perturbation (ex : blanchiment progressif d'une image).
- **La robustesse relative** : ratio entre la performance en conditions perturbées et celle en conditions idéales.
- **La sensibilité moyenne** : mesure l'impact moyen sur la performance pour un « pas » de perturbation.

Ces indicateurs, utilisés conjointement, donnent une vision complète : par exemple, un modèle de détection de fraude peut rester performant avec des perturbations légères mais s'effondrer brutalement après un certain seuil - une information clé pour le monitoring en production.

Robustesse relative

Az Définition

La **robustesse relative** compare la performance d'un modèle en environnement perturbé à sa performance initiale sans perturbation, généralement exprimée en pourcentage, afin de normaliser la mesure entre différents modèles ou contextes.

Robustesse dans la finance

👁 Exemple

Un moteur de scoring crédit montrait une bonne précision globale. Mais en ajoutant un **léger bruit gaussien** sur les variables de revenus (simulation d'erreurs de saisie), la performance chutait de 20 points. L'analyse a révélé une dépendance excessive à ces champs particuliers, conduisant à une refonte de la pondération des variables.

Tests en environnement simulé ou réel

Les **environnements simulés** (simulateurs 3D, données synthétiques, générateurs de bruit) offrent l'avantage de reproduire un large éventail de scénarios à coût réduit. Ils permettent de jouer rapidement des centaines d'itérations et d'ajuster les paramètres. Cependant, la simulation reste une approximation : certains effets réels échappent à ce type de reproductions.

Les **tests en environnement réel** (ou semi-réel) permettent de confronter le modèle à des données issues directement de son futur terrain d'application : usage par un panel d'utilisateurs, activation sur un échantillon limité d'appareils, collecte de données sur site. Cette étape révèle souvent des phénomènes non anticipés : latences réseau, résolutions inattendues, combinaisons de perturbations qui se cumulent.

Un exemple marquant vient d'un projet de détection d'objets embarqué : les tests en laboratoire avaient montré une très bonne tenue à la pluie et au brouillard simulés, mais les tests sur route réelle ont révélé une sensibilité forte aux reflets de phares sur chaussée humide, un cas jamais reproduit en simulation.

Ne pas négliger les tests « mixtes »

 **Attention**

Une combinaison simulation + terrain permet de profiter de la rapidité et de la variété des scénarios synthétiques, tout en validant le comportement sur des situations authentiques impossibles à simuler parfaitement.

III Sécurité et résilience face aux attaques adverses

A. Comprendre les menaces spécifiques aux modèles IA

Attaques adversariales - nature et risques

Les **attaques adversariales** font partie des menaces les plus documentées et préoccupantes dans le domaine de la sécurité IA. Elles consistent à apporter de **légères modifications intentionnelles** et soigneusement calculées aux données d'entrée, souvent imperceptibles pour un humain, mais capables de tromper complètement un modèle. Cette vulnérabilité tient à la nature même des algorithmes d'apprentissage automatique : les frontières de décision qu'ils tracent peuvent être délibérément franchies à l'aide de perturbations fines, orientant le modèle vers une classification erronée.

Dans la reconnaissance d'images, une simple altération de quelques pixels peut transformer la prédiction d'un panneau « *STOP* » en un panneau « *LIMITATION 80* » pour un véhicule autonome. En traitement du langage, un ajout discret de caractères spéciaux dans un texte peut dévier l'analyse de sentiment. Dans les systèmes de cybersécurité, des flux réseau légèrement modifiés - mais conservant leur apparence normale - peuvent échapper à la détection d'un IDS basé sur l'IA.


Le risque est double : d'une part, compromettre la **fiabilité fonctionnelle** du système en provoquant des erreurs critiques ; d'autre part, menacer la **sûreté** dans des contextes humains ou financiers sensibles.

Exemple d'attaque adversariale

Az Définition

Une **attaque adversariale** peut être une image légèrement retouchée, invisible pour un observateur humain, mais conçue pour pousser un modèle de classification à renvoyer une sortie erronée. C'est un acte volontaire visant à exploiter la géométrie de l'espace décisionnel du modèle.

Exemple d'attaque adversariale



Autres menaces pour les modèles IA

En dehors des perturbations adversariales, plusieurs autres vecteurs d'attaque peuvent compromettre un modèle. L'**injection de données malveillantes** durant l'entraînement (data poisoning) consiste à intégrer dans le jeu de données des exemples biaisés ou manipulés pour influencer le comportement futur de l'algorithme. L'**inversion de modèle** permet, en analysant la sortie du modèle, d'inférer des éléments sensibles des données d'entrée originales. L'**extraction de modèle**, enfin, vise à reconstituer une copie fonctionnelle d'un modèle propriétaire en l'interrogeant systématiquement pour en reproduire les comportements.

Ces menaces posent autant de problèmes de **confiance** que la **confidentialité** ou de **propriété intellectuelle**. Dans le domaine médical, l'inversion de modèle pourrait révéler des données personnelles à partir d'un algorithme de diagnostic. Dans la finance, l'extraction d'un modèle de trading pourrait exposer une partie du savoir-faire stratégique d'une entreprise.

Risques indirects

 Attention

Même lorsque la finalité d'une attaque n'est pas de tromper la prédiction, le simple fait de perturber la stabilité d'un modèle ou d'accéder à certaines informations internes peut fragiliser tout un écosystème de décision.

Évaluer l'exposition au risque

L'évaluation du niveau de risque doit se baser sur le **contexte fonctionnel** et la **surface d'exposition** du modèle. Un algorithme intégré à une application publique, recevant des données venant d'utilisateurs divers et non filtrées, est logiquement plus exposé qu'un modèle exécuté dans un environnement strictement contrôlé. La criticité des données traitées joue aussi : données médicales, financières ou de sécurité nationale imposent un seuil de tolérance quasi nul face à la compromission. Le rythme de mise à jour du modèle, sa capacité à apprendre en continu et le degré d'ouverture de son API influencent également la sensibilité globale.

Un exemple caractéristique concerne un **assistant vocal** exposé au grand public : il peut recevoir des commandes malveillantes intégrées dans des séquences sonores ordinaires, déclenchant des actions non souhaitées. Ce type de menace impose une analyse proactive de son exposition réelle avant et après déploiement.

B. Stratégies de défense et sécurisation des modèles

Défenses face aux attaques adversariales

La première réponse aux attaques adversariales est l'**entraînement adversarial**, qui consiste à exposer le modèle, pendant sa phase d'apprentissage, à des exemples volontairement perturbés pour l'habituer à les traiter correctement. Des mécanismes de **filtrage d'entrée** peuvent également être mis en place pour détecter ou bloquer des inputs suspects avant qu'ils n'atteignent le modèle. La **normalisation renforcée** joue sur la transformation standardisée des données pour réduire la sensibilité aux variations artificielles.

Ces approches, si elles sont efficaces, ne garantissent pas une protection totale : elles doivent être combinées et recalibrées régulièrement, car les techniques d'attaque évoluent rapidement.

Défense multicouche en e-commerce

 Exemple

Une plateforme e-commerce a combiné :

- **Entraînement adversarial** (le modèle « voit » des exemples modifiés),
- **Filtrage d'entrée** sur API (suppression de patterns suspects),
- **Monitoring temps réel** des requêtes.

Résultat : réduction de 70 % des attaques adversariales détectées en production en un trimestre.

Adopter une défense multicouche

 Conseil

Miser sur une seule méthode de protection est risqué ; une combinaison de mesures préventives et réactives, réparties sur plusieurs points de la chaîne de traitement, offre une bien meilleure résilience.

Sécurisation de bout en bout du pipeline IA

Protéger un modèle ne se limite pas à son code ou à ses paramètres pour l'inférence. Il faut envisager le **pipeline complet** : sécurisation et nettoyage des données en amont, contrôle des contributions lorsqu'elles proviennent d'utilisateurs externes, limitation et journalisation des accès, suivi des versions de modèles, chiffrement des éléments critiques. Des pratiques de supervision en continu permettent de détecter les signes avant-coureurs d'une attaque ou d'une dérive anormale.

Une grande banque française a par exemple mis en place un protocole où chaque version d'un modèle de scoring est chiffrée, accessible uniquement via des API auditées, et insérée dans un environnement cloisonné. Chaque requête est tracée et analysée pour prévenir les abus.

Intégration de la sécurité dans la gouvernance IA

Au-delà de l'aspect technique, la sécurité doit être inscrite dans la **gouvernance des projets IA** et s'intégrer aux pratiques **MLOps**. Documenter les menaces identifiées, valider la robustesse avant mise en production, établir des plans de réponse aux incidents, réaliser des audits réguliers et adapter les politiques de mise à jour à la criticité du modèle sont des points clés. Dans l'univers des objets connectés, ce suivi garantit par exemple que des modèles embarqués ne deviennent pas un point d'entrée exploitable dans un réseau.

Sécurité continue

⚠ Attention

La sécurité d'un modèle IA n'est jamais acquise : elle demande une réévaluation constante, en particulier après l'introduction de nouvelles données, de nouvelles fonctionnalités ou suite à la découverte publique de nouvelles techniques d'attaque.

IV Synthèse

A. Flashcards

Robustesse d'un modèle IA

Capacité à maintenir des résultats fiables malgré variations, perturbations ou conditions inattendues des données d'entrée.

Données hors distribution (OOD)

Données en production différant fondamentalement de celles vues à l'entraînement, révélant les failles de robustesse.

Robustesse relative

Ratio entre performance en environnement perturbé et performance initiale sans perturbation, exprimé en pourcentage.

Attaque adversariale

Modification intentionnelle imperceptible des données d'entrée pour tromper complètement un modèle d'IA.

Data poisoning

Injection de données malveillantes ou biaisées durant l'entraînement pour influencer le comportement futur du modèle.

Inversion de modèle

Technique permettant d'inférer des éléments sensibles des données d'entrée originales en analysant les sorties du modèle.

Extraction de modèle

Reconstitution d'une copie fonctionnelle d'un modèle propriétaire en l'interrogeant systématiquement pour reproduire ses comportements.

Entraînement adversarial

Exposition du modèle à des exemples volontairement perturbés pendant l'apprentissage pour renforcer sa résistance.

Courbe de dégradation

Graphique traçant l'évolution de la performance d'un modèle en fonction de l'intensité croissante de perturbation.

Filtrage d'entrée

Mécanisme de détection et blocage des inputs suspects avant qu'ils n'atteignent le modèle pour prévenir les attaques.

Normalisation renforcée

Transformation standardisée des données pour réduire la sensibilité du modèle aux variations artificielles et perturbations.


Sécurisation du pipeline IA

Protection de bout en bout incluant nettoyage des données, contrôle d'accès, chiffrement et surveillance continue.

La théorie en Bref

💡 Fondamental

Les **tests de robustesse** et de **sécurité** des modèles IA évaluent leur capacité à maintenir des performances fiables face aux **perturbations**, **données bruitées** et **attaques adversariales**. La **robustesse** mesure la stabilité du modèle lorsque les conditions d'entrée diffèrent de l'entraînement : bruit, déformations, données hors distribution (OOD), valeurs manquantes ou extrêmes. Les **attaques adversariales** exploitent des modifications imperceptibles pour tromper le modèle, tandis que d'autres menaces incluent l'**injection de données malveillantes**, l'**extraction** et l'**inversion de modèle**. Les **stratégies de défense multicouches** combinent **entraînement adversarial**, **filtrage d'entrée**, **normalisation renforcée** et **sécurisation du pipeline** complet. L'intégration dans la **gouvernance IA** et les pratiques **MLOps** garantit une surveillance continue et une résilience durable en production.



1. Capacité à maintenir des performances fiables malgré les perturbations.
2. Performance mesure la qualité en conditions idéales, robustesse la stabilité sous contrainte.
3. Médecine, finance, sécurité, automobile autonome.
4. Fluctuations visuelles, sonores ou numériques.
5. Rotations, flous, compressions, distorsions.
6. Nouvelles classes, évolutions saisonnières, différences régionales.
7. Valeurs manquantes, capteurs hors service.
8. Ajout progressif de bruit, suppression de variables.
9. Simulateurs 3D, données synthétiques, générateurs de bruit.
10. Validation sur terrain avec données authentiques.
11. Stabilité entre scénarios perturbés.
12. Performance selon intensité de perturbation.
13. Ratio performance perturbée sur performance idéale.
14. Modifications imperceptibles pour tromper le modèle.
15. Data poisoning durant l'entraînement.
16. Reconstitution de données sensibles depuis les sorties.
17. Copie fonctionnelle par interrogation systématique.
18. Accès public, données non filtrées.
19. Médical, financier, sécurité nationale.
20. API publique, apprentissage continu.
21. Exposition à exemples perturbés durant apprentissage.
22. Détection et blocage d'inputs suspects.
23. Transformation standardisée pour réduire sensibilité.
24. Contrôle accès, chiffrement, journalisation, versioning.
25. Identification et traçabilité des risques.
26. Tests de robustesse et sécurité obligatoires.
27. Protocoles d'incident et audits réguliers.

28. Monitoring post-déploiement et réévaluation.

Tests de robustesse et sécurité IA

Les conseils pro

Conseil

Comment concevoir un plan de test de robustesse adapté au contexte métier ?

- Identifier les perturbations réalistes propres au secteur : bruit capteur en industrie, variations lumineuses en vision, formats variables en finance.
- Prioriser les tests selon l'impact métier potentiel : concentrer les efforts sur les défaillances aux conséquences critiques.
- Combiner environnements simulés pour la variété et tests terrain pour la validation des cas réels non anticipés.
- Mesurer la robustesse avec des indicateurs quantitatifs : variance, courbes de dégradation, robustesse relative, sensibilité moyenne.

Comment évaluer l'exposition d'un modèle aux risques de sécurité ?

- Cartographier la surface d'exposition : accès public, API ouverte, données utilisateurs non filtrées augmentent le risque.
- Évaluer la criticité des données traitées : médical, financier, sécurité imposent un seuil de tolérance quasi nul.
- Analyser l'architecture du système : apprentissage continu, mise à jour fréquente, cloisonnement des environnements.
- Documenter les menaces identifiées et les scénarios d'attaque plausibles pour chaque point d'entrée du pipeline.

Comment mettre en place une défense multicouche efficace ?

- Intégrer l'entraînement adversarial dès la phase d'apprentissage pour habituer le modèle aux perturbations intentionnelles.
- Déployer un filtrage d'entrée sur les API pour détecter et bloquer les patterns suspects avant inférence.
- Appliquer une normalisation renforcée des données pour réduire la sensibilité aux variations artificielles.
- Sécuriser le pipeline complet : chiffrement, contrôle d'accès, journalisation, versioning, limitation des contributions externes.

Comment intégrer la sécurité dans la gouvernance IA et les pratiques MLOps ?

- Documenter systématiquement les menaces identifiées, les tests réalisés et les mesures de protection déployées.
- Valider la robustesse et la sécurité avant chaque mise en production : tests adversariaux, audits de vulnérabilité.
- Établir des plans de réponse aux incidents : protocoles d'alerte, procédures de rollback, équipes dédiées.
- Planifier des audits réguliers et adapter les politiques de mise à jour selon la criticité et l'évolution des menaces.

Comment organiser la surveillance continue post-déploiement d'un modèle critique ?

- Monitorer en temps réel les indicateurs de performance et détecter les dérives anormales signalant une attaque ou dégradation.
- Tracer et analyser chaque requête pour identifier les comportements suspects : volume anormal, patterns inhabituels, tentatives répétées.

- Réévaluer périodiquement la robustesse face aux nouvelles données, fonctionnalités et techniques d'attaque émergentes.
- Mettre en place des alertes automatiques et des seuils de tolérance pour déclencher une intervention rapide en cas d'anomalie.

V Auto-évaluation

Exercice 1 : Robustesse vs performance des modèles

[solution n°1 p. 23]

Exercice

Un modèle affichant un score de validation élevé sur des données propres est nécessairement robuste face aux perturbations rencontrées en production.

Vrai

Faux

Exercice

Un modèle de détection de fraude bancaire obtient d'excellents résultats sur son jeu de test. Quelques semaines après déploiement, ses performances chutent significativement. Quelle est la cause la plus probable selon les principes de robustesse abordés dans la leçon ?

Le modèle a été mal entraîné et ses hyperparamètres sont incorrects.

Les données de production présentent des variations ou une distribution différente de celles vues à l'entraînement.

Le jeu de test utilisé était trop petit pour être représentatif.

Le modèle souffre d'un surapprentissage sur les données de validation.

Exercice

Parmi les perturbations suivantes, lesquelles font partie des types à tester lors d'une évaluation de robustesse d'un modèle IA selon la leçon ?

A L'ajout de bruit aléatoire sur les données d'entrée

B La modification de l'architecture du réseau de neurones

C La suppression de variables ou de valeurs dans un dataset tabulaire

D L'apparition de nouvelles classes non vues à l'entraînement

E Le changement de l'optimiseur utilisé pendant l'entraînement

Exercice 5 : Méthodes et indicateurs de robustesse

[solution n°2 p. 24]

Exercice

Associez chaque indicateur de robustesse à ce qu'il mesure concrètement.

A Courbe de dégradation**B** Variance des résultats entre scénarios perturbés**C** Sensibilité moyenne**D** Robustesse relative

Stabilité globale du modèle face à différentes perturbations	Évolution de la performance en fonction de l'intensité croissante d'une perturbation	Ratio entre la performance en conditions perturbées et la performance initiale sans perturbation	Impact moyen sur la performance pour un pas de perturbation donné
--	--	--	---

Exercice

Un projet de détection d'objets embarqué a validé son modèle en simulation avec de bons résultats face à la pluie et au brouillard. Lors des tests sur route réelle, des défaillances inattendues apparaissent. Quelle conclusion s'impose selon la leçon ?

Les tests en simulation sont inutiles et doivent être remplacés par des tests terrain exclusivement.

La simulation est suffisante si elle couvre un large éventail de scénarios.

Certains phénomènes réels ne peuvent pas être reproduits en simulation et nécessitent des tests en environnement réel ou semi-réel.

Les défaillances terrain indiquent que le modèle a été mal entraîné et doit être réentraîné depuis le début.

Exercice

Les données OOD (Out-Of-Distribution) désignent uniquement des données corrompues ou de mauvaise qualité technique, comme des images floues ou des enregistrements bruités.

Vrai

Faux

Exercice 9 : Menaces et attaques adversariales

[solution n°3 p. 26]

Exercice

Dans le contexte d'un véhicule autonome, un acteur malveillant modifie imperceptiblement quelques pixels d'un panneau de signalisation pour que le modèle de vision le classe comme un panneau de limitation de vitesse au lieu d'un panneau STOP. De quel type de menace s'agit-il ?

Une injection de données malveillantes (data poisoning) dans le pipeline d'entraînement

Une attaque adversariale exploitant la géométrie de l'espace décisionnel du modèle

Une extraction de modèle visant à reproduire son comportement

Une inversion de modèle permettant de reconstituer des données sensibles

Exercice

Parmi les menaces suivantes, lesquelles sont explicitement identifiées dans la leçon comme des vecteurs d'attaque spécifiques aux modèles IA, distincts des attaques adversariales classiques ?

A L'injection de données malveillantes dans le jeu d'entraînement (data poisoning)

B L'inversion de modèle pour reconstituer des données sensibles à partir des sorties

C La surcharge du serveur d'inférence par un volume excessif de requêtes

D L'extraction de modèle pour reproduire un modèle propriétaire

E La modification des hyperparamètres pendant l'entraînement par un tiers

Exercice

Associez chaque type de menace IA à la conséquence principale qu'elle peut engendrer selon la leçon.

A Inversion de modèle

B Extraction de modèle

C Attaque adversariale

D Data poisoning

Influence sur le comportement futur du modèle via des exemples biaisés introduits à l'entraînement	Révélution de données personnelles sensibles à partir d'un algorithme de diagnostic ou de classification	Exposition du savoir-faire stratégique ou propriétaire d'une organisation	Erreurs critiques de classification provoquées par des modifications imperceptibles des entrées
--	--	---	---

Exercice 13 : Stratégies de défense et gouvernance IA

[solution n°4 p. 27]

Exercice

Remettez dans le bon ordre les étapes d'une démarche de sécurisation complète d'un pipeline IA, de l'amont vers l'aval.

A Surveillance continue post-déploiement pour détecter dérives et tentatives d'attaque

B Contrôle des contributions externes et limitation des accès

C Entraînement adversarial et normalisation renforcée du modèle

D Chiffrement des éléments critiques et journalisation des accès à l'inférence

E Sécurisation et nettoyage des données en amont du pipeline

Réponse : ____ ____ ____ ____ ____

Exercice

Une plateforme e-commerce souhaite se protéger contre les attaques adversariales sur son moteur de recommandation. Quelles mesures, parmi les suivantes, correspondent aux stratégies de défense multicouche décrites dans la leçon ?

☒ **A** Exposer le modèle à des exemples volontairement perturbés pendant l'entraînement

☒ **B** Augmenter la taille du jeu d'entraînement avec des données propres supplémentaires

☒ **C** Mettre en place un filtrage des inputs suspects avant qu'ils n'atteignent le modèle

☐ **D** Appliquer une normalisation renforcée pour réduire la sensibilité aux variations artificielles

☐ **E** Réduire la complexité du modèle pour limiter le nombre de paramètres

VI Exercice : Sécuriser un modèle IA de classification documentaire en administration publique

Mise en situation professionnelle

Vous venez d'intégrer la **Direction du Numérique** d'une grande administration française en tant que référent·e IA. Votre équipe a développé un modèle de classification automatique de documents administratifs (courriers entrants, formulaires, pièces justificatives) destiné à orienter chaque document vers le service compétent. Le modèle, basé sur une architecture de deep learning combinant analyse d'image (OCR) et traitement du langage naturel, affiche un **taux de précision de 94 %** sur le jeu de test interne.

Cependant, plusieurs signaux d'alerte remontent du terrain depuis le début du déploiement pilote :

- Des documents scannés en basse résolution ou légèrement de travers sont régulièrement mal classés.
- Un lot de formulaires provenant d'une antenne régionale utilisant un scanner d'un autre fabricant a généré un **taux d'erreur de 38 %**, contre 6 % habituellement.
- L'équipe cybersécurité a signalé que l'API de classification est exposée sur le réseau interne sans mécanisme de filtrage des entrées, ce qui pourrait permettre l'envoi de documents volontairement altérés.
- La CNIL a rappelé que certains documents traités contiennent des **données personnelles sensibles** (avis d'imposition, justificatifs médicaux), ce qui impose des exigences renforcées en matière de confidentialité et de sécurité du modèle.

Données techniques du modèle

Caractéristique	Détail
Type de modèle	CNN + Transformer (multimodal image/texte)
Volume d'entraînement	120 000 documents annotés manuellement
Classes de sortie	14 catégories documentaires
Précision sur jeu de test interne	94 %
Précision sur documents scanner alternatif	62 %
Format d'entrée	Images PDF scannées (résolution variable)
Exposition	API REST sur réseau interne, sans filtrage d'entrée
Données sensibles traitées	Oui (données personnelles, données fiscales, données médicales)
Fréquence de mise à jour prévue	Trimestrielle

Question 1

[solution n°5 p. 28]

Concevez un plan de test de robustesse du modèle en tenant compte des différents types de perturbations possibles sur les documents traités. Précisez les catégories de perturbations à simuler, les indicateurs à surveiller et la logique de priorisation retenue.

Question 2

[solution n°6 p. 29]

Identifiez les vulnérabilités potentielles du modèle face à des attaques adversariales et autres menaces de sécurité applicables à ce contexte administratif. Évaluez le niveau d'exposition du modèle.

Question 3

[solution n°7 p. 30]

Proposez des techniques de renforcement et de sécurisation adaptées à ce modèle et à son contexte d'utilisation. Justifiez vos choix en fonction des vulnérabilités identifiées.

Question 4

[solution n°8 p. 30]

Définissez une politique de surveillance continue post-déploiement pour détecter et réagir aux dégradations de robustesse ou aux tentatives d'attaque sur ce modèle.

Solutions des exercices

Solution n°1

[exercice p. 17]

Exercice

Un modèle affichant un score de validation élevé sur des données propres est nécessairement robuste face aux perturbations rencontrées en production.

Vrai

✓ Faux



Performance et robustesse sont deux notions distinctes. Un score de validation élevé mesure la qualité du modèle dans les conditions pour lesquelles il a été calibré, c'est-à-dire sur des données reflétant la distribution d'entraînement. Il ne dit rien sur la capacité du modèle à maintenir ses performances lorsque les entrées sont bruitées, incomplètes ou issues d'une distribution différente. Un modèle peut ainsi afficher 99 % de précision en studio et tomber à 60 % sur des données terrain — une faiblesse invisible sans tests de robustesse spécifiques.

Exercice

Un modèle de détection de fraude bancaire obtient d'excellents résultats sur son jeu de test. Quelques semaines après déploiement, ses performances chutent significativement. Quelle est la cause la plus probable selon les principes de robustesse abordés dans la leçon ?

Le modèle a été mal entraîné et ses hyperparamètres sont incorrects.

✓ Les données de production présentent des variations ou une distribution différente de celles vues à l'entraînement.

Le jeu de test utilisé était trop petit pour être représentatif.

Le modèle souffre d'un surapprentissage sur les données de validation.



La leçon illustre précisément ce scénario : un modèle peut réussir brillamment en phase pilote et échouer au déploiement parce que seuls les indicateurs de performance « idéaux » ont été examinés. En production, les données peuvent présenter des changements de distribution, des valeurs manquantes ou des variations non anticipées — c'est exactement ce que les tests de robustesse sont censés révéler en amont. Les autres options (hyperparamètres, taille du jeu de test, surapprentissage) sont des problèmes distincts qui ne correspondent pas au mécanisme décrit.

Exercice

Parmi les perturbations suivantes, lesquelles font partie des types à tester lors d'une évaluation de robustesse d'un modèle IA selon la leçon ?

- A** L'ajout de bruit aléatoire sur les données d'entrée
- B** La modification de l'architecture du réseau de neurones
- C** La suppression de variables ou de valeurs dans un dataset tabulaire
- D** L'apparition de nouvelles classes non vues à l'entraînement
- E** Le changement de l'optimiseur utilisé pendant l'entraînement



La leçon identifie plusieurs catégories de perturbations à tester : le bruit aléatoire (fluctuations injectées pour simuler des dégradations), les données incomplètes (valeurs manquantes, capteurs hors service), et les changements de distribution incluant l'apparition de nouvelles classes – c'est précisément la définition des données OOD (Out-Of-Distribution). En revanche, modifier l'architecture du réseau ou changer l'optimiseur sont des décisions de conception du modèle, pas des perturbations des données d'entrée testées lors d'une évaluation de robustesse.

Solution n°2

[exercice p. 18]

Exercice

Associez chaque indicateur de robustesse à ce qu'il mesure concrètement.

Stabilité globale du modèle face à différentes perturbations	Évolution de la performance en fonction de l'intensité croissante d'une perturbation	Ratio entre la performance en conditions perturbées et la performance initiale sans perturbation	Impact moyen sur la performance pour un pas de perturbation donné
Variance des résultats entre scénarios perturbés	Courbe de dégradation	Robustesse relative	Sensibilité moyenne



Ces quatre indicateurs sont complémentaires : la variance des résultats révèle si le modèle est stable ou erratique selon les scénarios ; la courbe de dégradation permet de visualiser à quel seuil les performances s'effondrent ; la robustesse relative normalise la mesure pour comparer des modèles entre eux ; la sensibilité moyenne quantifie la réactivité du modèle à chaque incrément de perturbation. Utilisés conjointement, ils donnent une vision complète du comportement du modèle sous contrainte.

Exercice

Un projet de détection d'objets embarqué a validé son modèle en simulation avec de bons résultats face à la pluie et au brouillard. Lors des tests sur route réelle, des défaillances inattendues apparaissent. Quelle conclusion s'impose selon la leçon ?

Les tests en simulation sont inutiles et doivent être remplacés par des tests terrain exclusivement.

La simulation est suffisante si elle couvre un large éventail de scénarios.

✓ Certains phénomènes réels ne peuvent pas être reproduits en simulation et nécessitent des tests en environnement réel ou semi-réel.

Les défaillances terrain indiquent que le modèle a été mal entraîné et doit être réentraîné depuis le début.

🔍 La leçon cite exactement ce cas : des tests en laboratoire avaient montré une bonne tenue à la pluie et au brouillard simulés, mais les tests sur route réelle ont révélé une sensibilité aux reflets de phares sur chaussée humide — un cas jamais reproduit en simulation. La conclusion n'est pas d'abandonner la simulation (qui offre rapidité et variété à coût réduit), mais de la combiner avec des tests terrain pour valider les comportements sur des situations authentiques impossibles à simuler parfaitement.

Exercice

Les données OOD (Out-Of-Distribution) désignent uniquement des données corrompues ou de mauvaise qualité technique, comme des images floues ou des enregistrements bruités.

Vrai

✓ Faux

🔍 La leçon définit les données OOD comme des données qui diffèrent fondamentalement de celles vues à l'entraînement — ce qui va bien au-delà de la simple dégradation technique. Cela inclut des nouvelles classes d'objets, des vocabulaires inédits, ou des capteurs différents. L'exemple du modèle de détection de nodules pulmonaires illustre ce point : les scanners d'un autre fournisseur d'imagerie n'étaient pas « corrompus », mais issus d'un contexte de distribution différent, ce qui a suffi à diviser par deux les performances.

Solution n°3

Exercice

Dans le contexte d'un véhicule autonome, un acteur malveillant modifie imperceptiblement quelques pixels d'un panneau de signalisation pour que le modèle de vision le classe comme un panneau de limitation de vitesse au lieu d'un panneau STOP. De quel type de menace s'agit-il ?

Une injection de données malveillantes (data poisoning) dans le pipeline d'entraînement

✓ Une attaque adversariale exploitant la géométrie de l'espace décisionnel du modèle

Une extraction de modèle visant à reproduire son comportement

Une inversion de modèle permettant de reconstituer des données sensibles



La leçon décrit précisément ce scénario comme exemple d'attaque adversariale : une simple altération de quelques pixels transforme la prédiction d'un panneau STOP en panneau de limitation de vitesse. Ces attaques exploitent le fait que les frontières de décision des algorithmes peuvent être délibérément franchies à l'aide de perturbations fines, invisibles pour un humain. Le data poisoning (option 1) intervient pendant l'entraînement, l'extraction de modèle (option 3) vise à copier le modèle, et l'inversion (option 4) cherche à reconstituer des données d'entrée – trois mécanismes distincts.

Exercice

Parmi les menaces suivantes, lesquelles sont explicitement identifiées dans la leçon comme des vecteurs d'attaque spécifiques aux modèles IA, distincts des attaques adversariales classiques ?

A

L'injection de données malveillantes dans le jeu d'entraînement (data poisoning)

B

L'inversion de modèle pour reconstituer des données sensibles à partir des sorties

C

La surcharge du serveur d'inférence par un volume excessif de requêtes

D

L'extraction de modèle pour reproduire un modèle propriétaire

E

La modification des hyperparamètres pendant l'entraînement par un tiers



La leçon identifie trois menaces distinctes des attaques adversariales : le data poisoning (intégration d'exemples biaisés dans les données d'entraînement pour influencer le comportement futur), l'inversion de modèle (inférer des éléments sensibles des données d'entrée à partir des sorties), et l'extraction de modèle (reconstituer une copie fonctionnelle d'un modèle propriétaire en l'interrogeant systématiquement). La surcharge serveur et la modification des hyperparamètres ne sont pas mentionnées dans la leçon comme des menaces spécifiques à l'IA.

Exercice

Associez chaque type de menace IA à la conséquence principale qu'elle peut engendrer selon la leçon.

Influence sur le comportement futur du modèle via des exemples biaisés introduits à l'entraînement	Révélation de données personnelles sensibles à partir d'un algorithme de diagnostic ou de classification	Exposition du savoir-faire stratégique ou propriétaire d'une organisation	Erreurs critiques de classification provoquées par des modifications imperceptibles des entrées
Data poisoning	Inversion de modèle	Extraction de modèle	Attaque adversariale



La leçon associe chaque menace à des conséquences concrètes : le data poisoning oriente le comportement du modèle en corrompant ses données d'apprentissage ; l'inversion de modèle peut révéler des données médicales personnelles à partir d'un algorithme de diagnostic ; l'extraction de modèle peut exposer le savoir-faire d'un modèle de trading ; les attaques adversariales provoquent des erreurs critiques comme la confusion entre un panneau STOP et un panneau de limitation de vitesse. Ces quatre menaces posent des problèmes distincts de fiabilité, confidentialité et propriété intellectuelle.

Solution n°4

[exercice p. 20]

Exercice

Remettez dans le bon ordre les étapes d'une démarche de sécurisation complète d'un pipeline IA, de l'amont vers l'aval.

A Sécurisation et nettoyage des données en amont du pipeline

B Contrôle des contributions externes et limitation des accès

C Entraînement adversarial et normalisation renforcée du modèle

D Chiffrement des éléments critiques et journalisation des accès à l'inférence

E Surveillance continue post-déploiement pour détecter dérives et tentatives d'attaque



La leçon insiste sur la nécessité de penser la sécurité de bout en bout, depuis la collecte jusqu'à la surveillance post-déploiement. La logique séquentielle est la suivante : on sécurise d'abord les données à la source (nettoyage en amont), puis on contrôle qui peut contribuer ou accéder au pipeline, ensuite on renforce le modèle lui-même via l'entraînement adversarial, puis on protège l'inférence par chiffrement et journalisation, et enfin on surveille en continu après déploiement. Chaque étape protège un maillon spécifique de la chaîne – aucune ne peut se substituer aux autres.

Exercice

Une plateforme e-commerce souhaite se protéger contre les attaques adversariales sur son moteur de recommandation. Quelles mesures, parmi les suivantes, correspondent aux stratégies de défense multicouche décrites dans la leçon ?

A Exposer le modèle à des exemples volontairement perturbés pendant l'entraînement

B Augmenter la taille du jeu d'entraînement avec des données propres supplémentaires

C Mettre en place un filtrage des inputs suspects avant qu'ils n'atteignent le modèle



Appliquer une normalisation renforcée pour réduire la sensibilité aux variations artificielles

E Réduire la complexité du modèle pour limiter le nombre de paramètres



La leçon décrit trois mécanismes de défense face aux attaques adversariales : l'entraînement adversarial (exposer le modèle à des exemples perturbés pour l'habituer à les traiter), le filtrage d'entrée (détecter ou bloquer des inputs suspects avant qu'ils n'atteignent le modèle), et la normalisation renforcée (transformation standardisée des données pour réduire la sensibilité aux variations artificielles). Augmenter la taille du jeu d'entraînement avec des données propres ou réduire la complexité du modèle ne sont pas présentés comme des stratégies de défense adversariale dans la leçon.

[exercice p. 22] **Solution n°5**

Réponse attendue

Le plan de test de robustesse doit couvrir les perturbations réalistes auxquelles le modèle sera confronté en exploitation. Vous commencez par identifier les catégories de perturbations : **bruit visuel** (résolution dégradée, flou, taches, rotation), **variations matérielles** (scanners de fabricants différents, contrastes et calibrations hétérogènes), **données incomplètes** (pages manquantes, texte tronqué, champs vides) et **valeurs extrêmes** (documents atypiques, formats inhabituels, langues étrangères ponctuelles). Pour chaque catégorie, vous définissez des scénarios de test progressifs avec des niveaux d'intensité croissants. Les indicateurs retenus sont la **variance des résultats** entre scénarios, les **courbes de dégradation** (précision en fonction de l'intensité de perturbation) et la **robustesse relative** (ratio performance perturbée / performance nominale). La priorisation se fait selon l'**impact métier** : les perturbations liées aux scanners alternatifs et aux documents contenant des données sensibles sont traitées en priorité, car une mauvaise orientation de ces documents peut entraîner des violations de confidentialité.

Éléments de solution

- **Catégories de perturbations à couvrir** : bruit aléatoire (gaussien sur pixels), déformations géométriques (rotation, inclinaison), changements de distribution (scanners différents, résolutions variables), données incomplètes (pages manquantes, OCR partiel), valeurs extrêmes (documents multilingues, formats non standard)
- **Méthode de test** : appliquer des altérations contrôlées de manière progressive pour tracer des courbes de dégradation et identifier les seuils critiques

- **Indicateurs clés** : variance inter-scénarios, robustesse relative (performance perturbée / performance nominale), sensibilité moyenne par pas de perturbation
- **Logique de priorisation** : concentrer les efforts sur les perturbations à fort impact métier – ici, la variabilité des scanners (déjà identifiée comme problème réel avec un taux d'erreur passant de 6 % à 38 %) et les documents contenant des données personnelles sensibles
- **Approche mixte recommandée** : combiner tests en environnement simulé (génération synthétique de dégradations) et tests sur données réelles collectées auprès des antennes régionales pour valider les résultats en conditions authentiques
- Le chiffre de **62 % de précision** sur le scanner alternatif est un signal d'alerte typique d'un problème de robustesse face aux données hors distribution (OOD)

[exercice p. 22] **Solution n°6**

Réponse attendue

Le modèle présente plusieurs vulnérabilités exploitables. Premièrement, les **attaques adversariales** : un acteur malveillant pourrait soumettre via l'API un document visuellement normal mais comportant des modifications imperceptibles (altération de quelques pixels, ajout de micro-patterns) conçues pour forcer une mauvaise classification – par exemple, orienter un courrier sensible vers un service non habilité. Deuxièmement, **l'injection de données malveillantes** (data poisoning) lors des mises à jour trimestrielles : si le processus de réannotation n'est pas sécurisé, des documents biaisés pourraient être intégrés au jeu d'entraînement. Troisièmement, **l'inversion de modèle** constitue un risque majeur ici, car le modèle traite des données personnelles sensibles : un attaquant pourrait tenter de reconstituer des informations fiscales ou médicales à partir des sorties du modèle. Le niveau d'exposition est **élevé** en raison de l'API non filtrée, du traitement de données sensibles et de l'absence de journalisation des requêtes signalée implicitement par l'équipe cybersécurité.

Éléments de solution

- **Attaques adversariales** : modifications imperceptibles des documents soumis via l'API pour provoquer une classification erronée – risque amplifié par l'absence de filtrage des entrées
- **Data poisoning** : injection de documents annotés de manière malveillante dans le pipeline de réentraînement trimestriel, pouvant biaiser durablement le comportement du modèle
- **Inversion de modèle** : risque de reconstitution de données personnelles sensibles (données fiscales, médicales) à partir des réponses du modèle – particulièrement critique au regard des exigences CNIL
- **Extraction de modèle** : interrogation systématique de l'API pour reproduire le comportement du modèle, exposant le savoir-faire de l'administration
- **Évaluation de l'exposition** : la surface d'attaque est large (API non protégée, données sensibles, accès réseau interne potentiellement partagé), le rythme de mise à jour trimestriel crée des fenêtres de vulnérabilité, et la criticité des données traitées impose un seuil de tolérance quasi nul
- La combinaison API exposée + données sensibles + absence de filtrage constitue un **scénario à risque élevé** nécessitant une action corrective immédiate

[exercice p. 22] **Solution n°7****Réponse attendue**

La stratégie de défense doit être **multicouche** pour couvrir l'ensemble du pipeline. Sur le volet robustesse, vous recommandez un **entraînement adversarial** intégrant des documents volontairement perturbés (bruit, déformations, résolutions variées) et surtout des données issues de scanners différents pour corriger la dépendance matérielle identifiée. Sur le volet sécurité de l'API, vous préconisez un **filtrage des entrées** (détection de patterns suspects, vérification de format et de taille), une **limitation du débit de requêtes** (rate limiting) pour contrer l'extraction de modèle, et une **journalisation exhaustive** de chaque requête. Pour protéger les données sensibles, vous recommandez le **chiffrement des paramètres du modèle**, la restriction des accès via une authentification forte, et la limitation des informations retournées par l'API (ne pas exposer les scores de confiance détaillés pour réduire le risque d'inversion). Enfin, le pipeline de réentraînement doit intégrer un **contrôle qualité des données** entrantes pour prévenir le data poisoning.

Éléments de solution

- **Entraînement adversarial** : exposer le modèle à des exemples perturbés pendant l'apprentissage pour renforcer sa résistance – inclure impérativement des documents issus de scanners variés
- **Normalisation renforcée** : standardiser les images en entrée (résolution, contraste, orientation) pour réduire la sensibilité aux variations matérielles
- **Filtrage des entrées sur l'API** : vérification de format, détection d'anomalies dans les fichiers soumis, rejet des entrées suspectes avant qu'elles n'atteignent le modèle
- **Rate limiting et authentification** : limiter le nombre de requêtes par utilisateur/session pour contrer l'extraction de modèle, imposer une authentification forte
- **Réduction de la surface d'information** : ne pas exposer les scores de confiance détaillés ni les logits bruts dans les réponses API, pour limiter les possibilités d'inversion de modèle
- **Chiffrement et cloisonnement** : chiffrer les poids du modèle, cloisonner l'environnement d'exécution, tracer et auditer chaque accès
- **Contrôle qualité du pipeline de données** : valider systématiquement les nouvelles annotations avant intégration au jeu de réentraînement pour prévenir le data poisoning
- La logique de **défense multicouche** (préventive + réactive + organisationnelle) est essentielle : aucune mesure isolée ne suffit face à la diversité des menaces

[exercice p. 22] **Solution n°8****Réponse attendue**

La politique de surveillance post-déploiement repose sur trois piliers. Le **monitoring de performance** consiste à suivre en continu les indicateurs de précision et de robustesse relative sur les flux réels, avec des alertes automatiques lorsque la performance descend sous un seuil critique (par exemple, précision inférieure à **88 %** sur une fenêtre glissante de 7 jours). La **détection d'anomalies sur les requêtes** vise à identifier les comportements suspects : pics de requêtes inhabituels, soumission de documents aux caractéristiques statistiquement anormales, tentatives répétées avec des variations mineures (signature d'une attaque adversariale ou d'une extraction). Enfin, la **gouvernance opérationnelle** structure la réponse : définition de plans d'incident avec escalade, audits de sécurité trimestriels alignés sur le cycle de réentraînement, documentation systématique des menaces identifiées et des correctifs appliqués, et réévaluation

de la robustesse après chaque mise à jour du modèle. Cette politique doit être inscrite dans la démarche MLOps de l'administration et validée conjointement par les équipes data, cybersécurité et conformité CNIL.

Éléments de solution

- **Monitoring continu des performances** : suivi en temps réel de la précision, du taux de rejet, de la robustesse relative sur les flux de production, avec seuils d'alerte paramétrables
- **Détection de dérive de distribution** : comparaison statistique régulière entre les données d'entrée en production et la distribution d'entraînement pour repérer les glissements (data drift)
- **Analyse comportementale des requêtes** : détection de patterns suspects (volumes anormaux, variations systématiques d'un même document, requêtes provenant de sources inhabituelles)
- **Journalisation et traçabilité** : enregistrement exhaustif de chaque requête, réponse et métadonnée associée pour permettre l'investigation post-incident
- **Plans de réponse aux incidents** : procédures documentées d'escalade, de mise en quarantaine du modèle, de rollback vers une version antérieure validée
- **Audits réguliers** : réévaluation de la robustesse et de la sécurité à chaque cycle de réentraînement trimestriel, et après toute découverte publique de nouvelles techniques d'attaque
- **Intégration dans la gouvernance IA** : la surveillance doit être portée conjointement par les équipes data science, cybersécurité et conformité, avec une documentation vivante des risques et des mesures
- La sécurité d'un modèle IA **n'est jamais acquise** : elle exige une réévaluation constante, en particulier après l'introduction de nouvelles données ou fonctionnalités